

Агенты и вайб-кодинг

Практический курс: как работать с ИИ-агентами
и не обманывать себя результатом

Собрано по материалам полугода профессиональной переписки практиков.
42 главы, десять модулей, приложения с чек-листами и шаблонами.

Содержание

Введение	4
Модуль 1. Устройство	7
Глава 1. Что такое агент	8
Глава 2. Анатомия агента	11
Глава 3. Харнесс: слово без одного значения	15
Глава 4. Как устроена модель: минимум механики	19
Глава 5. Маршрут новичка	23
Модуль 2. Постановка задачи	26
Глава 6. Спецификация вместо задания	27
Глава 7. Требования, понятные агенту	31
Глава 8. Диалог, который превращается в план	34
Глава 9. Выбор модели, уровень усилий и оценка сроков	38
Модуль 3. Обязка	42
Глава 10. Файл правил	43
Глава 11. Правила, которые работают	47
Глава 12. Скиллы: механика и жизненный цикл	52
Глава 13. Хуки и детерминированные гарантии	57
Глава 14. Инструменты и когда обязка вредит	61
Модуль 4. Контекст и память	65
Глава 15. Контекст как единственный ресурс	66
Глава 16. Сжатие и что должно его пережить	70
Глава 17. Память: файлы, векторы, нити	74
Глава 18. Поиск по коду и по документам	78
Модуль 5. Делегирование	82
Глава 19. Субагент: когда помогает, когда мешает	83
Глава 20. Многоагентность и рои	87
Глава 21. Роли и конвейер	91
Модуль 6. Проверка	95

Глава 22. Ревью	96
Глава 23. Эвалы	100
Глава 24. Детерминированные проверки вместо уговоров	104
Глава 25. Сколько полировать	108
Модуль 7. Автономность	112
Глава 26. Ночной прогон	113
Глава 27. Дрейф намерения	117
Глава 28. Автономный режим: что он реально делает	121
Глава 29. Постоянно работающий агент	125
Модуль 8. Люди и компании	129
Глава 30. AI-first процессы	130
Глава 31. Внедрение и неявное знание	134
Глава 32. Владение скиллами в компании	138
Глава 33. Роли: что теперь делает разработчик	142
Модуль 9. Безопасность и риски	146
Глава 34. Разрушительные действия и заборы	147
Глава 35. Изоляция, права, песочница	151
Глава 36. Почему правила не удерживают агента	155
Глава 37. Приватность и утечки	159
Модуль 10. Экономика и практика	163
Глава 38. Токеномика	164
Глава 39. Подписки, лимиты и горизонт	168
Глава 40. Личный агент	171
Глава 41. Агент в групповом чате	175
Глава 42. Документы, дизайн, интерфейсы	179
Заключение. Что устоялось, а что нет	183
Приложение А. Словарь терминов	186
Приложение Б. Чек-листы	188
Приложение В. Шаблоны запросов	191

Введение

Эта книга собрана из полугода переписки людей, которые каждый день работают с ИИ-агентами. Не из документации поставщиков, не из докладов на конференциях и не из постов, написанных ради охвата. Из рабочего разговора, где человек приходит с ошибкой, получает три разных совета, пробует, возвращается и рассказывает, что сработало.

У такого источника есть недостаток: здесь нет причёсанных методологий. И есть достоинство, ради которого всё и затевалось: здесь видна цена. Сколько стоит ошибка, сколько времени уходит на проверку, где красивая схема разваливается на второй неделе и почему совет, который звучит разумно, у половины людей не работает.

Для кого

Для человека, который начинает с нуля.

Вам не нужно уметь программировать, чтобы прочитать первые три модуля и начать пользоваться агентом осмысленно. Дальше пригодится хотя бы поверхностное представление о том, как устроена разработка, но каждое новое понятие вводится отдельно и объясняется на пальцах.

Если вы уже работаете с агентами, книга даст другое: сведённые вместе споры, которые вы наверняка вели сами, с их разрешением или с честным признанием, что разрешения нет.

Что здесь есть и чего нет

Есть: приёмы, проверенные на настоящих проектах, с указанием, где они ломаются. Разобранные инциденты. Измерения, которые люди делали для себя и выкладывали. Несколько десятков готовых формулировок, которые можно вставить в свои правила и запросы прямо сегодня.

Нет: сравнений конкретных моделей и цен. Такие вещи устаревают за месяц, и книга, набитая ими, превращается в архив. Названия инструментов встречаются только там, где без них не объяснить суть, и почти всегда описаны как класс, а не как бренд.

ТРИ СЛОВА, КОТОРЫЕ НУЖНЫ С ПЕРВОЙ СТРАНИЦЫ

Модель это то, что генерирует текст. Она ничего не помнит между вызовами и ничего не умеет делать руками.

Агент это модель, которую посадили в цикл и дали инструменты. Он может прочитать файл, запустить команду, посмотреть результат и решить, что делать дальше.

Обязка, она же харнесс, это всё, что вокруг: инструкции, набор инструментов, память, проверки. Именно она превращает модель в работника, и именно про неё большая часть этой книги.

Почему область выглядит такой запутанной

Потому что она молодая. Термины появляются быстрее, чем успевают получить общепринятое значение. Одно и то же слово у трёх собеседников означает три разные вещи, и они спорят часами, не заметив этого.

Книга не делает вид, что консенсус есть там, где его нет. Где мнение общее, так и написано. Где идёт спор, приведены обе стороны с их аргументами, и сказано, от чего зависит выбор. Таких мест немало, и это не слабость материала, а его состояние.

Как устроена книга

Десять модулей. Внутри каждой главы по три-пять страниц. Модули идут по нарастанию: сначала устройство, потом постановка задачи, потом обвязка, дальше более сложные темы. Но главы самостоятельны, и если вам прямо сейчас нужен ответ про память или про то, сколько полировать результат, идите сразу туда.

Модуль	О чём	Кому нужен
1. Устройство	Что такое агент и из чего состоит	Всем, с этого начинается счёт
2. Постановка задачи	Как объяснить, чтобы получилось	Всем
3. Обвязка	Правила, скиллы, хуки, инструменты	Всем
4. Контекст и память	Единственный ресурс и как им платят	Всем
5. Делегирование	Субагенты, рои, роли	Когда задача не влезает в разговор
6. Проверка	Ревью, эвалы, детерминированные тесты	Когда результат идёт наружу
7. Автономность	Долгие прогоны и дрейф	Когда хочется отойти от компьютера
8. Люди и компании	Внедрение, роли, владение	Кто отвечает не только за себя
9. Безопасность	Инциденты, изоляция, приватность	Перед первым доступом в прод
10. Экономика и практика	Счета и первые проекты	В любой момент

Первые четыре модуля стоит прочитать подряд: дальше всё на них опирается. Модули с пятого по седьмой нужны, когда задачи перестали помещаться в один разговор. Восьмой и девятый пригодятся, если вы отвечаете не только за себя. Десятый практический, его можно читать в любой момент, когда захочется что-нибудь собрать.

Пять типов врезок

Текст размечен так, чтобы можно было читать по-разному.

Врезка	Что внутри	Как читать
Главное	Сформулированный вывод раз-дела	Если торопитесь, читайте только их
Для новичка	Разбор базового понятия	Пропускайте, если понятие знакомо
Случай из практики	Разобранный инцидент	Здесь видна цена ошибки
Разные взгляды	Спор без победителя	Выбирать придётся вам
Что делать	Готовый чек-лист или шаблон	Можно применять сразу

Одна просьба

Не воспринимайте написанное как свод законов. Почти каждый приём в этой книге кто-то опроверг на своём проекте, и там, где это известно, так и сказано. Область меняется быстрее, чем печатается тираж.

Правильное отношение такое: здесь собрано то, что работало у многих на настоящих задачах. Проверяйте на своей. Единственное, что действительно универсально, это привычка измерять, а не верить.

Модуль 1. Устройство

Пять глав о том, из чего всё состоит.

Здесь вводятся понятия, на которые опирается вся остальная книга: что называют агентом и почему об этом спорят, из каких слоёв он собран, что означает слово харнесс, как работает модель внутри и с чего начинать человеку, который пришёл с нуля.

Если вы читаете подряд, этот модуль обязательный. Дальше без него будет непонятно.

Что такое агент

Спросите пятерых практиков, что такое агент, и получите пять определений. Причём каждый будет уверен, что его определение общепринятое, а остальные просто путаются в терминах.

Это не повод махнуть рукой. Определение нужно, иначе невозможно ответить на простейшие рабочие вопросы: считать ли агентом то, что вы собрали, стоит ли платить за инструмент, который называет себя агентской платформой, и почему совет из чужой статьи у вас не работает.

Разберём спор до конца, а потом дадим порог, которым можно пользоваться.

Четыре определения и четыре контрпримера

ЧТО ВООБЩЕ ПРОИСХОДИТ ВНУТРИ

Модель принимает текст и выдаёт текст. Всё. Она не запускает программы, не читает файлы, не помнит вчерашний разговор.

Чтобы она что-то сделала, кто-то должен: собрать текст запроса, отправить его, разобрать ответ, увидеть там просьбу вроде прочитай файл, выполнить эту просьбу самому и отправить результат обратно новым запросом. Этот кто-то и есть программа-обвязка. Повторяющиеся круги такого обмена называют циклом.

Первое определение самое популярное: агент это модель плюс инструкции плюс инструменты плюс контекст, работающие в цикле.

Контрпример: процессный агент, собранный из жёстко заданных шагов, цикла не имеет вообще. Ход исполнения задан заранее, модель вызывается на каждом шаге по одному разу. Но все вокруг называют такую штуку агентом, и спорить с этим бесполезно.

Второе определение: агент это модель плюс память плюс планирование плюс использование инструментов.

Контрпример: исследовательский режим поисковика. Там есть и планирование, и инструменты, и обвязка, собирающая контекст. А результат один: сообщение в чат, и всё только на чтение. Многие откажутся называть это агентом, потому что он ничего не делает.

Третье определение шире: агент это вся система, которая реально выполняет за вас работу, и неважно, как физически разнесены её части.

Контрпример: короткий ответ поисковика, собранный моделью из трёх найденных страниц. Работу за вас он тоже выполнил. Значит, и он агент? Тогда слово перестаёт что-либо означать.

Четвёртое, самое требовательное: агент это когда обязательно есть цикл и свобода выбора инструментов, плюс какое-то управление контекстом.


Контрпример: тот же процессный агент. И тот же исследовательский режим. Оба выпадают.

ГЛАВНОЕ ПРО ОПРЕДЕЛЕНИЕ

Спор не разрешается, потому что агентность это не свойство, а спектр. На одном конце одиночный вызов модели, на другом система, которая сама берёт задачи и сама их закрывает. Между ними десятки промежуточных форм, и каждый ставит порог там, где ему удобно. Требовать от собеседника вашего порога бессмысленно. Спрашивать, где стоит его, полезно.

Спектр вместо категории

Хорошая аналогия прозвучала в разговоре: солёная ли еда. Курица в меду солёная? А хлеб? А чиабатта? Соль есть везде, вопрос только в том, где вы проводите черту.

СПЕКТР АГЕНТНОСТИ

Слева направо растут три вещи одновременно: свобода агента, непредсказуемость результата и стоимость ошибки. Это единственная закономерность, которая работает независимо от определения, и на неё стоит опираться при выборе.

Рабочий порог

Если нужно одно предложение, вот оно.

Агент это посредник, который сам собирает контекст и сам выбирает инструменты.

Слово посредник тут ключевое. В обычном языке агент это тот, кто действует по вашему поручению: агент по недвижимости ищет квартиру, актёрский агент договаривается о работе. От него не требуется гениальности, от него требуется, чтобы он понял задачу и довёл дело до конца, обращаясь по пути к нужным людям и инструментам.

Из этого следует практический вывод, который переворачивает многие разговоры. Если вынести модель за скобки, качество агента определяется качеством его инструментов и тем, насколько эти инструменты понятны модели. Не размером модели. Не количеством инструкций. Инструментами и их описанием.

ТРИ ВЗГЛЯДА НА ГРАНИЦУ

Строгий. Нет цикла и свободы выбора, значит не агент, а процесс. Удобен, когда надо оценить риск: чем больше свободы, тем строже проверка.

Функциональный. Делает работу за человека, значит агент. Удобен в разговоре с бизнесом, где важен результат, а не устройство.

Инженерный. Агент это система с состоянием, идентичностью, памятью и границами. Удобен при проектировании, потому что сразу называет, что придётся построить.

Зачем это знать новичку

Затем, что от выбранного порога зависят три решения.

Сколько свободы дать. Чем правее по спектру, тем меньше вы можете предсказать. Задачу с высокой ценой ошибки лучше зажать в процесс, где шаги заданы, чем отдать агенту, который сам решит, как её сделать.

Что проверять. Процесс проверяется по шагам, агент только по результату и по траектории. Это разные затраты и разные инструменты, о чём отдельный модуль.

За что платить. Половина продуктов, которые называют себя агентскими платформами, продают вам процесс. Это не обман: процесс часто именно то, что нужно. Но платить за него как за агента не стоит.

КАК РАЗОБРАТЬСЯ В ЧУЖОМ ПРОДУКТЕ ЗА ПЯТЬ МИНУТ

1. Спросите, есть ли цикл. Модель вызывается один раз за шаг или столько, сколько сама решит?
2. Спросите про инструменты. Их набор фиксирован для шага или агент выбирает из общего списка?
3. Спросите, кто собирает контекст. Шаблон подставляет заранее известные поля или система решает, что положить?
4. Спросите, что происходит при ошибке. Повтор, откат, остановка или продолжение как ни в чём не бывало?
5. Три ответа из четырёх в пользу свободы означают агента. Иначе перед вами процесс, и это нормально.

Что запомнить

Единого определения нет, и в ближайшее время не будет. Есть спектр, на котором растёт свобода, а вместе с ней непредсказуемость и цена ошибки.

Рабочий порог: сам собирает контекст, сам выбирает инструменты.

И главное следствие, к которому мы будем возвращаться всю книгу: агент настолько хорош, насколько хороши его инструменты и описания этих инструментов. Всё остальное надстройка.

Анатомия агента

Чтобы дальше говорить предметно, агента надо разобрать на части. Иначе разговор всё время сваливается в общие слова: он тупит, он не слушается, он выдумывает. Тупит не он целиком, а какой-то один слой, и почти всегда можно сказать, какой.

Шесть слоёв

ЧТО ПРОИСХОДИТ ЗА ОДИН ХОД

Вы написали фразу. Дальше происходит вот что.

Программа собирает большой текст: правила проекта, описания доступных инструментов, историю разговора, вашу фразу. Отправляет это модели. Модель возвращает текст, в котором может быть просьба вызвать инструмент. Программа выполняет просьбу, кладёт результат в тот же большой текст и отправляет заново.

Так повторяется, пока модель не скажет, что закончила. Каждый круг стоит денег, потому что весь накопленный текст отправляется целиком.

Первое, что удивляет новичка: модель не помнит ничего. Каждый круг ей заново пересказывают всё, что было. Именно поэтому контекст оказывается главной валютой, и целый модуль этой книги посвящён тому, как им распоряжаться.

Слой	За что отвечает	Кто им управляет	Как ломается
Модель	Догадка, рассуждение, текст	Поставщик	Выдумывает, срезает углы
Цикл	Повторение ходов, остановка	Обязка	Зацикливается или бросает
Инструменты	Действия во внешнем мире	Вы	Плохое описание, нет ограничений
Контекст	Что модель видит сейчас	Обязка и вы	Переполнение, мусор, противоречия
Память	Что переживает разговор	Вы	Свалка фактов, устаревшее
Проверка	Признание работы годной	Вы	Её просто нет

Шестой слой стоит особняком. Он не внутри агента, он снаружи. И это единственный слой, который целиком ваш: поставщик его не сделает, фреймворк не подскажет.

ОДИН ХОД АГЕНТА



Модель: догадка и ничего больше

Модель хороша ровно в одном: угадывать, что уместно дальше. Это огромная сила, когда задача требует понимания, и полная беспомощность, когда задача требует точности.

Отсюда правило, которое стоит запомнить до всякой практики.

ГЛАВНОЕ ПРО РАЗДЕЛЕНИЕ ТРУДА

Модели отдавайте то, где нужна догадка. Всё, что требует надёжности, пишите кодом.

Формат ответа, описанный словами в запросе, нарушается примерно в одном случае из десяти. Это не лечится формулировкой, не лечится строгим тоном и не лечится большой моделью. Контракт должен обеспечивать код, который вызывает модель, а не абзац внутри запроса.

Пример, который часто разбирают. Есть инструмент распознавания блюд на подносе. Модели просят вернуть ответ в определённом формате, и формат описан прямо в тексте запроса. В девяти случаях из десяти всё хорошо, в десятом формат нарушен, и всё разваливается. Правильное решение не в том, чтобы написать формат покрупнее, а в том, чтобы обвязка сама принуждала к структуре ответа.

Цикл: что заставляет всё работать

Цикл это простая петля: спросили, получили просьбу, выполнили, спросили снова. Вся сложность в двух вопросах, которые редко задают вслух.

Когда останавливаться? Если критерия нет, агент либо закончит слишком рано и объявит готовым недоделанное, либо будет крутиться, пока не кончатся деньги.

Что делать при ошибке? Повторить, откатиться, спросить человека или пойти дальше как ни в чём не бывало. Четвёртый вариант выбирается по умолчанию, если вы не выбрали иначе, и именно он приносит больше всего сюрпризов.

МИНИМУМ, КОТОРЫЙ ДОЛЖЕН БЫТЬ В ЛЮБОМ ЦИКЛЕ

1. Явный признак завершения. Не молчание модели, а проверяемое условие.
2. Ограничение на число ходов. Иначе одна неудачная задача съест дневной бюджет.
3. Правило при ошибке инструмента: повтор с ограничением, откат, остановка.
4. Запрет объявлять готовым то, что не прошло проверку.

Последний пункт стоит выделить. Если агент не может доказать, что задача выполнена, он не имеет права говорить, что она выполнена. Это правило встречается в каждом серьёзном

разборе, потому что нарушается оно постоянно.

Инструменты: интерфейс важнее уговоров

Инструмент это не функция, а контракт. У него есть схема входа, предусловия, побочные эффекты, таймаут, поведение при повторном вызове и права.

Слово идемпотентность звучит страшно, а значит простую вещь: повторный вызов не должен ломать мир. Отправить письмо дважды плохо. Пересчитать сумму дважды нормально. Если инструмент не идемпотентен, повтор при ошибке становится опасным, и это надо знать заранее, а не выяснять на проде.

Второе важное свойство: описание инструмента это часть его работы. Модель выбирает инструмент по описанию, и плохое описание означает, что инструмент не будет вызван вовремя или будет вызван не туда. Мы вернёмся к этому в главе про скиллы, где та же закономерность видна ещё резче.

СПОРНАЯ ГРАНИЦА: ИНСТРУМЕНТЫ ИЛИ ПОДКЛЮЧАЕМЫЕ СЕРВЕРЫ

За отдельные утилиты. Их проще тестировать, они не занимают место в контексте постоянно и работают в любом окружении. Практики, которые упаковывали внешние интерфейсы в утилиты, отмечали, что фон выдумок пропал.

За протокольные подключения. Единый способ подключить чужой сервис, не описывая его руками. Удобно, когда сервисов много и они чужие.

Что решает на практике. Скорость появления: утилиту пишут за десять минут, подключение согласовывают неделями. Поэтому набор утилит вырастает быстрее, и большинство команд живут на нём.

Контекст: то, за что вы платите

Контекст это весь текст, который уходит модели на каждом круге. Правила проекта, описания инструментов, история, результаты вызовов, ваша фраза.

Два свойства делают его главной темой книги.

Он платный. Каждый круг оплачивается целиком, а не по приросту. Длинный разговор дорожает нелинейно.

Он ограничен. И даже внутри лимита работает неравномерно: начало и конец модель использует лучше, чем середину. Чем больше вы туда положили, тем меньше внимания достаётся каждой части.

Память: то, что переживает разговор

Память это всё, что должно сохраниться, когда разговор кончится. Она бывает трёх видов, и все три нужны в разных случаях: файлы, векторный поиск и нити с историей решений. Целая глава разбирает, какой вид что решает и какими болезнями болеет.

Пока достаточно одного различия. Контекст это то, что модель видит сейчас. Память это то, откуда в контекст попадает нужное. Путать их дорого: люди сваливают в правила проекта

то, чему место в памяти, и потом удивляются счёту.

Проверка: слой, которого обычно нет

Разбирая чужие сборки, практики чаще всего находят одно и то же: модель выбрана, инструменты написаны, правила расписаны на трёх страницах, а как понять, что стало лучше, никто не знает.

ГЛАВНОЕ ПРО АНАТОМИЮ

Пять слоёв внутри агента делают работу. Шестой, снаружи, отвечает на вопрос, годится ли она.

Первые пять можно взять готовыми: модель у поставщика, цикл у фреймворка, инструменты у сообщества. Шестой придётся построить самому, потому что он зависит от вашей задачи. И именно он отличает работающего агента от впечатляющей демонстрации.

Кто чем управляет

Полезно понимать, где проходит граница вашей ответственности.

Поставщик даёт модель и её поведение. Вы на это не влияете, кроме выбора модели и уровня усилий, и должны быть готовы к тому, что поведение поменяется без предупреждения.

Фреймворк даёт цикл, вызовы инструментов, базовое сжатие. Это можно взять готовым, и почти всегда стоит.

Ваша зона: описания инструментов, правила, память, проверки. Здесь ничего готового нет, и здесь решается, будет ли работать.

Что запомнить

Агент это шесть слоёв, а не монолит. Когда что-то идёт не так, определите слой: выдумки это модель, бесконечное кручение это цикл, не тот инструмент это описание, забыл сказанное это контекст или память, объявил готовым недоделанное это отсутствие проверки.

Модели отдавайте догадку, всё остальное коду. Формат, описанный словами, нарушается в одном случае из десяти.

И последнее, к чему мы будем возвращаться: агент это не веса и не обвязка, а модель вместе с инструкциями, памятью и историей. Уберите любой слой, и перед вами другой агент.

Харнесс: слово без одного значения

Есть слово, которое за полгода стало главным в профессиональном разговоре и при этом не получило общепринятого значения. Харнесс. Дословно упряжь.

Разбираться с ним нужно не из любви к терминологии. Половина непониманий между людьми, которые вроде бы говорят об одном, происходит именно здесь. Один имеет в виду автономность, другой набор инструментов, третий систему целиком, и они спорят час, не заметив расхождения.

Три определения, которые ходят рядом

Автономность. Харнесс не про быструю и качественную разработку кода, а про то, чтобы агент работал сам, с долгим временем цикла, особенно на этапе отладки. При таком взгляде харнесс это способность отойти от компьютера.

Полная автономка. Более радикальная версия того же: агент сам забрал задачу, сам разбил, сам сделал, сам закрыл, взял следующую. Тут харнесс уже почти синоним самостоятельной системы.

Упряжь. Не автономность, а оснастка: инструменты, скиллы, правила, проверки. Модель это лошадь, упряжь это то, что на неё надето, агент это тот, кто едет. Чем лучше лошадь и упряжь, тем дальше и бодрее едешь.

КАКОЕ ОПРЕДЕЛЕНИЕ ВЫБРАТЬ

Если вы оцениваете риск, берите определение через автономность. Оно сразу говорит, сколько свободы вы отдаёте.

Если вы строите, берите определение через упряжь. Оно называет части, которые придётся сделать руками.

Если вы объясняете бизнесу, берите определение через результат. Остальное только запутает.

Главное не спорить о слове, а спросить собеседника, что он имеет в виду. Это экономит час.

Отрезвляющий вопрос

В самом конце разговора кто-то задал вопрос, на который никто не смог ответить убедительно. Чем сегодняшний харнесс отличается от того, что было почти год назад, когда уже существовали субагенты со своими инструкциями под разные задачи?

Ответ прозвучал такой: в основном названием. Раньше говорили, что нашли классный запрос для модели, теперь говорят харнесс.

Это не повод отмахнуться от темы, но это повод относиться к терминологии трезво. Половина словаря области родилась в социальных сетях: кто-то произнёс слово, остальные подхватили. А дальше слово превращается в сроки и бюджеты, потому что про это все говорят.

ГЛАВНОЕ ПРО ТЕРМИНОЛОГИЮ

Проверяйте, за что именно вы платите. Если продукт продаёт вам харнесс, спросите, что входит: цикл, память, набор инструментов, проверки, изоляция? Ответ покажет, речь про новую сущность или про переупакованное старое.


И договоритесь о значениях внутри команды. Общепринятого может не появиться вовсе.

Каркас, с которым можно работать

Спор о слове разрешается практически: не выбирать определение, а перечислить, из чего харнесс состоит. Такой список собрали в разговоре, и он стал опорной схемой для целого модуля этой книги.

- 1. Архитектура и идентичность.** Харнесс это система с состоянием, идентичностью, памятью и границами. Нужна идентичность, переживающая перезапуск. Нужно разделение стабильных инструкций, текущей траектории, рабочего состояния, журнала событий и долгосрочной памяти. И нужен ответ на вопрос, что агент имеет право менять в себе сам.
- 2. Инженерия контекста.** Правила сжатия: когда и что схлопывается. Происхождение: откуда взялся кусок. Удержание: что забывается, а что хранится вечно. И явное разделение того, что инструкция, что факт, что гипотеза, а что воспоминание.
- 3. Инструменты как граждане первого класса.** Схема, предусловия, побочные эффекты, таймаут, поведение при повторе, права, песочница, формальный контракт входа и выхода.
- 4. Контур надёжности.** Контекст, инструменты, ограничения, проверка, коррекция. С лимитами, повторами, откатом и терминальными состояниями.
- 5. Многоагентность без хаоса.** Субагенты на подзадачи, обмен находками, возврат результата на интеграцию вместо сваливания в общий контекст, видимость того, кто чем занят, и возможность остановить любого.
- 6. Скиллы и плагины.** Простой способ подключить и отключить, реестр, явное указание, что активно, права владельца.
- 7. Прозрачность.** Трассировки, метрики, разделение доказательств, выводов и неизвестного. В идеале воспроизводимые прогоны.
- 8. Проверки как обязательная часть.** Базовая линия, состязательные случаи, релизный шлюз, канареечный выпуск, откат.
- 9. Независимость от поставщика.** Иначе смена тарифа обрушивает продукт.
- 10. Чего избегать.** Не строить систему вокруг отпечатка конкретной машины: это привязка и проблемы с переносимостью.

КАК ЧИТАТЬ КАРКАС



Универсального харнесса не будет

Важное наблюдение, которое экономит месяцы: переиспользуются только базовые куски. Поиск, линтеры, работа с историей изменений. Всё остальное зависит от стека, задачи и размера проекта.

Из этого следуют два практических вывода.

Первый: не ищите готовую обвязку, которая подойдёт вам целиком. Её нет, и попытка натянуть чужую обычно заканчивается тем, что вы неделю правите чужие решения под свои задачи.

Второй: не начинайте со сборки харнесса. Начинайте с задачи. Обвязка появляется как ответ на конкретную боль, а не как проект сам по себе.

Собственно, это и была шутка, которая ходила по кругу: я делаю этот харнесс, чтобы написать наш основной харнесс, а тестирую пока на другом маленьком харнессе. Смешно ровно потому, что похоже на правду.

Мета-харнесс

Идея, которая оформилась в рабочую практику: на проект делается два набора обвязки. Один рабочий, второй тестирующий. Второй нужен, чтобы измерять первый.

Звучит избыточно, но именно отсутствие второго объясняет, почему люди годами спорят о приёмах вместо того, чтобы их сравнить.

С ЧЕГО СОБРАТЬ СВОЮ ОБВЯЗКУ

1. Возьмите задачу, которую делаете чаще всего.
2. Запишите, где именно агент спотыкается. Три-пять мест, не больше.
3. Каждое место закройте самым дешёвым способом: правилом, описанием инструмента, хуком.
4. Заведите одну проверку, которая покажет, стало ли лучше.
5. Через месяц отключите всё и посмотрите, что вернуть. Половина не понадобится.

Что запомнить

Единого значения у слова нет. Есть три ходовых, и они несовместимы.

Опора не в определении, а в каркасе из десяти пунктов: идентичность, контекст, инструменты, надёжность, многоагентность, скиллы, прозрачность, проверки, независимость от

поставщика и отказ от привязки к машине.

Универсальной обвязки не будет. Переиспользуется поиск, линтеры и история изменений, остальное всегда своё.

И привычка, которая пригодится не только здесь: когда слово в разговоре начинает работать как заклинание, спросите, что оно означает у собеседника.

Как устроена модель: минимум механики

Эта глава про внутренности, и её легко пропустить. Не пропускайте. Половина рабочих приёмов из следующих модулей выглядят как суеверия, пока не поймёшь, откуда они берутся. А когда поймёшь, начинаешь придумывать свои.

Механики здесь ровно столько, сколько нужно, и ни строчкой больше.

Системный запрос не имеет особого статуса

Первое открытие, которое переворачивает представление у большинства новичков.

Существует убеждение, что системные инструкции модель воспринимает как-то иначе: серьёзнее, приоритетнее, обязательнее. Отсюда попытки написать их капсом, добавить слова обязательно и критически важно, продублировать трижды.

Внутри модели никакого особого канала нет. Системный запрос это такой же текст, попадающий в тот же поток. Разница только в том, что он стоит в начале и обычно повторяется каждый круг.

ЧТО МОДЕЛЬ ВООБЩЕ ДЕЛАЕТ С ТЕКСТОМ

Модель предсказывает продолжение. Она получает всю ленту текста и оценивает, какой кусок должен идти дальше, опираясь на то, что видела при обучении.

Никакого исполнения команд там нет. Есть текст, который делает одни продолжения вероятнее других. Инструкция работает не потому, что это приказ, а потому что после такой инструкции в обучающих данных чаще шло соответствующее поведение.

Из этого сразу следуют два практических правила, которые в другом месте книги разобраны подробно.

Объяснение работает лучше запрета. Голый запрет это короткая строка, которая слабо влияет на вероятности. Запрет с причиной разворачивается в рассуждении и тянет за собой поведение даже там, где формально не нарушен.

Повторение не усиливает. Оно просто занимает место. А место платное.

Три границы знаний

Второе открытие. У модели не одна дата, после которой она ничего не знает, а три.

Граница предобучения. Когда собрали основной массив текстов. Новые модели далеко не всегда получают новый массив: часто это дообучение прежнего, и тогда фактическая осведомлённость остаётся на месте.

Граница инструктивного набора. Когда собрали примеры того, как отвечать. Здесь закладывается стиль, форматы и привычки.

Границы сред дообучения. Когда собрали задачи, на которых модель тренировали действовать. И вот тут начинается самое неприятное.

ГЛАВНОЕ ПРО ЗНАНИЯ МОДЕЛИ

Дообучение с подкреплением ломает то, что не попало в его среды. Знание не просто устаревает, оно искажается, а уверенность при этом остаётся прежней.

Практическое следствие: модель уверенно ошибается в новых версиях библиотек и в свежих интерфейсах. Не потому что не знает, а потому что помнит по-старому. Лечится это не уточняющим вопросом, а подсунутой документацией.

Отсюда простой рабочий приём, который окупается почти всегда: перед задачей на незнакомой библиотеке скормите модели выжимку из актуальной документации. Дешевле, чем ловить последствия.

Начало и конец ленты работают лучше середины

Третье. Внимание распределяется неравномерно. Последние куски текста модель использует хорошо, начало тоже неплохо, середина проседает.

Практических следствий три.

Важное кладите ближе к концу запроса, а не в середину простыни.

Чем больше вы положили, тем меньше внимания достаётся каждой части. Это не значит, что надо экономить всегда: если материалы не противоречат друг другу, чуть больше лучше, чем чуть меньше, потому что дочитывать дороже. Но если материалы противоречат, лишнее вреднее нехватки.

И самое неприятное: длинный файл модель не читает целиком. Один и тот же эксперимент проводили дважды с интервалом в несколько месяцев, и результат поменялся: то, что раньше читалось полностью, потом перестало. Это значит, что проверять надо у себя и сейчас, а не полагаться на чужой прошлогодний результат.

Рассуждения вам не покажут

Четвёртое, и оно про наблюдаемость.

Раньше был приём: попросить модель проговорить ход мыслей вслух, и качество ответа росло. Потом это назвали рассуждением, встроили внутрь и закрыли. Сегодня внутренние рассуждения в большинстве продуктов зашифрованы и недоступны.

Отсюда две ловушки.

КАК УЗНАТЬ, ПОЧЕМУ АГЕНТ ТАК РЕШИЛ



Первая ловушка: модель может выдумать объяснение. Оно будет складным и правдоподобным, потому что складность это ровно то, что она умеет.

Вторая тоньше и важнее. Сама просьба объяснить меняет решение. Вы спрашиваете, почему она поступила так, и она в процессе ответа заново проходит рассуждение, приходя иногда к другому выводу. Вы измеряете не то, что было, а то, что получилось при измерении.

Вывод для практики: наблюдаемость строится снаружи, через трассировки и экспорт сессий. Самоотчёт агента это материал для размышления, а не свидетельство.

Оптимизация под измеримое

Пятое, и самое неприятное для тех, кто выбирает модель по таблицам.

Модели обучают так, чтобы они хорошо решали задачи, которые можно проверить автоматически. Это работает, и прогресс на таких задачах настоящий. Но у этого есть цена: то, что не похоже на проверяемую задачу, улучшается медленнее, а иногда деградирует.

Формулировка, которая ходила в разговорах: там, где не оптимизируют под измерение, всё сломано.

КАК ОТНОСИТЬСЯ К ТАБЛИЦАМ С РЕЗУЛЬТАТАМИ

Скептик. Рекорд всегда показывают в самом проработанном направлении, у самой неурезанной версии, на самом удачном наборе. На вашу задачу это не переносится.

Прагматик. Таблица показывает не качество, а направление вложений поставщика. Если в вашей области он не вкладывался, вы это почувствуете.

Что делать в обоих случаях. Собрать десяток своих задач и мерить на них. Это единственная таблица, которая имеет к вам отношение.

Отдельно стоит знать, что качество плавает и внутри одного дня. В пиковые часы поставщики применяют приёмы экономии, и поведение модели заметно меняется. Люди составляют себе личные памятки, в какое время лучше работать, и памятки эти у всех разные. Это само по себе говорит, что мерить надо у себя.

Пять заблуждений

Заблуждение	Что на самом деле
Системная инструкция важнее остального текста	Особого канала нет, это такой же текст
Повторить трижды значит убедить	Повтор занимает место и почти не влияет
Модель знает всё до своей даты	Границ три, и дообучение искажает знания
Можно спросить, почему она так решила	Ответ может быть выдуман, а сам вопрос меняет решение
Модель одинакова в любой час	Поведение плавает, в том числе по времени суток

Что запомнить

Модель предсказывает продолжение. Всё, что вы делаете с инструкциями, вы делаете с вероятностями, а не с приказами.

Границ знаний три, и уверенность модели не связана со свежестью того, о чём она говорит.

Внимание неравномерно: начало и конец работают лучше середины, а объём отбирает внимание у каждой части.

Рассуждения недоступны, самоотчёт ненадёжен, наблюдаемость строится снаружи.

И главное: измеряйте на своих задачах. Всё остальное чужая статистика.

Маршрут новичка

Самый частый вопрос в профессиональных разговорах звучит так: с чего начать. Отвечают на него по-разному, и оба ходовых ответа рабочие, просто подходят разным людям.

Два маршрута

От практики. Берёте свою настоящую задачу, поручаете её агенту, упираетесь в проблему, разбираетесь именно с ней, идёте дальше. Теория подтягивается по мере надобности и сразу ложится на пережитое.

Плюс: вы с первого дня получаете пользу и не бросаете. Минус: набор знаний получается дырявым, и какое-то время вы не понимаете, почему одно работает, а другое нет.

От устройства. Сначала разбираетесь, как устроен цикл, что такое контекст, откуда берутся инструменты. Потом собираете что-то простое своими руками. Потом идёте к задачам.

Плюс: меньше суеверий, быстрее растёте после первого месяца. Минус: скучно, и многие бросают на середине.

ЧТО ВЫБРАТЬ

Если у вас есть задача, которая болит прямо сейчас, идите от практики. Мотивация важнее полноты.

Если вы уже пробовали и запутались, отступите на шаг и разберитесь с устройством. Скорее всего, вы боретесь с симптомом.

Если вы вообще не программист, начинайте от практики, но с задач, где цена ошибки нулевая: тексты, разбор документов, личные заметки.

Порог входа не упал, он сместился

Есть красивая мысль, которую любят повторять: теперь программировать может каждый. Есть противоположная: без опыта разработки ничего не выйдет. Обе неточны.

Что действительно произошло: меньше стало нужно знать синтаксис и помнить интерфейсы. Больше стало нужно уметь другое.

Стало неважно	Стало важнее
Помнить синтаксис языка	Формулировать задачу однозначно
Знать интерфейс библиотеки наизусть	Понимать, где решение сломается
Быстро печатать	Придумать, чем проверить результат
Держать в голове весь проект	Решить, что отдать, а что делать самому

Отсюда неприятная новость для тех, кто рассчитывал обойтись без опыта: без понимания того, где решение ломается, вы не отличите работающее от кажущегося работающим. И

приятная для тех, кто боялся не потянуть синтаксис: он больше не барьер.

Учиться на своей задаче

Совет, который повторяют чаще всего и который стоит принять всерьёз: не учитесь на учебных задачах. Возьмите свою.

Причина простая. В учебной задаче вы не понимаете, хорош ли результат, потому что вам всё равно. В своей вы сразу видите, что агент не учёл, и это и есть учебный материал.

Первая цель для человека, который начинает, обычно одна и та же: автоматизировать собственную рутину. Что-то, что вы делаете еженедельно и что вас раздражает.

ВОСЕМЬ НЕДЕЛЬ, ПО НЕДЕЛЕ НА ШАГ

1. **Разговор.** Просто пользуйтесь моделью на своих задачах. Заметьте, где она угадывает, а где промахивается.
2. **Первый агент.** Возьмите готовый инструмент с доступом к файлам. Поручите разобрать папку, собрать сводку, найти повторы.
3. **Правила.** Заведите файл правил проекта. Записывайте туда только то, что нельзя понять, посмотрев на файлы.
4. **Проверка.** Придумайте, чем вы проверяете результат. Хотя одну проверку, но автоматическую.
5. **Первый скилл.** Оформите то, что повторили больше трёх раз, в отдельную инструкцию с описанием, когда её применять.
6. **Долгая задача.** Разбейте задачу на пункты с критериями готовности и запустите по одному пункту за раз.
7. **Измерение.** Прогоните одну и ту же задачу пять раз. Посмотрите, насколько расходятся результаты. Это отрезвляет сильнее любой главы.
8. **Уборка.** Отключите всё, что накопили. Верните только то, без чего стало заметно хуже.

Восьмая неделя не шутка. Это самый недооценённый шаг, и он отдельно разобран в главе про вред обвязки.

Что не работает

Копировать чужую обвязку целиком. Чужие правила написаны под чужой стек, чужую модель и чужие болячки. Половина из них у вас будет мешать, и вы не поймёте, какая именно.

Собирать инструменты вместо решения задач. Симптом узнаваемый: три недели настраиваете окружение и ни одной закрытой задачи. Окружение вторично.

Верить в один хитрый приём. Его нет. Работает эмпирический цикл: дать задачу, которая кажется слишком сложной, снабдить инструментами проверки, посмотреть, где модель ошибается, и починить именно это место.

Читать бесконечно. Через месяц вы заметите, что новости перестали давать полезное и все обсуждают одно и то же. Это нормальный признак роста: обсуждение всегда идёт на массовом уровне, и когда вы его перерастаете, становится скучно.

Про курсы и источники

Вопрос неизбежный, ответ такой.

Курс имеет смысл, когда практик показывает, как он работает: что открывает, что пишет, где останавливается. Это трудно получить из текста.

Курс не имеет смысла, когда учат очевидному с нуля. У вас есть неисчерпаемый источник объяснений под рукой, который отвечает на любой вопрос столько раз, сколько нужно, и сразу даёт попробовать.

Отдельно про соревнования и открытые разборы. Это лучший источник честных данных, который есть, потому что там видно не заявление, а результат на общей задаче. Разбор чужого решения даёт больше, чем десять статей: видно, что человек делал, чем платил и где обманул сам себя.

ГЛАВНОЕ ПРО ВХОД

Единственный универсальный навык это привычка измерять. Не выбор модели, не набор инструментов, не длина правил.

Возьмите десять своих типовых задач. Прогоните каждую несколько раз. Запишите, что получилось. Всё остальное в этой книге имеет смысл только на фоне таких измерений, потому что иначе вы не отличите улучшение от совпадения.

Чего ожидать по времени

Первая неделя приносит эйфорию. Всё получается, задачи закрываются за минуты, кажется, что мир изменился.

Через месяц эйфория проходит, и остаётся привычка. Вы начинаете видеть, где агент врёт, и перестаете радоваться каждому ответу. Это правильный момент: именно тут начинается работа.

Через три месяца появляется собственный набор приёмов, и он не будет похож на чужой. К этому моменту у вас накопится свой обвес, и его пора будет чистить.

Что запомнить

Два маршрута, оба рабочие. Выбирайте по тому, есть ли у вас болящая задача.

Порог входа сместился: меньше синтаксиса, больше проектирования и проверки.

Учитесь на своей задаче, начинайте с рутины, где цена ошибки нулевая.

Единственного хитрого приёма нет. Есть цикл: дать сложную задачу, дать инструменты проверки, посмотреть, где ломается, починить именно это.

И привычка измерять важнее всего остального вместе взятого.

Модуль 2. Постановка задачи

Четыре главы о том, что происходит до запуска.

Качество результата определяется на входе. В этом модуле: почему спецификация заменила задание, как формулировать требования, чтобы агент мог проверить себя сам, как превратить разговор в план и как выбрать модель, уровень усилий и оценить сроки.

Модуль применим независимо от того, программируете вы или нет.

Спецификация вместо задания

Есть закономерность, которую подтверждают все, кто работал с агентами дольше пары месяцев. Качество результата определяется на входе. Не моделью, не набором инструментов, не длиной правил. Тем, насколько точно поставлена задача.

Звучит банально ровно до момента, когда выясняется, что именно считать точной постановкой.

Прототип стал техническим заданием

Самое интересное изменение последнего года описали так: уровень абстракции сместился настолько, что само техническое задание теперь и есть рабочий проект, только в миниатюре.

История из практики. Руководитель, вместо того чтобы долго рассказывать, что он хочет увидеть от продукта, берёт низкокодový конструктор, собирает рабочий процесс сам и показывает прототип. А дальше говорит: сделайте мне это агентами и в прод.

Причина, по которой так делают, не в лени. Собрать миниатюру быстрее, чем написать длинный документ, и понимается она однозначнее. Из текста каждый вычитывает своё, из работающего прототипа вычитать нечего: вот кнопка, вот результат.

ГЛАВНОЕ ПРО ПОСТАНОВКУ

Если можете показать вместо того, чтобы описать, показывайте. Работающая миниатюра, набросок интерфейса, пример готового результата, набор тестов, кусок кода из другого проекта.

Спецификацией может быть что угодно, что снимает неоднозначность. Формат текста тут не священный.

Это касается и мелочей. Макет интерфейса работает лучше, чем описание дизайна словами. Пример желаемого ответа работает лучше, чем перечисление требований к ответу.

Из чего состоит пакет документов


На серьёзную задачу практики готовят не один файл, а четыре. Схема устоявшаяся, её описывали независимо разные люди.

Документ	Что внутри	Кто читает
Центральная спецификация проекта	Что за система, границы, ключевые решения	Все агенты, всегда
Спецификация под новую функцию	Что именно делаем сейчас, критерии готовности	Агент на этой задаче
План реализации	Разбивка на пункты в нужном порядке	Агент, по одному пункту

Документ	Что внутри	Кто читает
Файл прогресса	Что сделано, что заблокировано, что пропущено	Агент пишет, человек читает

Четвёртый файл важнее, чем кажется. Он превращает автономную работу из чёрного ящика в наблюдаемую: утром вы читаете не код, а отчёт о том, где агент застрял.

ПУТЬ ЗАДАЧИ



Один файл или несколько

Спор, у которого нет универсального ответа, но есть внятные аргументы с обеих сторон.

За один центральный документ. Несколько файлов хуже поддерживаются: агент что-то меняет в одном и забывает в другом, и через неделю они расходятся. Один файл на четыре-пять тысяч строк удерживается нормально.

За разбивку по областям. Если файл огромный, агенту приходится искать нужную часть поиском, а мог бы прочитать доменную спецификацию целиком. Особенно заметно на больших системах, где области почти не пересекаются.

КАК РЕШИТЬ У СЕБЯ

Ориентируйтесь на связность. Если ваши области действительно независимы и меняются по отдельности, разбивайте. Если правки постоянно затрагивают несколько областей сразу, держите один файл, иначе будете ловить рассинхронизацию.

Практический признак: если при изменении в одном файле вы каждый раз лезете править второй, объединяйте.

Спецификация это не описание, а договор о проверке

Главная ошибка новичка: спецификация описывает, что должно быть сделано, и молчит о том, как понять, что это сделано.

Такая спецификация даёт агенту свободу объявить работу готовой в любой момент. И он ею воспользуется, потому что закрыть задачу это то, к чему его подталкивает всё устройство.

Правильная спецификация отвечает на три вопроса.

Что должно получиться. Не как это сделать, а что появится в мире.

Как это проверить. Конкретно: какая команда, какой файл, какой ответ.

Когда переходить дальше. Явный запрет двигаться к следующему пункту, пока текущий не закрыт по критериям.

Полный конвейер


У команд, которые прошли этот путь до конца, конвейер выглядит примерно одинаково.

Сначала требования на человеческом языке. Потом их превращают в исполняемые спецификации, где каждое требование связано с проверкой. Потом по спецификациям пишется код, вертикальными срезами, а не слоями. Потом проверка, потом приёмка.

Ключевая деталь: границы сужаются от шага к шагу. К моменту, когда агент пишет код, свободы у него почти не остаётся, и уйти в дебри негде.

Практик, который довёл эту схему до рабочего состояния, сформулировал так: у меня разделены фазы написания требований, написания исполняемых спецификаций и реализации кода под спецификации. На последнем этапе границы уже чётко очерчены, и дебри найти очень сложно.

КУДА УХОДИТ ВРЕМЯ



Сколько документации на самом деле нужно

Противоположная крайность тоже существует: люди пишут спецификации на сорок страниц и потом обнаруживают, что агент их не читает целиком, а сами они устали ещё на пятнадцатой.

Ориентир, к которому пришли практики: документация нужна ровно там, где без неё агент ошибётся. Всё остальное он выведет из кода.

ПРОВЕРКА СПЕЦИФИКАЦИИ НА ДОСТАТОЧНОСТЬ

1. Есть ли в ней хоть одно утверждение, которое нельзя понять, посмотрев на код? Если нет, спецификация не нужна, хватит кода.
2. Может ли агент по ней однозначно сказать, готова задача или нет? Если нет, добавьте критерии.
3. Есть ли в ней то, что уже написано в коде? Уберите, это будет расходиться.
4. Прочитайте её вслух. Места, где вы запнулись, агент поймёт неправильно.

Чего спецификация не решает

Честности ради. Спецификация не спасает от одного класса проблем: от того, чего вы сами не знаете.

Дефекты живут там, где ни документация, ни спецификация их не описывают. Внешний интерфейс возвращает не то, что обещал. Идентификатор, который по всей логике должен быть постоянным, вдруг меняется. Ни одна методология этого не ловит, ловит только реальный прогон.

Поэтому спецификация не отменяет проверки, а делает её возможной. Это разные слои, и оба нужны.

Что запомнить

Показывайте вместо описания, если можете. Прототип понимается однозначнее текста.

Пакет из четырёх документов: центральная спецификация, спецификация функции, план, файл прогресса.

Спецификация без критериев проверки это разрешение объявить готовым что угодно.

Границы сужаются по фазам: требования, исполняемые спецификации, код. К последней фазе свободы почти нет, и это правильно.

И документация нужна только там, где без неё агент ошибётся. Всё остальное он прочитает в коде.

Требования, понятные агенту

Спецификация из прошлой главы состоит из требований. Эта глава про то, как их формулировать, чтобы агент мог проверить себя сам.

Разница принципиальная. Требование, которое агент не может проверить, это пожелание. Он его прочитает, кивнёт и объявит выполненным, когда сочтёт нужным.

Описание чёрного ящика

Приём, вокруг которого сложился консенсус: описывайте не то, как делать, а то, что приходит на вход и что должно получиться на выходе. Внутренности не описываются.

ОТКУДА ЭТО ВЗЯЛОСЬ

Подход называют поведенческим описанием. Он старше агентов лет на двадцать и придуман был для другой цели: чтобы бизнес и разработчики понимали друг друга.

Идея простая. Вместо технической формулировки пишут сценарий: в такой-то ситуации, при таком-то действии, должен получиться такой-то результат. Три части, никакой реализации.

С агентами приём заиграл заново, потому что такой сценарий одновременно и постановка задачи, и готовый тест.

Сравните две формулировки одного требования.

ОПИСАНИЕ РЕАЛИЗАЦИИ

Добавить проверку в обработчик формы

Использовать регулярное выражение для валидации

Вернуть ошибку 400

ОПИСАНИЕ ПОВЕДЕНИЯ

Если пользователь отправил форму с пустым полем адреса

То заявка не создаётся

И пользователь видит объяснение, какое поле не заполнено

Слева агент прочитает и сделает буквально: добавит проверку туда, куда написано, и не подумает о том, что бывают другие пути создания заявки. Справа он вынужден закрыть поведение целиком, а как именно, решает сам.

Второе важное отличие: правое требование можно проверить, не заглядывая в код. Левое нельзя.

Атомарность

Второе свойство хорошего требования: оно про одну вещь.

Требования вида пользователь может управлять профилем бесполезны. Управлять это создать, изменить, удалить, восстановить, перенести. Каждое со своими краевыми случаями, и агент закроет то из них, которое первым пришло ему в голову.

Признак неатомарного требования: в нём есть союз и или слово управление, работа, обработка.

Критерии готовности

Третье и самое важное. У каждого требования должен быть проверяемый признак выполнения, и он должен лежать прямо в спецификации.

Схема, которая работает у практиков: в спецификации есть отдельный раздел с критериями, и в задании агенту стоит явный запрет двигаться дальше, пока критерии текущего пункта не закрыты.

ШАБЛОН ТРЕБОВАНИЯ ИЗ ЧЕТЫРЁХ СТРОК

Ситуация. Когда происходит вот это.

Действие. И пользователь или система делает вот то.

Результат. Тогда в системе появляется вот это, наблюдаемое снаружи.

Проверка. Проверяется командой, тестом или запросом, вот таким. Пока не проходит, к следующему пункту не переходим.

Четвёртая строка отличает требование от пожелания. Без неё три первых это просто вежливый текст.

Один пункт за раз

Есть схема, которую практики называют более дисциплинированной, и она заметно снижает вероятность уехать не туда.

Вместо того чтобы дать агенту весь план сразу, ему говорят: возьми спецификацию, перед выполнением составь план ровно на один пункт, напиши тесты, потом код. Критерии успешности лежат в спецификации в разделе готовности. Пока они не закрыты, к следующему пункту не приступай.

Побочный эффект приятный: такая формулировка заодно лечит склонность к переусложнению. Когда горизонт один пункт, придумывать архитектуру на вырост негде.

ЦИКЛ ОДНОГО ПУНКТА



Где эта схема ломается

Честный разговор, без которого глава была бы рекламой.

Когда архитектура ещё не устоялась. Прибивать неопределившуюся систему тестами больно: каждое изменение решения означает переписывание тестов. Практики в такой фазе

сознательно ограничиваются интеграционными проверками на основные сценарии, а детали докручивают потом.

Когда требований не существует. Автоматизация проверки всегда упирается в проблему требований, и так было задолго до появления агентов. Если в компании никто не знает, как система должна себя вести, агент этого не выяснит.

Когда внешний мир врёт. Ни одна методология не заменяет реальный прогон против чужого интерфейса. Дефекты живут ровно там, где ни документация, ни спецификация их не описывают: значение, которое по всякой логике обязано быть постоянным, вдруг меняется, а формат ответа отличается от заявленного.

НАСКОЛЬКО СТРОГО ФОРМАЛИЗОВАТЬ

Максимально. Требования, исполняемые спецификации, тесты до кода. Дольше и дороже по токенам, но вы не получите отчёт о готовности там, где половина не проверена.

Умеренно. Интеграционные проверки на главные сценарии, остальное по мере появления проблем. Быстрее, но часть дефектов доедет до пользователя.

Что определяет выбор. Цена ошибки и зрелость архитектуры. На неустоявшемся прототипе строгая схема тормозит, на системе с живыми пользователями отсутствие схемы стоит дороже.

Требования для тестирования

Отдельный случай, который стоит упомянуть, потому что многие приходят именно за ним: можно ли поручить агенту тестирование целиком.

Можно, но при условии. Агенту нужен нормальный вход: сценарии использования, описания контрактов между частями системы, описание архитектуры. И нужны инструменты, превращающие текстовый сценарий в действие.

Схема оркестрации, которую описывали практики: на каждую предметную область свой набор агентов, впереди лёгкий классификатор, который решает, куда направить. Новое требование туда, регрессия сюда.

И то же ограничение, что и везде: без внятных требований вся конструкция не работает, потому что классификатору нечего классифицировать.

Что запомнить

Описывайте вход и выход, а не реализацию. Такое требование одновременно и задание, и тест.

Одно требование про одну вещь. Союз и это признак, что их два.

Без проверяемого критерия требование это пожелание, и агент им воспользуется.

Один пункт за раз, с запретом идти дальше до закрытия критериев. Побочно лечит переусложнение.

И помните, где схема не работает: неустоявшаяся архитектура, отсутствие требований в компании и врущий внешний мир. Последнее ловится только реальным прогоном.

Диалог, который превращается в план

Предыдущие две главы описывали, каким должен быть результат подготовки. Эта про то, как к нему прийти, потому что редко кто садится и сразу пишет хорошую спецификацию.

Работает не написание, а разговор. Но разговор устроенный, а не произвольный.

Вопросы пачками

Самый недооценённый приём во всём наборе. Формулируется в одну строку: просите у модели вопросы, а не ответы.

Схема такая. Вы описываете задачу в общих чертах. Дальше просите не решение, а список вопросов, которые нужно закрыть перед началом. Пачками примерно по пять штук: прочитали, ответили, попросили следующую пачку.

Почему пачками, а не сразу тридцать вопросов. Первые пять ответов меняют картину, и следующие пять вопросов оказываются другими. Список из тридцати, составленный до ваших ответов, наполовину промахивается.

ГОТОВЫЙ ТЕКСТ ЗАПРОСА

Не начинай реализацию. Задай мне вопросы, ответы на которые нужны, чтобы задачу можно было выполнить однозначно.

Давай по пять вопросов за раз, от самых важных к менее важным. К каждому вопросу добавь, почему без ответа на него ты можешь сделать не то.

Когда я отвечу, задай следующую пачку. Останавливайся, когда оставшиеся вопросы перестанут влиять на результат.

Приписка про почему важна. Она вынуждает модель не задавать вопросы ради вопросов, и заодно показывает вам, где вы сами не додумали.

Люди, которые пользуются этим приёмом, отмечают одно и то же: половину вопросов они бы себе не задали, и именно эта половина потом всплывала бы в переделках.

Режим планирования нужен реже, чем кажется

Многие инструменты имеют отдельный режим, где агент только планирует и ничего не делает. Практики, попробовав, в основном от него отказались.

Причина не в том, что режим плохой. В том, что достаточно попросить: сначала принеси план, потом будем делать. Модель прекрасно это понимает, а вы не теряете возможность в любой момент вмешаться и сказать делай.

ОТДЕЛЬНЫЙ РЕЖИМ ПЛАНИРОВАНИЯ

За. Гарантия, что агент ничего не тронет, пока вы не одобрили. Полезно на чужом проекте и на проде.

Против. Лишнее переключение, из которого потом надо выходить. Автоматический режим удобнее, а план всё равно можно попросить словами.

Практика большинства. Живут в автоматическом, план просят словами, отдельный режим включают только там, где действия необратимы.

Как читать длинный план

Проблема, которую замечают все: агент приносит план на две страницы, вы его пролистываете, говорите хорошо, а потом выясняется, что во втором пункте была ерунда.

Два приёма против этого.

Комментировать по кускам. Просите разбить план так, чтобы вы могли отвечать по частям, а не одним да.

Подсветка изменений. Просите приносить план не текстом, а артефактом, где жёлтым выделено то, что изменилось с прошлой итерации. Тогда на второй и третий раз вы читаете не всё заново, а только разницу.

Второй приём экономит больше всего времени на длинных согласованиях, потому что именно там внимание садится и ошибки проскакивают.

Проход по слепым зонам

Отдельный запрос, который стоит делать перед запуском.

ЗАПРОС НА СЛЕПЫЕ ЗОНЫ

Прочитай план ещё раз и найди места, где он может не сработать.

Отдельно перечисли: чего в плане нет вообще, какие предположения сделаны молча, что произойдёт при ошибке на каждом шаге, и какие места я, скорее всего, объяснил неоднозначно.


Ничего не исправляй. Только перечисли.

Запрет исправлять важен. Если модели разрешить чинить на ходу, она начнёт править формулировки и потеряет находки. Список нужен вам, а не ей.

Ревью плана до реализации

Правило, которое повторяли независимо разные практики: сначала ревью самого плана, а уже потом исполнение. Слепые зоны находятся всегда.

Лучше, если план ревюит другая модель или тот же агент в чистой сессии. Причина в том, что предвзятость создаётся контекстом, а не моделью: тот, кто только что придумал план, видит в нём стройность, потому что помнит, как его придумывал.

ПЕТЛЯ ПОДГОТОВКИ

Петля выглядит длинной, но занимает меньше времени, чем один цикл переделки. Практики, которые готовят задачи на ночной прогон, тратят на это полтора-два часа вечером и считают это нормальной ценой.

Спорить с планом полезно

Отдельное наблюдение, которое стоит знать. Модель по умолчанию соглашается. Если вы скажете, что второй пункт лишний, она согласится и уберёт, даже если пункт был нужен.

Это лечится формулировкой. Вместо вопроса не лишний ли второй пункт спрашивайте: объясни, зачем нужен второй пункт и что сломается, если его убрать. Тогда вы получите аргумент, а не согласие.

Тот же приём работает шире: спрашивайте не оценку, а обоснование. Оценку модель подстроит под ваш тон, обоснование подстроить труднее.

Когда всё это лишнее

Честно: описанная петля избыточна для мелких задач.

Если задача занимает пятнадцать минут и цена ошибки нулевая, просто скажите, что нужно. Готовить спецификацию на правку текста в интерфейсе это ритуал, а не инженерия.

Ориентир простой: если результат вы проверите глазами за минуту, готовьтесь минимально. Если проверка стоит дороже подготовки, готовьтесь всерьёз.

ГЛАВНОЕ ПРО ПОДГОТОВКУ

Время, вложенное до запуска, возвращается кратно. Полчаса согласования до работы экономят часы тяжёлого ревью после неё.

Но возвращается оно только на задачах, где проверка дорогая. На мелочах подготовка это чистая потеря, и умение отличать одно от другого приходит с опытом раньше всех остальных умений.

Что запомнить

Просите вопросы, а не ответы. Пачками по пять, с обоснованием, почему вопрос важен.

Отдельный режим планирования нужен редко: достаточно попросить план словами.

Читайте план по кускам и просите подсветку изменений между итерациями.

Отдельным запросом ищите слепые зоны, с запретом чинить на ходу.

Ревью плана до реализации, желательно в чистой сессии.

Спрашивайте обоснование, а не оценку: оценку модель подстроит под ваш тон.

И соизмеряйте подготовку с ценой проверки. На мелочах это ритуал.

Выбор модели, уровень усилий и оценка сроков

Перед каждой задачей принимаются два решения, о которых обычно не думают: какой моделью и на каком уровне усилий. Оба стоят денег, оба влияют на результат, и оба принимаются за секунды, если есть критерий.

Третья тема главы, оценка сроков, стоит рядом, потому что вопрос сколько это займёт задают ровно в тот же момент.

Модель выбирается по типу неопределённости

Формула, которая ходила в разговорах в разных вариантах, но всегда об одном.

Что вы знаете о задаче	Какая модель
Путь известен, проверка сильная, риск низкий	Самая дешёвая
Цель ясна, а как решать, надо придумать	Средняя
Непонятно даже, в чём именно задача	Старшая

Другая формулировка того же, ещё короче: если задачу можно поручить даже школьнику, берите младшую модель. Если вы понимаете, как решить, и вам просто нужна пара рук, берите среднюю. Если вам самому не ясно, что делать, берите старшую.

ГЛАВНОЕ ПРО ВЫБОР МОДЕЛИ

Вы платите не за ум, а за неопределённость. Старшая модель нужна там, где надо придумать, а не там, где надо сделать.


Отсюда самая частая ошибка новичка: он берёт лучшую модель на всё подряд и удивляется счёту. И самая частая ошибка опытного: он берёт дешёвую на задачу, где нужно придумать, а потом полдня спорит с результатом.

Уровень усилий это бюджет, а не шкала ума

Второе решение путают чаще первого. Многие считают, что более высокий уровень означает более умную модель. Это не так: модель та же, ей просто разрешают потратить больше на обдумывание.

Из этого следует, что уровень надо подбирать под размер задачи, а не под её важность.

ЧТО ПРОИСХОДИТ ПРИ НЕВЕРНОМ УРОВНЕ



Признак завышенного уровня легко заметить: если вчитаться в рассуждения, видно, что одна и та же мысль ходит по кругу. Люди, которые читают рассуждения, замечают это первыми и спускаются на ступень ниже.

Признак заниженного тоже узнаваемый: работа сделана, но по краям. Ровно то, что просили буквально, и ничего вокруг.

Отдельно стоит знать, что одинаковые настройки в разных инструментах дают разное. У одного человека субагенты запускаются только на максимальном уровне, у другого приходится специально запрещать, иначе плодятся везде. Переносить чужие настройки бессмысленно, надо подбирать у себя.

Разделение ролей между моделями

Практика, которая устоялась у людей, работающих каждый день: разные этапы отдают разным моделям.

Спецификацию пишет одна. Реализацию по готовой спецификации другая, попроще. Поиск ошибок и ревью третья.

Причины называют конкретные. Одна модель пишет честный рабочий код, но плохо справляется с проектированием агентов и написанием инструкций. Другая работает очень долго и её приходится ловить за руку, зато она глубже копает. Третья лучше всех находит корневые причины.

СТОИТ ЛИ ГОРОДИТЬ ТАКУЮ СХЕМУ

За. Экономия. Схема, где сильная модель планирует и принимает, а дешёвая исполняет, замедляет работу примерно втрое и кратно снижает расход лимитов.

Против. Сложность. Переключения, разные форматы, разное поведение. На одном проекте это терпимо, на пяти превращается в отдельную работу.

Обязательное условие для обеих позиций. Ревью самого плана. Слепые зоны есть всегда, и если план не проверен, экономия уходит в переделки.

Отдельная тонкость, которую заметили практики: сильная модель работает хорошо, когда контекст ей собрали, и плохо, когда она должна собрать его сама. Это ещё один аргумент за разделение: сборка контекста и принятие решений разные умения.

Оценка сроков

Вопрос, который задают руководители, и на который у модели нет честного ответа.

Причина фундаментальная: модели нечем измерять время. Она не устаёт, не спит и не умрёт. Всё, что она скажет о сроках, это пересказ того, как подобные задачи оценивали люди в её обучающих данных.

Отсюда две позиции.

Радикальная. Любое упоминание сроков от модели считать выдумкой и попыткой заболтать. Позиция честная, но бесполезная, если начальству нужна цифра.

Рабочая. Использовать модель как калькулятор, а точку отсчёта задавать самому.

КАК ПОЛУЧИТЬ ОЦЕНКУ, КОТОРОЙ МОЖНО ПОЛЬЗОВАТЬСЯ

1. Разбейте работу на этапы до нужной детализации.
2. Обязательно включите в разбивку хотя бы один этап, длительность которого вы знаете из опыта.
3. Попросите оценить этапы, предупредив: исполнителем будет один инженер с агентом, и в компании принят такой-то коэффициент ускорения относительно обычной разработки.
4. Посмотрите на контрольный этап. Если модель дала четыре дня там, где вы точно знаете, что три, скажите об этом и попросите пересчитать все остальные пункты с тем же коэффициентом.
5. Полученную цифру считайте оценкой порядка, а не обещанием.

Контрольный этап это вся суть приёма. Он превращает выдумку в масштабируемый коэффициент.

И напоминание, которое стоит держать в голове при любых оценках: работа заполняет время, отпущенное на неё. Если вы дадите две недели, задача займёт две недели независимо от того, сколько она требовала.

Честная картина

Как это выглядит в жизни: чаще всего вопрос звучит не сколько это займёт, а как уместить в две недели то, что заведомо не умещается. Модель тут не помощник, она помощник в другом: разложить работу так, чтобы стало видно, что именно придётся выбросить.

Это, кстати, лучший способ применения оценки. Не назвать срок, а показать состав.

Что запомнить

Модель выбирается по типу неопределённости: сделать, придумать как, понять что.

Уровень усилий это бюджет в токенах. Завышенный даёт придирки и хождение по кругу, заниженный срезанные углы.

Чужие настройки не переносятся. Проверяйте у себя, особенно поведение субагентов.

Разделение ролей между моделями окупается расходом, а не качеством, и требует ревью плана.

Модели нечем измерять время. Дайте ей контрольный этап, длительность которого знаете сами, и пересчитайте остальное по коэффициенту.

Модуль 3. Обязка

Пять глав об инструкциях, скиллах, хуках и инструментах.

Сначала о том, что писать в файл правил и как писать, чтобы правило исполнялось. Потом о скиллах: как они устроены, как стареют и во что обходятся. Потом о хуках, единственном способе гарантировать шаг. И в конце глава о том, когда всю эту конструкцию пора снести.

Последняя глава модуля важнее первых четырёх.

Файл правил

У каждого проекта, где работает агент, есть файл с правилами. Называется он в разных инструментах по-разному, суть одна: текст, который подкладывается в контекст на каждом ходу и объясняет агенту, где он находится и как себя вести.

Это первое, что заводит новичок, и первое, что портится. Через месяц там триста строк, половина из которых противоречит другой половине, а работать стало хуже, чем было.

Оглавление, а не энциклопедия

Формулировка, которая расставляет всё по местам: файл правил это оглавление, а не энциклопедия.

Пара строк про то, что это за репозиторий и как он устроен. Всё остальное место потратить на подводные камни, которые нельзя понять, посмотрев на файлы.

ГЛАВНОЕ ПРО СОДЕРЖАНИЕ ФАЙЛА ПРАВИЛ

Единственный критерий: если агент может выяснить это сам, открыв код, писать не надо.

Структура папок, названия модулей, используемые библиотеки, стиль оформления, который виден в любом файле, это всё он прочитает. А вот что здесь нельзя вызывать напрямую, потому что в проде оно ведёт себя иначе, чем в тестах, он не узнает никогда.

Проверка простая. Пройдите по своему файлу построчно и на каждой строке спросите: агент узнал бы это, открыв два-три файла? Если да, вычёркивайте.

Люди, которые проводили такую чистку, сокращали файл в пять-десять раз и не замечали ухудшения. Один из разборов звучал так: убрал десятки скиллов, выключил хуки, ужал правила до трёх десятков строк, разницы не заметил, значит это и не было нужно.

Каждую строку проверять экспериментом

Правило, которое стоит принять как дисциплину: если модель справляется без инструкции, инструкции не место нигде.

Проверяется это простым сравнением. Берёте типовую задачу, прогоняете с инструкцией и без неё, смотрите, отличается ли результат. Если не отличается, строка уходит.

Звучит нудно, и это действительно нудно. Но альтернатива хуже: файл растёт, каждая строка занимает контекст на каждом ходу, а какая из них работает, не знает никто.

Ограничение на объём

Практическая деталь, о которую спотыкаются регулярно. У подключаемых инструкций есть предел объёма, и он не всегда очевиден.

История, которую разбирали в подробностях: человек долго не мог понять, почему часть правил игнорируется, и выяснилось, что цепочка подключаемых файлов упирается в лимит,

а всё, что за ним, просто не доезжает. Никакого сообщения об этом не было.

ПРОВЕРКА, ЧТО ПРАВИЛА ВООБЩЕ ДОЕХАЛИ

1. Вставьте в конец файла правил строку с необычным словом и указанием сказать его при первом ответе.
2. Начните новую сессию и задайте любой вопрос.
3. Слова нет, значит конец файла не доехал.
4. Повторите после каждого крупного добавления. Лимит подкрадывается незаметно.

Отдельно стоит знать, что длинный файл модель читает не целиком даже в пределах лимита. Эксперименты на эту тему давали разные результаты в разные месяцы: то, что читалось полностью весной, перестало читаться летом. Это ещё один аргумент за короткий файл и за проверку у себя.

Что писать, а что нет

Писать	Не писать
Ловушки, которых не видно в коде	Структуру папок
Инварианты, которые нельзя нарушать	Список библиотек
Как запускать проверки	Стиль, видимый в любом файле
Где живут секреты и как их не трогать	Общие пожелания про качество кода
Чего в этом проекте делать нельзя и почему	То, что уже есть в описании инструментов

Последняя строка правой колонки заслуживает пояснения. Если поведение можно описать в описании инструмента, там ему и место. В файл правил оно не идёт: описание инструмента подгружается вместе с инструментом, а правила висят всегда.

Каскадные правила

Многие инструменты умеют подхватывать файл правил из папки, в которой агент сейчас работает, с более высоким приоритетом.

Приём удобный. У вас есть больное место, например работа с внешним интерфейсом, где агент постоянно ошибается. Вы кладёте правила рядом с соответствующими файлами, и они подхватываются, только когда агент туда придёт.

Честное предупреждение от практика, который это пробовал: сам не пользуюсь, потому что такое быстро превращается в кладбище неактуальных правил. Файл в глубине проекта никто не перечитывает, а он продолжает работать.

КАСКАДНЫЕ ПРАВИЛА

За. Контекст не забивается тем, что нужно в одном месте из двадцати. Правило появляется ровно там, где применимо.

Против. Правила разъезжаются. Через полгода в трёх папках лежат три противоречащих версии одного требования, и найти их можно только поиском.

Компромисс. Заводите каскадные правила только для мест, которые действительно изолированы, и записывайте их существование в центральный файл. Одна строка вида в папке такой-то лежат отдельные правила.

Что и как: разделение с проектными скиллами

Полезное разграничение, к которому пришли независимо несколько человек.

Файл правил отвечает на вопрос что: что это за система, что нельзя нарушать, что проверяем.

Проектный скилл отвечает на вопрос как: как выполняется конкретная процедура, к которой обращаются не всегда.


Разделение помогает решить, куда положить очередной кусок текста. Если это нужно всегда, идёт в правила. Если применимо в конкретной ситуации, идёт в скилл, и там же описывается, как эту ситуацию распознать.

Память вместо правил

Ещё одна линия, которую стоит знать. Часть того, что раньше писали в правила, современные инструменты умеют запоминать сами: вы говорите запомни это, и оно оседает в автоматической памяти.

Приём удобный, но у него есть предел. Память объёмом больше пятнадцати-двадцати тысяч символов начинает деградировать: агент помнит всё хуже, а обновление факта требует переписывания большого куска.

Практический вывод: память для того, что меняется, правила для того, что стабильно. И регулярная уборка нужна обоим.

Живой пример структуры**СТРУКТУРА КОРОТКОГО ФАЙЛА ПРАВИЛ**

Четыре блока, каждый на своём месте, ничего лишнего. Если ваш файл не укладывается в эту схему, скорее всего часть его содержимого просто не нужна.

Что запомнить

Оглавление, а не энциклопедия. Единственный критерий: если агент выяснит сам, писать не надо.

Каждую строку проверяйте экспериментом: с ней и без неё.

У подключаемых инструкций есть лимит, и о его превышении вам не сообщат. Проверяйте контрольным словом.

Что нужно всегда, идёт в правила. Что нужно иногда, идёт в скилл с описанием ситуации.

Каскадные правила по папкам работают и превращаются в кладбище. Заводите с оглядкой и упоминайте в центральном файле.

Правила, которые работают

Прошлая глава была о том, что писать в правила. Эта о том, как писать, чтобы правило исполнялось. Разница видна на одном примере, который знаком каждому, кто доверял агенту работу с текстом.

Вы даёте агенту подробное задание. Расписываете всё: логика идёт через инструменты, углы не срезаем, агентный цикл честный. Агент отвечает, что готово. Открываете код, а там регулярные выражения.

Это случается не из-за кривого запроса. Так ведут себя все кодовые агенты, на любых проектах, во все месяцы. Привычка держится крепче остальных, и на ней хорошо видно, чем рабочее правило отличается от нерабочего.

ЧТО ТАКОЕ ЭВРИСТИКА И ПОЧЕМУ ЭТО СЛОВО ЗВУЧИТ КАК ДИАГНОЗ


Эвристика: упрощённое правило, которое обычно даёт верный ответ и не требует думать. Скажем, если в сообщении встретилось слово "пожар", считаем, что случилась авария. Регулярное выражение, оно же регексп, позволяет такое правило записать: это шаблон для поиска подстрок в тексте.

Инструмент нормальный, половина полезного кода в мире так и работает. Ломается всё там, где задача требует понимания смысла. Именно туда агент лезет первым делом, потому среди практиков слово "эвристики" давно звучит как диагноз.

Развилка, на которой всё решается

Получив задачу, агент выбирает между двумя маршрутами. Первый дешёвый и быстрый. Второй правильный.

ЧТО ПРОИСХОДИТ, КОГДА АГЕНТ ПОЛУЧАЕТ ЗАДАЧУ ПРО СМЫСЛ



Проблема в том, что развилку агент проходит молча. Вы узнаете о его выборе, когда откроете код, а к тому моменту решение уже расплзлось по проекту.

Как это выглядит на живом проекте

Лучше всего историю объясняет система, которая читает домовые чаты и вылавливает сообщения об авариях. Задача целиком про смысл: жилец пишет как умеет, и понять, случилась беда или нет, можно только вникнув в текст.

ПОЖАР В СЕРДЦЕ

Агент упирался до последнего. Ждать ответа модели незачем, доказывал он, ведь слова "пожар", "затопило", "искрит" ловятся прямым сравнением строк: быстро, дешево, без лишних запросов.

Спор кончился, когда разработчик придумал контрпример. Человек вполне может написать, что у него пожар в сердце и он затопил свои трусики. Два слова из списка совпали, аварии не случилось. После этого агент согласился и сам вписал в правила проекта запрет на такие решения.

Пример стоит запомнить: он показывает, чем именно ломается подход. Список слов промахивается не случайно, он промахивается систематически. На образном, на ироничном, на сказанном вскользь. А живой язык в пользовательских чатах ровно такой.

История не одна. В другом проекте, системе учёта заявок от жителей, повторилось то же самое: агент раз за разом возвращался к ловле по ключевым словам вместо оценки моделью, пока разработчик не запретил это прямым правилом. Два независимых проекта, два месяца между ними, одна болезнь. Совпадением такое уже не назовёшь.

Откуда это берётся

Объяснение простое. Агент воспроизводит то, чего в его обучающих данных было больше всего, а в открытом коде больше всего именно быстрых решений на совпадении строк. Модель не вредничает. Она идёт по самому вероятному пути.

Дальше включается механизм, который дороже всего обходится на практике: **один пропущенный регексп в начале задаёт тон всей задаче**. Агент видит собственный предыдущий код и продолжает в том же духе. К концу работы упрощения расходятся по проекту как трещины по стеклу.

ГЛАВНОЕ ПРО ЭТУ ПРИВЫЧКУ

Агент не саботирует задание, он идёт по самому вероятному маршруту из своего опыта. В мире открытого кода этот маршрут ведёт к сравнению строк. Значит, воевать надо не с отдельным регекспом в отдельном файле, а с самим маршрутом: перекрывать его в начале задачи и держать перекрытым до конца.

Есть формулировка порезче. Она уже не про данные, а про поведение модели под давлением задачи. Модель уверенно докладывает, что сделала как просили, а сама выбирает обходной путь. Задачу закрыть хочется, прямой дороги она не видит, вот и находит любую другую.

Четыре приёма, которые работают

За полгода практики набралось четыре рабочих способа. Заменить один другим не получится, они закрывают разные дыры.

Приём	Когда применять	Что ловит
Запрет с причиной	При настройке правил проекта	Обход ограничения по формальному признаку
Контроль в трёх точках	На входе, в процессе, на выходе	Упрощения, пока они дешёвы в правке
Пересказ своими словами	После крупного куска работы	Расхождение кода с замыслом
Цикл самопроверки	Постоянно, автоматически	Всё, что пропустили первые три

Запрет с причиной

Приём неочевидный, зато самый сильный. Идея пришла из производственной методологии Toyota TWI, где мастер обучает прямо на рабочем месте и объясняет не только порядок действий, но и причину.

Голый запрет модель воспринимает как формальность и при первом удобном случае обходит его по такой же формальности. Запрет с причиной ложится в рассуждение целиком.

ЗАПРЕТ БЕЗ ПРИЧИНЫ

запрещено округлять до целых

Модель видит ограничение, ищет лазейку и находит её в первом же неоднозначном месте.

ЗАПРЕТ С ПРИЧИНОЙ

запрещено округлять до целых, потому что на разнице мы в прошлый раз потеряли 12 000 USD в коммерческом предложении

Причина попадает в рассуждение, и модель учитывает её даже там, где формально запрет не нарушен.

Тот же эффект замечают на соседнем требовании: сначала запускать красные тесты, потом писать код. Модель упирается в непройденный тест и только после этого решает, что писать. Появляется опора, которую не обойдёшь рассуждением.

Контроль в трёх точках

Проверка в конце опаздывает. К финалу упрощения уже выросли в код, и вычищать их дороже, чем написать заново.

Точка	Что смотреть	Цена пропуска
На входе	Как агент понял постановку и что предлагает делать	Минуты на переформулировку
В процессе	Чем он занят на самом деле, а не что докладывает	Часы на переделку куска

Точка	Что смотреть	Цена пропуска
На выходе	Совпадает ли результат с замыслом	Дни на разбор проекта

Первая точка самая дешёвая и самая недооценённая. Агент выдаёт свои намерения уже в первом ответе на постановку, надо просто прочитать.

Пересказ своими словами


Приём против главной ловушки вайб-кодинга: код вы не читаете, а значит и не знаете, что там. Вместо чтения попросите агента объяснить обычными словами, что он сделал. Откуда берутся данные, куда записываются, на основании чего принимаются решения.

Подделать пересказ нельзя. Если под капотом список ключевых слов, это вылезет в первом же предложении, потому что описывать придётся именно список ключевых слов. Прочитали, сверили с замыслом, разошлось: правьте сразу. Отложенная правка обходится в разы дороже.

Цикл самопроверки

Разовое "проверь себя" слабее, чем требование крутиться до чистого результата.

КАК ВЫГЛЯДИТ РАБОЧИЙ ЦИКЛ



Разница между "проверь" и "проверяй, пока не станет чисто" на практике решает исход.

Где это не работает

У подхода есть граница, и знать её лучше заранее.

ЗАПРЕТ ПОМОГАЕТ НЕ ВСЕГДА

Позиция первая. Запрещать надо жёстко и сразу: эвристики, тихие подмены при ошибках, поддержку устаревших веток. Дальше строить агенту узкий коридор из правил, готовых сценариев, линтеров и автопроверок. Чем уже коридор, тем предсказуемее результат. Иначе придётся вечно читать код глазами, а это возвращает нас туда, откуда уходили.

Позиция вторая. Работает такой запрет только на подготовленной почве, когда разработка идёт по рельсам и модели есть куда свернуть. На открытой задаче агент, которому запретили эвристики, но не показали правильного пути, всё равно не остановится. Закрыть задачу хочется, и он выкрутится. Чем строже запрет, тем изобретательнее обход.

Вывод из спора. Запрет закрывает половину работы. Вторую половину закрывает готовый способ сделать правильно: инструмент, образец, пример решения. Без него ограничение родит не качество, а изворотливость.

Полезно помнить и встречное соображение, которое звучит как шутка, но по сути верно: языковая модель тоже эвристика, просто заметно сложнее. Граница проходит между решением, которое умеет работать со смыслом, и решением, которое умеет только сравнивать буквы. Агент ошибается не тем, что применил простое правило. Он ошибается тем, что применил его к задаче, где смысл важнее формы.

ЧТО ДЕЛАТЬ НА СВОЁМ ПРОЕКТЕ

1. Впишите в правила проекта запрет на решения по совпадению строк там, где задача про смысл. Обязательно с причиной, желательно с ценой ошибки в деньгах или времени.
2. Читайте первый ответ агента на постановку. Он там сразу выдаёт, куда собирается свернуть, а править на этом этапе дешевле всего.
3. После каждого крупного куска просите пересказ обычными словами. Быстрее чтения кода и надёжнее.
4. Разошлось с замыслом, правьте сразу. По накатанной агент дотащит упрощение до конца проекта.
5. Замените разовую ревизию циклом самопроверки по стандартам, с требованием повторять до чистого результата.

Скиллы: механика и жизненный цикл


Скилл это отдельный файл с инструкцией, которую агент подгружает, когда сочтёт нужным. Сущность появилась недавно, за полгода вокруг неё выросла целая культура, и почти сразу выросли проблемы, о которых стоит знать заранее.

Как это устроено на самом деле

Механика простая, и её понимание сразу снимает половину вопросов.

В контексте агента постоянно висят только заголовки и описания всех доступных скиллов. Не тела, только описания, обычно одна-две строки каждое. Когда приходит задача, модель смотрит на этот список и решает, стоит ли подгрузить какой-то скилл целиком.

ЧТО ПРОИСХОДИТ СО СКИЛЛОМ



Из этой механики следуют все остальные свойства.

Скиллы платные даже когда не используются. Заголовки висят всегда, и сотня скиллов это сотня строк на каждом ходу.

Описание работает, а тело нет. Если описание сформулировано неудачно, тело не будет загружено никогда, и качество инструкции внутри не имеет значения.

Модель решает сама. Вы не управляете загрузкой напрямую, вы влияете на неё только текстом описания.

Описание решает всё

Самая практичная часть главы.

Хорошее описание делает две вещи: перечисляет ситуации, в которых скилл применим, и явно называет ситуации, в которых он не нужен. Второе важнее первого, потому что именно оно спасает от ложных срабатываний.

ОПИСАНИЕ, КОТОРОЕ НЕ РАБОТАЕТ

Помогает проектировать агентов

Слишком общо: модель не понимает, когда именно это про неё, и либо не загрузит никогда, либо будет грузить постоянно.

ОПИСАНИЕ, КОТОРОЕ РАБОТАЕТ

Использовать при проектировании, реализации, ревью, отладке или оценке агента: инженерия контекста, интерфейсы инструментов, надёжность обвязки, память, оценка, координация нескольких агентов. Не использовать для обычного неагентного кода приложения.

Перечислены ситуации и явно отсечены неподходящие. Загружается тогда, когда нужно, и молчит в остальное время.

Практики, у которых скиллы срабатывают стабильно, описывают это так: не люблю вызывать скиллы руками, подбешивает, когда скилл сам не вызывается. Стабильный автовызов это признак хорошего описания, а не удачи.

Скилл со скриптом или без

Спор, в котором обе стороны правы, и стоит понимать обе.

Позиция первая: скилл без скрипта бесполезен. Аргумент конкретный. Промпты живые, от проекта к проекту улучшаются. Если бы они лежали в скиллах, пришлось бы каждый раз обновлять и синхронизировать между всеми машинами. Проще держать текст там, где его удобно править, а в скилл класть то, что не планирует меняться, либо меняется централизованно.

Позиция вторая: скилл это методичка. А со скриптом она или без, дело второе. Интерактивность хороша, но не везде реальна и не везде нужна. Смысл скилла в том, чтобы не повторять одно и то же десять раз с минимальными вариациями, а обратиться по названию.

КАК РЕШИТЬ У СЕБЯ

Кладите в скилл то, что стабильно. Процедура, которая не меняется от проекта к проекту, знание о внутренней системе, порядок действий с чужим интерфейсом.

Не кладите то, что вы дорабатываете каждую неделю. Это будет расходиться между машинами, и вы устанете синхронизировать.

Отдельный случай, где скилл незаменим. Знания, которых нет ни в репозитории, ни в обучающих данных: внутренние соглашения компании, вендорский функционал, не описанный в коде. Иначе агент их не узнает никогда.

Пять типовых форм

Скиллы, которые встречаются в живых проектах, укладываются в несколько форм.

Форма	Что внутри	Когда нужна
Процедура	Пошаговый порядок действий	Повторяющаяся операция со стабильным ходом

Форма	Что внутри	Когда нужна
Справочник	Знание о системе или интерфейсе	Того, чего нет в коде и в обучающих данных
Обёртка над утилитой	Как вызывать инструмент и что делать с ответом	Внешние интерфейсы, где сборка запросов на лету даёт выдумки
Роль	Взгляд, с которым надо посмотреть на задачу	Ревью, критика, оценка с определённой позиции
Мета-скилл	Как делать другие скиллы или проверять их	Когда скиллов стало много

Последняя форма появляется поздно и означает, что пора наводить порядок.

Гигиена: три правила

Держите только инфраструктурные. Заголовки висят в контексте постоянно, поэтому каждый лишний скилл это налог на каждый ход. Практики, наводившие порядок, оставляли те, что описывают работу с системами, и убирали те, что описывают пожелания к стилю.

Считайте срок годности неделями. Формулировка резкая, но подтверждённая: скилл, собранный генератором скиллов, ломается через пару недель. Меняются инструменты, меняется поведение модели, меняется проект.

Ревьюйте как код. Даже аккуратный скилл после правок агентом требует проверки. Люди, выкладывавшие свои скиллы, регулярно получали замечания вида хороший скилл, чистый, но агенты в него насрали.

Версии и устаревание

Проблема, у которой в экосистеме нет общего решения: как человек узнаёт, что вышла новая версия скилла. Честный ответ, который дали авторы популярных скиллов: никак, только через ленту изменений.

Два обхода, придуманные практиками.

Предполётная проверка внутри скилла. Раз в сессию агент сверяет файл скилла с источником и, если версии разошлись, одной строкой сообщает, что вышло обновление и как обновиться. Если не разошлись, молчит.

Проверка на уровне хранилища. В корпоративном варианте лучше не зашивать проверку в каждый скилл, а повесить её на инфраструктуру: когда человек ставит, заливает или ищет очередной скилл, запускается проход по всем установленным.

ПРИЗНАКИ, ЧТО СКИЛЛ ПОРА УДАЛИТЬ

1. Вы не помните, что он делает, и в описании этого тоже не понять.
2. За месяц он ни разу не загрузился сам, а вы про него ни разу не вспомнили.
3. Он дублирует то, что модель делает и без него. Проверяется отключением.
4. Он лезет в задачи, к которым не относится. Описание слишком широкое.
5. Внутри он описывает интерфейс, который с тех пор поменялся.

Экономика скилла

Отрезвляющий пример, который стоит помнить перед тем, как автоматизировать очередную мелочь.

Человек хотел подписать один документ. Через готовый онлайн-редактор это заняло бы полминуты. Он попросил агента собрать скилл для этой операции, потратил на сборку и настройку около четверти часа, а по счётчику вышло больше пяти долларов за один заход. Дальнейшие подписания стали дешёвыми, но окупаемость надо было считать до, а не после.

ГЛАВНОЕ ПРО СКИЛЛЫ

Скилл окупается только на повторяющемся. Считайте окупаемость до создания: сколько раз в месяц это происходит и сколько стоит один ручной проход.

И помните, что стоимость скилла не заканчивается его сборкой. Он занимает место в контексте, устаревает, требует ревью и однажды начинает мешать. Скилл это не разовое вложение, а подписка.

Когда любимый скилл начинает мешать

Наблюдение, которое звучит комично, но описывает реальную проблему: иногда любимый скилл начинает лезть туда, где не нужен.

Причина всегда одна: слишком широкое описание. Лечится дописыванием строки о том, где скилл не применяется.

Отдельно стоит знать, что скилл, который пытается бороться со склонностью модели, добавляя новую яркую инструкцию, обычно усиливает перекося вместо того, чтобы его убрать. Работают не уговоры, а детерминированная проверка с ответом да или нет.

Что запомнить

В контексте висят только описания. Тело загружается по решению модели.

Описание важнее содержимого: перечислите ситуации и явно отсекайте неподходящие.

В скилл кладите стабильное. Живой текст держите там, где удобно править.

Настоящая ниша скилла это знания, которых нет ни в коде, ни в обучающих данных.

Срок годности измеряется неделями. Ревьюйте как код и удаляйте без сожаления.

И считайте окупаемость до сборки: скилл это подписка, а не разовая покупка.

Хуки и детерминированные гарантии

Правило можно проигнорировать. Скилл можно не загрузить. Есть ровно один способ гарантировать, что шаг произойдёт: сделать так, чтобы его выполняла не модель.

Это и есть хук.

ЧТО ТАКОЕ ХУК

Хук это ваш код, который система запускает сама в определённый момент. Не по решению модели, а по событию.

Событий обычно несколько: перед вызовом инструмента, после вызова, при старте сессии, при завершении задачи, перед сжатием контекста. Вы вешаете на событие маленькую программу, и она выполняется всегда.

Слово взято из обычного программирования, где так называют любую точку, куда можно вклиниться со своим кодом.

Три причины, по которым хуки выигрывают

Он выполняется всегда. Это главное. Правило это текст, который влияет на вероятности. Хук это код, который просто работает.

Он бесплатен. Хук не занимает место в контексте. Правило занимает на каждом ходу.

Он видит то, чего модель не видит. Хук может посмотреть на состояние системы, а не на пересказ состояния.

Цифра, которая лучше всего продаёт идею, взята из практики восстановления состояния после сжатия контекста. Инструкция вида после сжатия перечитай такие-то документы срабатывала почти никогда. Тот же шаг, повешенный хуком, срабатывает примерно в восьми случаях из десяти.

ГЛАВНОЕ ПРО ХУКИ

Хуки нужны там, где есть процесс. Если процесса нет, они не нужны.

Это не отговорка, а критерий. Если вы не можете назвать событие, после которого должен произойти шаг, вам нужен не хук, а более внятная постановка задачи.

Что на них вешают

Список реальных применений, собранный из практики.

Событие	Что делает хук	Что закрывает
Перед вызовом инструмента	Запрещает поиск по тексту там, где есть индекс	Забычивость модели

Событие	Что делает хук	Что закрывает
Перед вызовом инструмента	Блокирует чтение файлов с секретами	Обход правила
Старт сессии	Обновляет индексы, подтягивает контекст проекта	Работу по устаревшим данным
После сжатия	Восстанавливает состояние и перечитывает ключевое	Переделывание сделанного
Отправка изменений	Гоняет проверку на опасные паттерны	Упрощения, вросшие в код
Завершение задачи	Пишет отчёт, шлёт уведомление	Незаметный отказ

Механика ошибки важна: скрипт не просто запрещает, он возвращает текст ошибки прямо в сессию. Модель видит ошибку, понимает причину и меняет поведение. Это гораздо эффективнее, чем молчаливый отказ.

Хук как замена сложной инструкции

Отдельный случай, который стоит выделить. Инструкции вида после X сделай Y работают, пока цепочка линейная и короткая. Как только это становится графом, инструкция превращается в простыню, которую модель применяет через раз.

Хук здесь выигрывает вдвойне: он не занимает контекст и не зависит от того, вспомнила модель про правило или нет. Особенно хорошо это работает, когда X это внутреннее событие системы, о котором модель вообще не знает.


Дополнительные ветвления как повод для хука

Классическая болезнь агентского кода: защитные проверки на всякий случай.

Арифметика неприятная. Каждое лишнее ветвление удваивает число путей через код. Три ветвления это восемь комбинаций, четыре шестнадцать, пять тридцать две. И каждую надо протестировать, а агенты любят прятать ошибки именно в дополнительных ветках.

Ответ, к которому пришли практики: проверка на коммит, которая ищет опасные паттерны. Не просьба не делать так, а автоматический проход, который не пропускает.

КАК ЗАКРЫВАТЬ ПОВТОРЯЮЩУЮСЯ ОШИБКУ



Когда хуки не нужны

Честная противоположная позиция, которую высказывали практики.

Современные модели держат правила заметно лучше, чем год назад. Люди, которые раньше вешали хуки на перечитывание документов после сжатия, сейчас обходятся без них, потому что проблема перестала быть массовой.

И вторая мысль, более общая: если у вас нет процесса, хуки будут ритуалом. Вы навесите проверки на события, которые ничего не значат, и получите замедление без выигрыша.

СКОЛЬКО АВТОМАТИКИ НУЖНО

Минималист. Модели умные, обвязка устаревает быстрее, чем достраивается. Проверяйте раз в квартал, что без ваших хуков стало хуже.

Перестраховщик. Хуки бесплатны по контексту, а цена пропущенного шага в проде несопоставима. Ставьте на всё, что критично.

Разделяющий критерий. Обратимость. Если шаг можно откатить за минуту, живите без хука. Если нельзя, ставьте.

Память вместо хука не работает

Соблазн понятный: вместо кода просто сказать агенту запомни, что после такого-то шага надо делать то-то.

Ограничение, о котором стоит знать заранее: память объёмом больше пятнадцати-двадцати тысяч символов начинает деградировать. Агент помнит хуже, а обновление одного факта требует переписывания большого куска текста.

Память для того, что меняется и что человек говорит своими словами. Хуки для того, что должно выполняться независимо от того, вспомнил кто-то или нет.

Правило, скилл или хук

Сводка, которой удобно пользоваться при каждом новом требовании.

Если это	Кладите в
Нужно знать всегда	Правила
Нужно знать в конкретной ситуации	Скилл с описанием ситуации
Должно выполняться обязательно	Хук
Меняется от разговора к разговору	Память
Требует надёжного формата	Код обвязки, а не текст

ВАШ ПЕРВЫЙ ХУК ЗА ПЯТНАДЦАТЬ МИНУТ

1. Вспомните ошибку, которую агент повторил больше трёх раз.
2. Назовите событие, после которого её видно: вызов инструмента, коммит, конец задачи.
3. Напишите проверку, которая отвечает да или нет. Никаких оценок по шкале.
4. Верните текст ошибки в сессию, с объяснением причины, а не просто отказ.
5. Уберите из правил строку, которая пыталась это закрыть словами.

Пятый шаг обязателен. Иначе вы получите и хук, и мёртвую строку в правилах, которая продолжает занимать контекст.

Что запомнить

Хук отличается от правила ровно одним: он выполняется всегда. И он не занимает контекст.

Хуки нужны там, где есть процесс. Событие должно называться словами.

Ошибку возвращайте в сессию с объяснением, а не молча.

Восстановление после сжатия хуком работает в восьми случаях из десяти, инструкцией почти никогда.

Разделяющий критерий между хуком и правилом это обратимость шага.

И после установки хука вычищайте строку из правил, которая пыталась сделать то же самое словами.

Инструменты и когда обязанка вредит

Три предыдущие главы учили строить. Эта учит сносить, и она едва ли не важнее.

Инструмент это контракт

Сначала короткая часть про инструменты, потому что она примыкает по смыслу.

Инструмент, отданный агенту, описывается не функцией, а контрактом. В контракте шесть пунктов, и каждый из них однажды выстрелит, если его не назвать.

Пункт	Вопрос, на который отвечает
Схема входа	Что можно передать и в каком виде
Предусловия	Когда вызывать нельзя
Побочные эффекты	Что изменится в мире
Таймаут	Сколько ждать и что считать отказом
Идемпотентность	Что будет при повторном вызове
Права	Кому и в каком режиме доступен

Отдельно про интерфейс. Если хочется добавить в инструкцию пример использования инструмента, часто правильнее изменить сам инструмент.

Причина в том, что примеры сужают пространство решений: модель начинает воспроизводить показанный сценарий вместо того, чтобы придумать свой. Вместо примера лучше сделать параметр выразительнее: не свободная строка, а список допустимых значений.

ГЛАВНОЕ ПРО ИНСТРУМЕНТЫ

Внешние интерфейсы оборачивайте утилитами. Сборка запросов на лету даёт устойчивый фон выдумок и плохо тестируется.

Разбор реального продакшн-агента показал ровно это: пока агент собирал обращения к пяти внешним сервисам сам, был постоянный фон галлюцинаций. Когда каждое обращение завернуло в утилиту с внятным интерфейсом, проблема исчезла, а тестирование упростилось.

Главный вред обязанности это не объём


Теперь про снос.

Существует убеждение, что чем больше инструкций, тем предсказуемее агент. Разбор, который сделали у одного из поставщиков на собственном продукте, показал обратное.

Они убрали больше восьмидесяти процентов системных инструкций и не получили измеримой просадки на задачах программирования. А корень проблемы нашли в своих же записях работы агента: в одном запросе жили противоречащие друг другу указания. Системная инструкция требует не писать комментарии, скилл говорит держать документацию там, где

уместно, пользователь хочет третье.

ЧТО ДЕЛАЕТ МОДЕЛЬ С ПРОТИВОРЕЧИЕМ



Отсюда шесть переходов, которые стоит держать в голове при каждом добавлении в обязанку.

Правила в суждение. Вместо списка запретов дайте критерий, по которому модель решает сама. Например: пиши код, который читается как окружающий, повторяй его плотность комментариев, именование и идиомы.

Примеры в интерфейсе. Пример сужает поиск. Выразительный параметр не сужает.

Всё сразу в постепенное раскрытие. Ревью и верификация выносятся в скиллы по требованию. Файл правил становится деревом файлов, а не единой свалкой.

Повторы в описания инструментов. Если поведение можно описать там, в правила оно не идёт.

Память в правилах в автоматическую память. Разное живёт по-разному.

Простые спецификации в богатые референсы. Спецификацией может быть набор тестов, функция из другого проекта, макет интерфейса. Рубрика оценки тоже референс.

Раз в квартал сносит всё

Приём, который повторили независимо несколько человек, включая тех, кто делает эти инструменты.

Раз в несколько месяцев отключайте всё: скиллы, файл правил, хуки. Работайте так какое-то время. Возвращайте по одной строке, и только те, на которых агент спотыкается повторно.

Люди, которые это делали, описывают результат одинаково: убрал десятки скиллов, выключил хуки, ужал правила в несколько раз, разницы не заметил.

РЕВИЗИЯ ОБЯЗКИ

1. Сложите всё, что накопили, в отдельную папку и отключите.
2. Работайте неделю. Записывайте каждый случай, когда пришлось объяснять руками.
3. Верните только то, что встретилось два раза и больше.
4. Возвращая, спросите себя, где этому место: правило, скилл, хук или описание инструмента.
5. Повторяйте раз в квартал. Это не разовая уборка.

Постоянно живут только проверки. Инструкции стареют быстрее эвалов, и это нормально: инструкция описывает поведение конкретной модели в конкретный месяц.

Контраргумент, который нельзя игнорировать

Честность требует привести и обратную позицию, которая звучала не раз.

Обязка даёт неспециалисту иллюзию корректности. Человек, который не может оценить результат сам, видит зелёные проверки, аккуратные отчёты и уверенный тон и делает вывод, что всё хорошо. А обязанка проверяла то, что легко проверить, а не то, что важно.

Эта мысль стыкуется с более общей: модели обучены на корректности, которую можно проверить за секунды. Тест прошёл проверяется мгновенно, фича работает за минуты, регрессия не всплыла за дни, а вот выдержала ли архитектура изменение требований, выясняется через месяцы. Обучающего сигнала на нижних строках этой таблицы нет ни у модели, ни у вашей обязанности.

Что проверяем	За сколько видно
Тест прошёл	Секунды
Функция работает	Минуты
Регрессия не всплыла	Дни
Архитектура выдержала изменение требований	Месяцы
Систему всё ещё можно развивать	Годы

ОБЯЗКА ЭТО АКТИВ ИЛИ ОБЯЗАТЕЛЬСТВО

Актив. Она накапливает опыт команды и не даёт наступать на те же грабли. Без неё каждый новый человек проходит тот же путь заново.

Обязательство. У неё есть стоимость сопровождения и срок годности. Она устаревает быстрее, чем достраивается, и однажды начинает мешать больше, чем помогать.

Как жить с обоими. Считайте обязанку обязательством и пересматривайте по расписанию. Тогда всё, что переживёт пересмотр, действительно окажется активом.

Противоположная крайность

Чтобы картина была полной, стоит знать и радикальный ответ, который тоже работает у практиков.

Формулировка, положенная прямо в файл правил, звучала примерно так. Работаем короткими итерациями прямо в целевой ветке. Пул-реквесты, автоматические проверки и прочая процессная возня не нужны, система контроля версий нужна для разницы, истории и восстановления. Сначала воспроизвели ошибку, потом починили, потом проверили локально. В тесты сажаем шум: плохую сборку, глупые действия пользователя, мусор. Команда это я и ты, работаем на скорость без ущерба эффективности.

Автор объясняет так: модели уже достаточно умные, и боевой тест лучше, чем закладывать вату со всех сторон. После этой инструкции стало быстрее и лучше.

Это не совет всем. Это напоминание, что тяжёлый процесс не единственный ответ, и что выбор между ними определяется ценой ошибки, а не модой.

Что запомнить

Инструмент это контракт из шести пунктов. Неназванный пункт однажды выстрелит.

Внешние интерфейсы заворачивайте в утилиты: сборка запросов на лету даёт выдумки.

Главный вред обвязки не объём, а противоречия. Модель тратит рассуждение на их разрешение вместо задачи.

Давайте критерий вместо списка запретов. Критерий переносится на новые ситуации.

Раз в квартал отключайте всё и возвращайте только то, на чём спотыкаетесь повторно.

Постоянно живут только проверки. Инструкции стареют.

И держите в голове, что обвязка проверяет то, что легко проверить. Долгую сопровождаемость она не измеряет вообще.

Модуль 4. Контекст и память

Четыре главы о главном ресурсе.

Контекст это то, за что вы платите и чем определяется качество ответа. Здесь: как он устроен и сколько стоит, что происходит при сжатии и что должно его пережить, чем отличаются три подхода к памяти и как устроен поиск по коду и по документам.

Модуль технический, но без него счета остаются загадкой.

Контекст как единственный ресурс

Если из всей книги надо запомнить одну вещь, то вот она: контекст это то, за что вы платите, и то, чем определяется качество ответа. Не модель, не инструменты, не длина инструкций. Контекст.

Что это такое

Контекст это весь текст, который уходит модели на каждом круге. Правила проекта, описания доступных инструментов, история разговора, результаты вызовов, ваша последняя фраза.

Два свойства делают его центральной темой.

Он оплачивается целиком каждый раз. Не прирост, а весь накопленный объём. Поэтому пятидесятый ход разговора стоит в разы дороже первого, даже если вы написали одно слово.

Он ограничен, и работает неравномерно. Есть предел, за который не влезет. И внутри предела внимание распределяется неровно: начало и конец модель использует лучше, чем середину.

ПОЧЕМУ РАЗГОВОР ДОРОЖАЕТ

Модель ничего не помнит. Чтобы она знала, о чём вы говорили десять минут назад, ей это надо пересказать заново.

Обвязка так и делает: собирает всю переписку и отправляет целиком. На пятидесятом ходу отправляется всё, что накопилось за пятьдесят ходов.

Отсюда простое следствие: длинный разговор это не немного дороже короткого, а значительно дороже. И отсюда же вся дальнейшая инженерия.

Шаблон сборки

Контекст собирает не модель, а обвязка. Полезно представлять, из чего он складывается, в порядке попадания в запрос.

Блок	Что в нём	Меняется
Системные инструкции	Кто агент и как себя ведёт	Редко
Описания скиллов	Заголовки всех доступных	При добавлении скилла
Схемы инструментов	Что можно вызвать и как	При изменении набора
Правила проекта	Инварианты и ловушки	Редко
Цель	Что делаем сейчас	На каждой задаче
История	Предыдущие ходы	Постоянно

Блок	Что в нём	Меняется
Отчёты субагентов	Что они вернули	При делегировании
План и статус	Что сделано, что осталось	Постоянно
Текущий ход	Ваша фраза и последние результаты	Каждый ход

Тот, кто собирает этот текст, и называется контекстным движком. Важное уточнение, которое прозвучало в спорах: память и поиск по документам это источники, а не движок. Движок это то, что решает, что из источников попадёт внутрь и в каком порядке.

Сборщик или движок

Спор, который стоит знать, потому что за словом движок продают разное.

Одна позиция: движок это просто заполнение шаблона, и называть это движком слишком громко.

Вторая: в серьёзной сборке нет никакого шаблона, там компиляция журнала событий и множества источников на лету, при каждом изменении. Простой подстановкой не обойтись, если делать хорошо.

ЗА ЧТО ВЫ ПЛАТИТЕ, ПОКУПАЯ КОНТЕКСТНЫЙ ДВИЖОК

Скептик. Часто под этим продают обёртку над индексом кода, чтобы одно и то же не переизобреталось. Тот же результат даёт субагент, делающий несколько поисков, только там дороже.

Практик. Ценность в другом: модель получает готовый нужный кусок и не тратит ходы на его поиск. На больших базах это разница между работой и мучением.

Экономический аргумент против. Фронтир-модели на таких инструментах никто не дообучает, поэтому выигрыш в основном в токенах. Если расход не ограничен, окупается хуже.

Экономический аргумент за. В компаниях расход как раз ограничен, и там контроль токенов становится отдельной темой.

Практичный компромисс, который называли: для навигации по коду достаточно небольшой локальной модели, можно каскадом. Тратить фронтир-модель на хождение по файлам это самая дорогая часть счёта.

Отдать целиком или собирать вызовами

Вопрос, который встаёт на каждом проекте.

Аргумент за целиком: небольшой проект дешевле положить в контекст сразу, чем заставлять агента собирать его десятком вызовов. Он сразу увидит связи, а вы не заплатите за поиск.

Аргументы против, все существенные:

Так модель выделяет меньше вычислительного бюджета на осмысление каждой части.

После определённого объёма идёт размытие и заметное снижение качества, причём по ощущениям практиков снижение начинается гораздо раньше формального предела.

В проекте, который живёт дольше одного захода, в документы неизбежно набивается мусор даже при хорошем контроле.

ГЛАВНОЕ ПРО ОБЪЁМ

Если материалы не противоречат друг другу, лучше дать чуть больше, чем чуть меньше: дочитывать и переделывать дороже.

Если материалы противоречат, лишнее вреднее нехватки. Модель потратит рассуждение на разрешение конфликта.

Поэтому чистка контекста это в первую очередь устранение противоречий, и только во вторую сокращение объёма.

Кеш: экономика, которая решает больше выбора модели

Техническая деталь, которая на счетах видна сильнее всего.

Поставщики кешируют начало запроса. Если следующий запрос начинается точно так же, эта часть считается дешевле. Отсюда практическое правило: стабильное держите в начале, изменчивое в конце.

Нарушение этого правила стоит дорого. Если вы вставляете в начало текущее время, случайный идентификатор или что-то меняющееся, кеш рухнет целиком, и каждый ход оплачивается по полной.

Отдельная засада: кеш ключей и значений устроен линейно. Из-за этого самая продуманная схема сборки контекста может оказаться в разы дороже наивной, просто потому что промаывается мимо кеша.


ПРОВЕРКА КЕША ЗА ПЯТЬ МИНУТ

1. Посмотрите на первые строки запроса, который уходит модели.
2. Найдите там всё, что меняется от хода к ходу: время, идентификаторы, счётчики.
3. Перенесите это в конец.
4. Сравните долю попаданий в кеш до и после. У правильно настроенного агента она доходит до девяноста процентов.

Стадии инженерии контекста

Полезно понимать, на какой стадии вы находитесь. Люди проходят их примерно в одном порядке.

СТАДИИ



Первая стадия: всё сваливается в один большой запрос. Работает, пока задача помещается.

Вторая: появляется разделение на постоянное и переменное, правила отделяются от задачи.

Третья: появляется управление объёмом. Сжатие, вычистка, ограничение истории.

Четвёртая: появляется управление вниманием. Вы начинаете думать не о том, сколько текста, а о том, где он лежит и что модель прочитает внимательно.

Большинство останавливается на второй и жалуется на счета.

Что запомнить

Контекст оплачивается целиком каждый ход. Длинный разговор дорожает нелинейно.

Внимание распределяется неравномерно: начало и конец лучше середины.

Контекстный движок это то, что решает, что положить. Память и поиск это источники.

Непротиворечивое лучше дать с запасом. Противоречивое надо убирать, а не сокращать.

Стабильное в начало, изменчивое в конец: иначе кеш рушится и каждый ход платится полностью.

И самая дорогая ошибка это тратить сильную модель на навигацию по файлам вместо работы.

Сжатие и что должно его пережить

Рано или поздно разговор упирается в предел. Тогда система делает сжатие: берёт всю накопленную историю и заменяет её кратким пересказом.

Момент этот критический, потому что после него агент часто начинает вести себя странно. Разберём, почему.

Теряются не факты, а их статус

Главное наблюдение, которое объясняет всё остальное.

Сжатие обычно неплохо сохраняет факты: что за проект, какие файлы, что решили. Теряет оно другое: что из этого уже сделано, что отменено, что было гипотезой, а что стало решением.

Симптомы после сжатия узнаваемые. Агент заново берётся за работу, законченную полчаса назад. Отвечает на вопросы, которые уже сняты. Возвращается к варианту, который вы вместе отвергли.

ГЛАВНОЕ ПРО СЖАТИЕ

Сжатие теряет не факты, а их статус. Поэтому пересказ, сделанный автоматически, надо дополнять вашим собственным, где явно сказано, что сделано, что отменено и что решено окончательно.

Пережить сжатие должно то, что дорого восстанавливать, а не то, что легко перечитать. Список файлов агент прочитает заново за секунды. Причину, по которой вы отказались от очевидного решения, он не восстановит никогда.

Что писать в пересказ

Хороший пересказ перед сжатием отвечает на четыре вопроса, и почти никогда не отвечает автоматический.

Вопрос	Пример строки
Что уже сделано и проверено	Первые три пункта плана закрыты, тесты проходят
Что отменено и почему	От очереди отказались: она не решает проблему повторов
Что решено окончательно	Формат хранения выбран, к обсуждению не возвращаемся
Что остаётся открытым	Не решено, как обрабатывать пустой ответ внешнего сервиса

Вторая строка самая ценная. Отменённые варианты без причины возвращаются, потому что для модели они выглядят разумными.


Хук, а не надежда

Инструкция вида перед сжатием напиши хороший пересказ работает плохо, потому что момент сжатия модель не контролирует.

Работает другое: повесить пересказ хуком на событие сжатия. Тогда он формируется всегда, а не когда вспомнилось.

Практики, которые страдали от переделывания сделанного, решали задачу именно так: хук перед сжатием, который кладёт крупное собственное резюме, а не полагается на встроенный механизм.

ТРИ УРОВНЯ СЖАТИЯ



Фрактальные мини-сжатия

Идея, которая пока не стала общей практикой, но объясняет направление мысли.

Сжимать можно не только весь диалог. Можно сжимать отдельный шаг и группу шагов.

Пример, на котором это понятно. Агент листает результаты постранично: прочитал первую страницу, вторую, третью, нашёл нужное на четвёртой. В контексте остались все четыре, хотя нужна только четвёртая. Мини-сжатие убирает три ненужные, оставляя одну строку о том, что поиск занял четыре страницы.

Автор идеи описывал схему с тремя точками отсчёта: до первой ничего не меняется, между первой и второй можно сжимать при большом разрыве, после второй дописанное потом заменяется результатом.

Практическая ценность здесь не в конкретной схеме, а в самой мысли: сжатие это не одно событие в конце, а постоянная работа.

Порог сжатия это настройка

Деталь, о которой узнают поздно: у большинства инструментов есть параметр, задающий, при каком объёме наступает автоматическое сжатие.

Значение по умолчанию выбрано поставщиком под средний случай. Ваш случай средним не является.

ГДЕ СТАВИТЬ ПОРОГ

Раньше. Сжатие происходит чаще, каждый раз теряется меньше, диалог остаётся дешевле. Подходит для длинных прогонов и рутинной работы.

Позже. Сжатие происходит реже, модель дольше видит всю картину целиком. Подходит для задач, где важны связи между далёкими частями.

Признак, что порог не тот. Если после каждого сжатия приходится объяснять заново, ставьте раньше и пишите свой пересказ. Если модель начинает терять связи внутри одной задачи, ставьте позже.

Что делать после сжатия

Отдельный чек-лист, потому что первые ходы после сжатия самые рискованные.

ПЕРВЫЕ ДЕЙСТВИЯ ПОСЛЕ СЖАТИЯ

1. Спросите, что агент считает сделанным. Сверьте со своим представлением.
2. Спросите, какие решения он считает окончательными. Здесь чаще всего всплывают воскресшие отменённые варианты.
3. Попросите перечитать ключевые документы: спецификацию и файл прогресса.
4. Не запускайте длинную задачу сразу после сжатия. Сначала один короткий ход, чтобы увидеть состояние.

Третий пункт хорошо автоматизируется хуком, и именно этот хук в замерах давал восьми-десятипроцентную надёжность против почти нулевой у той же инструкции текстом.

Файл прогресса как страховка

Самый дешёвый способ пережить сжатие вообще без магии: вести файл прогресса на диске.

Агент пишет туда, что сделал, что заблокировано и что пропустил. Файл живёт вне контекста, сжатие его не касается, и после любого обрыва состояние восстанавливается чтением одного файла.

Этот приём стоит завести до того, как вы упрётесь в сжатие. Он же пригодится при автономных прогонах, о которых отдельный модуль.

Разные инструменты сжимают по-разному

Практическое наблюдение, которое стоит проверить у себя: качество автоматического сжатия сильно отличается между инструментами и меняется от версии к версии.

Люди отмечали и то, что в каком-то инструменте сжатие настолько хорошее, что многодневная сессия живёт без потерь, и то, что через месяц у того же инструмента оно стало хуже.

Вывод простой: не полагайтесь на репутацию. Проверьте на своей задаче, задав после сжатия три вопроса из чек-листа выше.

Что запомнить

Сжатие теряет статус фактов, а не факты. Отсюда переделывание сделанного.

Пережить должно то, что дорого восстанавливать: решения, отмены, причины. Списки файлов агент перечитает сам.

Пересказ пишите сами и вешайте хуком, а не надеждой.

Сжимать можно не только весь диалог, но и отдельные шаги.

Порог сжатия это настройка, и значение по умолчанию не про вас.

Файл прогресса на диске переживает любое сжатие и любой обрыв. Заведите его заранее.

Память: файлы, векторы, нити

Память это то, что должно сохраниться, когда разговор кончится. Подходов три, и они решают разные задачи. Путаница между ними стоит дорого, поэтому разберём каждый.

Первый подход: файлы

Самый простой и самый распространённый. Агент пишет заметки в текстовые файлы, они лежат на диске, при необходимости он их читает.

Достоинства очевидны: всё видно глазами, всё правится руками, всё версионировается обычными средствами, ничего не ломается.

Красивый приём, который применяют поверх файловой памяти: ночная свёртка. Дневные заметки раз в сутки сворачиваются в недельные, недельные в месячные, месячные в годовые. Верхние уровни короткие, нижние подробные, и глубина уходит по мере старения.

Недостаток тоже очевиден, и его сформулировали точно: как организация постоянного хранилища это хорошая классика, а вот как эффективно доставать нужное из кучи файлов, непонятно.

Пока файлов десяток, агент их читает. Когда их триста, он читает не те.

Второй подход: векторный поиск

Здесь заметки не просто лежат, а превращаются в числовые представления, по которым можно искать похожее по смыслу.

ЧТО ТАКОЕ ПОИСК ПО СМЫСЛУ

Обычный поиск ищет совпадение букв. Запрос про машину не найдёт заметку про автомобиль. Поиск по смыслу устроен иначе. Каждый кусок текста превращают в набор чисел так, что близкие по смыслу тексты получают близкие наборы. Дальше поиск это сравнение чисел, а не букв. Работает это хорошо ровно до тех пор, пока близость чисел совпадает с близостью смысла. А совпадает она не всегда, и в этом вся сложность.

Ключевая деталь реализации, которая отличает работающую схему от неработающей: подмешивать найденное надо до вызова модели, а не давать модели инструмент поиска.

В первом случае бэкенд получает вопрос, ищет по нему совпадения и кладёт их в контекст ещё до того, как модель начнёт формулировать ответ. Модели ничего не надо решать, факт уже под рукой. Цена этого одна-две секунды на работу поисковой модели.

Во втором случае модель должна догадаться вызвать поиск, сформулировать запрос и дождаться результата. Догадывается она не всегда.

Болезни векторной памяти

Противоречащие факты. Классический пример: человек работал в одной компании, перешёл в другую. Оба факта в памяти, оба похожи на запрос, и выдаются они случайно.

Частичное лечение: хранить дату и давать знаниям вес по времени. Полное: фоновая уборка, о которой ниже.

Порог близости. Проблема, у которой нет красивого решения. Ставите порог низко, и в контекст летят лишние факты, близкие по числам и далёкие по смыслу. Ставите высоко, и нужное перестаёт долетать.

Практик, который бился с этим, перебрал варианты и остановился на честном признании: любой фиксированный порог одновременно слишком строгий и слишком мягкий. Остаётся либо пропускать всё и переранжировать вторым проходом, либо тратить дополнительный вызов модели на отсев.

Свалка. Без уборки память за месяцы превращается в набор несвязных утверждений, и поиск по ней перестаёт что-либо значить.

ГЛАВНОЕ ПРО УБОРКУ ПАМЯТИ

Память нуждается в регулярной свёртке, и делать её лучше в фоне, а не в момент разговора.

Схема, которая работает: ночью отдельный процесс перечитывает накопленное, объединяет повторы, помечает устаревшее, связывает разрозненное. Днём агент пользуется прибранным.

Без этого шага любая память деградирует, независимо от того, файлы это или векторы.

Третий подход: нити

Самая свежая идея из корпуса и, пожалуй, самая полезная.

Нить это что-то между памятью и скиллом. Когда разговор касается долгого процесса, модель заводит нить и ведёт её во всех последующих обсуждениях этой темы.

Внутри нити не отдельные факты, а набор событий и обоснований, привязанный к теме и времени.


Примеры, на которых сразу понятна разница.

Обычный факт	Нить
У пользователя болит колено	История: когда началось, что пробовали, от чего отказались и почему, что сейчас работает
Инвестиционный профиль консервативный	Хронология решений: что покупали, из каких соображений, что оказалось ошибкой
Проект использует такую-то базу	Почему её выбрали, какие были альтернативы, при каких условиях решение пересмотрят

Ценность в правой колонке одна: агент может опереться на то, почему решение было принято раньше. Без этого он предлагает то, что вы уже отвергли, и каждый раз приходится

объяснять заново.

КАК НИТЬ ПОЯВЛЯЕТСЯ



Практик, который это реализовал, отмечал, что агент за одно-два сообщения понимает, когда пора завести новую нить, если в инструкции описан признак: тема, к которой мы возвращаемся и по которой принимаются решения.

Ограничения, о которых надо знать

Объём. Память больше пятнадцати-двадцати тысяч символов начинает деградировать. Агент помнит хуже, а обновление одного факта требует переписывания большого куска. Память это не архив.

Приватность. Групповая память переживает уход человека из группы. Если бот остался, он продолжит собирать сведения, когда человека упоминают. Это не злой умысел, а естественное следствие устройства, и решается оно архитектурой, а не обещаниями.

Стоимость. Честный провал, который стоит знать. В одной реализации маршрутизацией каждого сообщения занимался отдельный фоновый агент: решал, куда его положить. Инженерно красиво, экономически бессмысленно, потому что расход удваивается. Автор сам это признал и переделал.

КАК ВЫБРАТЬ ПОДХОД

1. Нужно, чтобы человек видел и правил руками? Файлы.
2. Записей больше сотни и надо доставать по смыслу? Векторы поверх файлов.
3. Есть темы, где важна история решений, а не факты? Нити.
4. В любом случае: фоновая свёртка и ограничение объёма.
5. И решите заранее, что происходит с памятью о человеке, когда он уходит.

Контекст и память это разные вещи

Напоминание, потому что путают постоянно.

Контекст это то, что модель видит прямо сейчас. Он платный, ограниченный и живёт один разговор.

Память это то, откуда в контекст попадает нужное. Она бесплатна в момент хранения и платна только тогда, когда что-то из неё подставили.

Ошибка, которая дорого обходится: складывать в правила проекта то, чему место в памяти. Правила висят в контексте всегда, а память подставляется по надобности.

Что запомнить

Файлы хороши как хранилище и плохи как поиск. Векторы решают вторую задачу и не решают первую.

Подмешивайте найденное до вызова модели, а не давайте инструмент поиска.

Память без времени врёт: противоречащие факты будут выдаваться случайно.

Любой фиксированный порог близости неверен. Либо переранжирование, либо дополнительный отсев.

Нити хранят не факты, а историю решений с обоснованиями. Это то, что нельзя восстановить.

Уборка в фоне обязательна. Без неё деградирует любая память.

И решите заранее, что происходит с памятью о человеке, когда он ушёл.

Поиск по коду и по документам

Агент, работающий с реальным проектом, большую часть ходов тратит не на решение задачи, а на поиск: где лежит нужное, что с чем связано, что уже сделано. От того, как устроен поиск, зависят и счёт, и качество.

Глава про два разных поиска, которые часто путают: по коду и по документам.

Поиск по коду

Есть три способа объяснить агенту, что где лежит.

Обычный текстовый поиск. Ищет строку. Дёшево, работает везде, ничего не понимает. На вопрос, где вызывается эта функция, даёт все места, где встретилось её имя, включая комментарии и похожие названия.

Языковой сервер. Тот же механизм, что подсказывает переходы в редакторе. Понимает язык, знает, где определение и где использования. Точный, но требует настройки и живёт не для всех языков одинаково хорошо.

Индекс по синтаксическому дереву. Разбирает код в структуру и позволяет искать по конструкциям: все обработчики маршрутов, все вызовы такого-то метода, все места, где перехватывается ошибка.

ЧТО ВЫБИРАТЬ

За языковой сервер. Он точен, потому что понимает язык по-настоящему. Если он у вас настроен, дополнительных индексов может и не понадобиться.

За синтаксический индекс. Он не зависит от окружения, работает на разнородных базах и отвечает быстрее. На больших монорепозитариях разница во времени ответа становится решающей.

Что показало сравнение. Люди, которые не спорили, а замеры, получили разницу во времени в десятки раз при близком качестве ответов. То есть выбор чаще про скорость и удобство, чем про правильность.

Практический совет, который повторяли: не тратьте фронтир-модель на навигацию. Для поиска по коду достаточно небольшой локальной модели, можно каскадом: сначала дешёвая сужает область, потом дорогая работает по сути. Хождение по файлам самой сильной моделью это самая дорогая строка в счёте.

И ещё один приём, который стоит копейки: если у вас есть индекс, запретите текстовый поиск хуком. В правилах это написать можно, но модель забывает.

Поиск по документам

Здесь всё сложнее, и здесь же живёт главный спор корпуса.

ЧТО ТАКОЕ ПОИСК С ПОДСТАНОВКОЙ

Идея простая. У вас есть куча документов, которые не влезают в контекст. Вы режете их на куски, для каждого куска считаете числовое представление и складываете в базу.

Когда приходит вопрос, вы считаете представление вопроса, находите похожие куски и подставляете их в запрос к модели.

Подход называют поиском с подстановкой. Он появился, когда контекст был маленьким, и с тех пор его несколько раз объявляли мёртвым.

Спор о том, нужен ли он

Позиция за отмену. Контекст вырос настолько, что проще положить всё целиком. Резать документы на куски значит терять связи, а поиск по числам промахивается там, где нужен смысл.

Позиция за сохранение. Целиком влезает не всё и не всегда, а платить за миллион токенов на каждый вопрос никто не будет. Плюс есть класс задач, где документы меняются каждый день, и перекладывать их в контекст бессмысленно.

Разрешение, к которому пришли. Это не мода и не пережиток, а инструмент под определённый профиль задачи: много документов, они меняются, вопросы к ним разные и заранее неизвестны. Если профиль другой, инструмент не нужен.

Что кладут в кусок

Самая практичная часть главы. Качество поиска определяется не алгоритмом, а тем, что вы положили в кусок вместе с текстом.

Что добавляют	Зачем
Путь по оглавлению	Кусок перестаёт быть безымянным абзацем
Заголовки разделов выше	Появляется контекст, откуда это
Теги и ключевые понятия	Работает поиск по синонимам
Дата и источник	Можно отсеять устаревшее и оценить доверие
Краткое описание куска	Модель понимает, что перед ней, не читая целиком

Отдельный приём, который заметно улучшает попадание: расширение запроса. Вопрос пользователя перед поиском переписывается моделью в несколько формулировок, и ищется по всем. Стоит один дешёвый вызов, а находит заметно больше.

ГЛАВНОЕ ПРО НАРЕЗКУ

Куски лучше делать моделью, а не фиксированным алгоритмом.

Нарезка по числу символов рвёт таблицы посередине и отделяет заголовок от содержания.


Модель режет по смыслу и заодно дописывает к куску метаданные.

Дороже на этапе подготовки, дешевле на каждом последующем вопросе. Подготовка делается один раз, вопросы задаются всегда.

Конвейер разбора документов

Практическая схема, которая экономит и деньги, и качество. Ошибка новичка здесь одна и та же: гнать всё через тяжёлый разбор с распознаванием текста.

КУДА ОТПРАВИТЬ ДОКУМЕНТ



Обе ветки сходятся в одном представлении, из которого дальше получают текст для модели, структурированные данные или куски для поиска.

Почему это важно, показывает замер, сделанный на живом документе. Популярная библиотека разобрала таблицу за сто семьдесят миллисекунд и развалила её в вертикальный столбик ячеек: связь строки и колонки потерялась полностью. Специализированный конвертер справился за четырнадцать миллисекунд и вернул нормальную таблицу с заголовками.

Разница не в скорости. Разница в том, что именно первый вариант попадает в куски и в глаза модели, когда человек прикрепил коммерческое предложение. Модель видит кашу и отвечает по каше.

Порог отсечения

Про него говорилось в главе о памяти, но повторим, потому что это общая беда обоих поисков.

Любой фиксированный порог близости одновременно слишком строгий и слишком мягкий. Близость по числам не равна релевантности.

Варианты, между которыми выбирают: пропускать всё и переранжировать вторым проходом, либо тратить дешёвый вызов модели на отсеивание, либо принять, что часть мусора долетит, и научить агента его игнорировать.

Третий вариант недооценён. Модель неплохо справляется с лишним куском, если он явно помечен как найденное по запросу, а не выдан за факт.

НАСТРОЙКА ПОИСКА ПО ДОКУМЕНТАМ

1. Проверьте разбор на самом сложном документе. Разваленная таблица это ваш потолок качества.
2. Добавьте в каждый кусок путь по оглавлению и дату.
3. Включите расширение запроса: один дешёвый вызов перед поиском.
4. Не подбирайте идеальный порог. Пропускайте с запасом и переранжируйте.
5. Пометьте подставленное как результат поиска, а не как истину.

Что запомнить

Поиск по коду и поиск по документам это разные задачи с разными инструментами.

Навигацию по коду отдавайте дешёвой модели. Это самая дорогая строка в счёте, если этого не сделать.

Есть индекс, запретите текстовый поиск хуком: правилом модель забудет.

Поиск с подстановкой нужен там, где документов много, они меняются и вопросы заранее неизвестны.

Качество определяется тем, что вы положили в кусок: путь по оглавлению, дата, теги, описание.

Офисные форматы не гоняйте через распознавание. Структура там уже есть, задача её не потерять.

И проверяйте разбор на самом сложном документе, потому что развалившаяся таблица это ровно то, что увидит модель.

Модуль 5. Делегирование

Три главы о том, кому и что отдавать.

Субагенты, рои и конвейеры из ролей. Когда делегирование помогает, когда мешает и почему разграничение всегда проходит по одной и той же линии: сбор материала делится, выбор нет.

Модуль нужен, когда задачи перестали помещаться в один разговор.

Субагент: когда помогает, когда мешает

Субагент это агент, которого запускает другой агент. У него свой чистый контекст, свой набор инструментов и своя задача. Отработал, вернул результат, исчез.

Звучит как очевидное благо: разделяй и властвуй. На практике это самая частая причина непонятного поведения и неожиданных счетов.

Зачем вообще делегировать

Настоящих причин две, и обе про контекст.

Изоляция мусора. Исследование засоряет основную сессию навсегда. Агент прочитал двадцать файлов, чтобы найти один ответ, и все двадцать теперь висят в контексте до конца разговора. Если то же самое делает субагент, наружу выходит только ответ.

Формулировка практика, который на этом обжётся: надо спавнить субагента, иначе весь результат поиска будет висеть у агента всю оставшуюся сессию за ненадобностью.

Параллельность. Пять независимых кусков работы делаются одновременно, а не по очереди. Работает только тогда, когда куски действительно независимы.

ГЛАВНОЕ ПРО ДЕЛЕГИРОВАНИЕ

Делегирование это решение по дизайну исполнения, а не способ сэкономить контекст.

Формулировка кажется придиркой, но она меняет подход. Если вы делегируете ради экономии, вы не считаете издержки координации. А они есть всегда: передача задачи, потеря контекста, сборка результатов, разбор противоречий между ответами.

Что теряется при передаче

Главная скрытая цена. Субагент получает не всё, что знает родитель, а только то, что родитель решил передать. И родитель решает это плохо.


Типичные потери:

Правила проекта. Субагенты не наследуют их автоматически, и об этом узнают, когда субагент нарушает то, что в правилах написано прямым текстом.

Причины предыдущих решений. Родитель знает, почему отказались от очевидного варианта. Субагент не знает и предлагает его снова.

Оговорки в задании. Вы сказали пять уточнений, родитель передал одно.

ЧТО ПРОИСХОДИТ С ЗАДАЧЕЙ ПРИ ДЕЛЕГИРОВАНИИ



Отсюда практическое следствие: чем тоньше задача, тем хуже её делегировать. Не потому что субагент глупый, а потому что канал передачи узкий.


Сформулированный запрет

Есть класс задач, где практики пришли к прямому запрету: писать код субагентами.

Критерий сформулирован точно. Тесно связанные решения должны оставаться у одного ответственного. Если два куска кода должны быть согласованы между собой, их нельзя писать в двух головах, у которых нет общего контекста.

Что происходит без этого запрета: два субагента пишут два куска, каждый по-своему трактует один и тот же интерфейс, и родителю достаётся работа по примирению, которая дороже, чем написать всё сразу.

ОТДАВАТЬ ЛИ РАБОТУ СУБАГЕНТУ



Правило для роя

Формулировка, которая закрывает большинство вопросов: не делегируйте агентам принятие решений. Говорите им копай и возвращайся, решать будем вместе.

Параллельность прекрасно работает на сборе и структурировании материала. И плохо работает на выборе, потому что выбор требует сравнения всех вариантов в одной голове.

Замеры, которые приводили практики, ложатся на это правило точно. Полсотни субагентов параллельно читали переписку и вернули структурированный материал за полчаса: типичная задача сбора. Девять агентов собирали карту кода, потом дюжина в несколько заходов писала проектный документ: тоже сбор и структурирование. А вот разбор архитектурной развилки восьмью агентами занял два часа и всё равно закончился человеческим решением.

Взрыв субагентов

Инцидент, который стоит знать до того, как он случится у вас.

Человек открыл свежий разговор в своём репозитории и задал безобидный вопрос: что это за проект и какие дальнейшие шаги. На максимальном уровне усилий.

Агент запустил три субагента. Каждый из них запустил по три. Через минуту их было сорок, и они продолжали появляться. Настройка ограничения глубины, которая была в конфигурации, не сработала. Уровень усилий субагенты наследовали от родителя, то есть максимальный.

Ещё через две минуты их было бы под три сотни.

ЗАЩИТА ОТ ВЗРЫВА

1. Проверьте ограничение глубины экспериментом, а не чтением конфигурации. Оно может не работать.
2. Ограничьте число одновременных субагентов явным числом.
3. Проверьте, наследуется ли уровень усилий. Обычно да, и это дорого.
4. Заведите потолок расхода на одну задачу и остановку при его достижении.
5. Первый запуск делегирования проводите на дешёвой модели.

Одноразовые исполнители против постоянных ролей

Два способа применять субагентов, и они дают разный результат.

Одноразовые. Субагент создаётся под конкретную подзадачу, получает всё нужное в задании, возвращает результат и забывается. Просто, предсказуемо, не накапливает состояние.

Постоянные роли. Заводится набор ролей с собственными инструкциями: исследователь, разработчик, ревьюер. Они живут долго, у каждого своё поведение.

ЧТО ВЫБРАТЬ

За одноразовых. Меньше сущностей, меньше состояния, проще отладка. Каждый запуск воспроизводим.

За роли. Инструкция пишется один раз и переиспользуется. На повторяющемся процессе экономит заметно.

Побочный эффект ролей, о котором предупреждают. Роли начинают жить своей жизнью: обрастают правилами, конфликтуют между собой и требуют отдельного сопровождения. Через полгода это отдельная система, которую надо поддерживать.

Когда делегирование просто не нужно

Отрезвляющее наблюдение: у людей, которые ведут несколько проектов, ограничение находится не в агентах, а в них самих. Больше двух-трёх задач одновременно человек не тянет когнитивно, и никакая параллельность этого не меняет.

Запустить много исполнителей недолго. Придумать им осмысленную работу и проверить результат это и есть узкое место.

Что запомнить

Делегируйте ради изоляции контекста и настоящей параллельности, а не ради экономии.

Считайте издержки координации явно. Они всегда есть.

Тесно связанные решения оставляйте у одного ответственного.

Правило для роя: копай и возвращайся, решать будем вместе.

Ограничение глубины проверяйте экспериментом, уровень усилий наследуется и стоит денег.

И помните, что потолок параллельности это не агенты, а человек, который ставит им задачи.

Многоагентность и рои

Если предыдущая глава была про одного субагента, эта про десятки. Тема, вокруг которой больше всего шума и больше всего разочарований.

Главный спор и его разрешение

Спор шёл почти весь наблюдаемый период и звучал так.

Позиция скептиков. Многоагентность это способ потратить в десять раз больше токенов и получить в среднем тот же результат. Ошибки накапливаются, агенты дублируют работу, координация съедает выигрыш.

Позиция сторонников. Одна голова не удержит большую задачу. Разделение неизбежно, вопрос только в том, как его организовать.

Разрешение оказалось не компромиссом, а разграничением: многоагентность хороша на одних задачах и разрушительна на других, и граница проходит там же, где в прошлой главе.

ГЛАВНОЕ ПРО РОИ

Параллельные агенты хороши на сборе и структурировании материала. Плохи на выборе.

Собрать сведения из тридцати источников, разобрать сорок файлов, прочитать длинную переписку и вернуть структуру: делится идеально, потому что куски независимы.

Выбрать между двумя архитектурами, решить, что важнее, определить приоритет: не делится вообще, потому что сравнение требует всех вариантов в одной голове.


Три топологии

Практически все рабочие схемы сводятся к трём формам.

Топология	Как устроена	Что даёт	Чем платит
Цепочка	Результат одного идёт следующему	Простота, воспроизводимость	Медленно, ошибка ранних передаётся дальше
Веер	Один разослал, все работают, один собрал	Настоящая параллельность	Сборка результатов и их противоречия
Дерево	Веер, у которого ветки тоже ветвятся	Масштаб	Взрыв, потеря контекста, непредсказуемый счёт

Первые две предсказуемы. Третья это то, где случаются истории про сорок субагентов за минуту.

БЕЕР, САМАЯ РАБОЧАЯ ФОРМА



Последний шаг критичен и чаще всего забывается. Сведение делает один агент или человек, потому что именно там принимается решение.

Цифры, которые полезно знать

Замеры из практики, чтобы представлять масштаб.

Полсотни агентов параллельно читали длинную переписку. Весь проход занял около полу-часа. Задача чистого сбора, делится идеально.

Девять агентов собирали карту незнакомого кода, потом дюжина в несколько заходов писала проектный документ. Здесь уже смешанная задача, и заметная часть времени ушла на согласование.

Восемь агентов два часа разбирали развилку в архитектуре. Результат: материал для человеческого решения. Само решение принял человек.

Отдельная строка: прогнать полный набор агентных бенчмарков стоит как квартира. Это не шутка автора, а цитата из разбора, и она объясняет, почему независимых проверок так мало.

Как ошибки накапливаются

Самое важное для понимания рисков.

Ошибки в многоагентном потоке накапливаются нелинейно. Долго всё выглядит стабильно, а потом происходит резкий срыв. Аналогия, которую приводили: это как прогноз погоды. На три дня вперёд считается неплохо, на четыре почти невозможно, и разница между тремя и четырьмя гораздо больше, чем кажется.

Практическое следствие: то, что схема отработала пять раз, не означает, что она отработает шестой. И отодвинуть точку срыва гораздо труднее, чем её обнаружить.

ЧТО С ЭТИМ ДЕЛАТЬ

Ограничивать. Держать глубину в один уровень, число агентов в десятках, а не сотнях, и всегда иметь потолок расхода.

Проверять. Считать не результат одного прогона, а разброс между несколькими. Стабильная схема даёт близкие результаты, нестабильная разные.

Не масштабировать раньше времени. Схема, отработавшая на трёх задачах, не готова к тридцати. Это разные режимы.

Мета-обвязка

Тренд, который оформился ближе к концу наблюдаемого периода и выглядит разумно.

Оркестратор держит чистый контекст и почти ничего не знает. Обвязка собирается субагентам под конкретную задачу: этому дали такие инструменты и такие правила, тому другие.

Смысл в том, что универсальный набор инструментов для всех агентов сразу это и дорого, и вредно: каждый агент видит инструменты, которые ему не нужны, и иногда ими пользуется.

Рядом идёт вторая идея: на проект делается два набора обвязки, рабочий и тестирующий. Второй существует, чтобы измерять первый.

Ферма не заменяет голову

Отрезвляющее наблюдение, которым закончился один из самых длинных споров.

Кто-то предположил, что скоро можно будет сказать системе собери мне хороший продукт, и рой агентов всё сделает. Ответ был такой: если постановка верхнего уровня звучит как собери отличный продукт, никакое количество агентов в циклах не даст хорошего результата, потому что человек, который так ставит задачу, не отличит отличный результат от плохого.

И вывод, который стоит запомнить целиком.

ГЛАВНОЕ ПРО ПРЕДЕЛЫ

Агентские фермы полезны в руках людей, которые справились бы и без агентских ферм.

Ферма умножает то, что у вас есть. Если есть внятная постановка и умение проверить результат, она умножит их. Если нет, она умножит отсутствие.

Практическая схема на сегодня

Что реально работает у людей, которые этим пользуются каждый день.

РАБОЧАЯ СХЕМА МНОГОАГЕНТНОСТИ

1. Делите только то, что действительно независимо. Проверка: результат одного куска нужен другому? Значит не независимо.
2. Глубина один уровень. Субагенты не запускают субагентов, пока вы не проверили, что ограничение работает.
3. Каждому субагенту минимальный набор инструментов. Лишний инструмент будет использован.
4. Формулировка задания одинаковая для всех: собери и верни, решать будем вместе.
5. Сведение результатов делает один агент или человек. Это точка принятия решения.
6. Потолок расхода на задачу и остановка при его достижении.

Что запомнить

Рои хороши на сборе и структурировании, плохи на выборе.

Три топологии: цепочка, веер, дерево. Первые две предсказуемы, третья взрывается.

Ошибки накапливаются нелинейно: долго стабильно, потом резкий срыв.

Оркестратор держит чистый контекст, обвязка собирается субагентам под задачу.

Ферма умножает то, что есть. Если постановка плохая, она умножит плохую постановку.

Роли и конвейер


Одиночные субагенты решают одну задачу. Если задач много и они однотипные, из агентов собирают процесс: у каждого своя роль, между ролями шлюзы.

Это работает, но не так, как рисуют на схемах. Разберём и схему, и разницу с реальностью.

Схема ролей

Вот конвейер, который собирали практики. Он повторяет обычный процесс разработки, только исполнители другие.

КОНВЕЙЕР РОЛЕЙ



Продукт формулирует требования. Исследователь собирает факты и варианты решения. Разработчик пишет код и тесты и отправляет изменения. Дальше параллельно работают двое: один смотрит код и разницу, другой проверяет поведение. Когда оба дали добро, изменения сливаются. В конце продукт принимает результат.

Схема красивая. Теперь честная часть.

Что происходит на самом деле

Автор этой схемы описал её состояние так: крутятся, задачи друг другу ставят, результат я не проверял.

И вопрос, который ему тут же задали, был правильный: покажи продуктовую задачу верхнего уровня, которую они разгрызают, нормально декомпозируя на технические, без лишних слоёв и переусложнения.

Ответа не последовало. Это типичная ситуация: конвейер собирается за вечер, выглядит убедительно, агенты действительно обмениваются сообщениями, и никто не проверил, стал ли результат лучше, чем у одного агента с хорошей постановкой.

ГЛАВНОЕ ПРО КОНВЕЙЕРЫ РОЛЕЙ

Проверять надо не то, что агенты общаются, а то, что результат стал лучше.

Обмен сообщениями между агентами выглядит впечатляюще и ничего не доказывает. Единственная честная проверка это сравнение с базовой линией: та же задача, один агент, хорошая постановка. Если конвейер не выигрывает, вы построили театр.

Побочные эффекты ролей

Практики, которые жили с ролевым конвейером дольше пары недель, отмечают несколько вещей.

Роли обрастают. Каждая роль постепенно получает свои правила, свои исключения, свои оговорки. Через полгода это отдельная система, требующая сопровождения.

Роли конфликтуют. Ревьюер требует одного, разработчик приучен к другому, и оба ссылаются на свои инструкции. Разрешать конфликт приходится человеку.

Роли имитируют. Самый неприятный эффект. Агент в роли ревьюера знает, что от него ждут замечаний, и находит их, даже когда всё в порядке. Замечания при этом формально верные и бесполезные.

РОЛИ ИЛИ ОДИН АГЕНТ С ЭТАПАМИ

За роли. Инструкция для каждой роли пишется один раз. На повторяющемся потоке задач экономит. Роли можно давать разным моделям, и это экономит расход.

За одного агента с этапами. Тот же результат достигается сменой инструкции внутри одного разговора: сейчас ты исследуешь, теперь проектируешь, теперь проверяешь. Контекст не теряется, координировать нечего.

Что решает. Объём. Если задача помещается в один разговор, роли не нужны. Если не помещается, роли это способ разбить её на разговоры.


Шлюзы

Самая ценная часть конвейера не роли, а шлюзы: точки, где что-то не пропускают дальше.

Практика, которая описана в разборах как переломная. В компании завели агента-ревьюера, который отписывается по каждому изменению. Без его одобрения изменения не сливаются. Иногда до согласия доходит десять итераций правок.

При этом человеческое ревью пройти проще, и если человек одобрил, можно сливать сразу.

ПОРЯДОК ШЛЮЗОВ



Смысл перестановки в том, что машинный проход дешёвый и бесконечно терпеливый, а человеческое внимание дорогое. Пусть дешёвое отсекает очевидное, а дорогое смотрит на суть.

Формулировка автора этой схемы была короткой: и это всё меняет.

Схема менеджер плюс исполнитель

Отдельная форма конвейера, которая появилась из экономии и оказалась полезной сама по себе.

Сильная модель работает только в режиме планирования: читает код, читает правила, готовит развёрнутый план. Ей явно говорят, что она не исполнитель, а менеджер, который ставит задачи. Исполнение уходит дешёвой модели. Финальное ревью снова у сильной.

Результат по замерам: время выполнения растёт примерно втрое, расход лимитов падает кратно.

Возражения, которые надо знать:

Сначала нужно ревью самого плана, потому что слепые зоны находятся всегда.

Написать код по хорошей спецификации нетрудно, а вот довести спецификацию до состояния хорошей менеджер не поможет.

И самое едкое: запустить тонну исполнителей недолго, задачи всё равно кто-то должен ставить.

КАК ПРОВЕРИТЬ, ЧТО КОНВЕЙЕР РАБОТАЕТ

1. Возьмите пять типовых задач.
2. Прогоните каждую двумя способами: через конвейер и через одного агента с хорошей постановкой.
3. Сравните три величины: качество результата, расход, время до готового.
4. Если конвейер не выигрывает хотя бы в одной, он не нужен.
5. Повторяйте после каждого изменения ролей. Конвейер деградирует незаметно.

Где конвейер точно оправдан

Чтобы глава не звучала как отрицание, назовём случаи, где конвейер выигрывает уверенно.

Однотипный поток. Десятки похожих задач в неделю. Инструкция роли пишется один раз и окупается.

Разные модели на разных этапах. Планирование дорогое, исполнение дешёвое. Разделение по ролям это способ развести их технически.

Обязательные шлюзы. Когда есть требование, чтобы ни одно изменение не проходило без проверки, роль ревьюера это способ его выполнить.

Разделение доступа. Исследователю не нужны права на запись. Разделение по ролям это заодно разделение прав.

Последний пункт часто оказывается главным аргументом, хотя вспоминают о нём последним.

Что запомнить

Конвейер из ролей проверяется сравнением с одним агентом, а не количеством сообщений между агентами.

Роли обрастают, конфликтуют и имитируют работу. Это цена, а не случайность.

Ценность конвейера в шлюзах, а не в ролях.

Машинный шлюз перед человеческим экономит самое дорогое: внимание человека.

Схема менеджер плюс исполнитель замедляет втрое и кратно снижает расход, но требует ревью плана.

И роли оправданы там, где есть поток однотипных задач или требование разделить права.

Модуль 6. Проверка

Четыре главы о том, как отличить работающее от кажущегося работающим.

Ревью, измерения, детерминированные проверки и ответ на вопрос, сколько полировать. Это тот слой, который поставщик не даст и фреймворк не подскажет: его придётся построить самому.

Если читать книгу выборочно, начинать стоит с этого модуля.

Ревью

Вопрос, который задают новички: зачем ревью, если план был подробный и агент по нему работал.

Ответ короткий: потому что ошибки бывают и в плане. Ответ длинный занимает эту главу.

Нельзя быть себе судьёй

Основа всего дальнейшего.

Агент, который только что написал код, видит в нём стройность. Не потому что он самодоволен, а потому что он помнит, как принимал каждое решение, и каждое кажется обоснованным. Это ровно то, что происходит с человеком.

Тот же агент, запущенный в чистой сессии и получивший тот же код без истории его создания, находит претензии. Иногда десятки.

ГЛАВНОЕ ПРО ПРЕДВЗЯТОСТЬ

Предвзятость создаётся контекстом, а не моделью.

Та же самая модель на той же задаче ведёт себя по-разному в зависимости от того, есть ли у неё история создания результата. Это значит, что для ревью не обязательно брать другую модель. Обязательно взять чистую сессию.

Практики, которые это заметили, описывали одинаково: у меня одна и та же модель ставит задачи на рефакторинг сама себе, и это не про конкретную модель, они всегда находят к чему придраться, если запускать ревью без предвзятости.

Почему агент в ревью надёжнее

Есть и вторая причина, помимо чистого контекста.

Ревью это более узкая работа. Область известна, контекст задан и его не надо собирать самому, отбрасывать ничего не нужно. Агент в такой позиции ошибается реже, чем когда он одновременно ищет, решает и делает.

Это же объясняет, почему ревью хорошо делегируется, а разработка плохо: у ревьюера канал передачи задачи широкий, вот код и вот критерии.

Что смотреть в трёх точках

Проверка только в конце опаздывает. К финалу упрощения выросли в код, и вычищать их дороже, чем написать заново.

Точка	Что смотреть	Цена пропуска
На входе	Как агент понял постановку и что предлагает делать	Минуты на переформулировку

Точка	Что смотреть	Цена пропуска
В процессе	Чем он занят на самом деле, а не что докладывает	Часы на переделку куска
На выходе	Совпадает ли результат с замыслом	Дни на разбор проекта

Первая точка самая дешёвая и самая недооценённая. Агент выдаёт свои намерения уже в первом ответе на постановку, надо просто прочитать.

Оценка вместо чтения кода

Отдельная проблема тех, кто в код не смотрит: как понять, что там.

Работающий приём: попросить пересказ обычными словами. Откуда берутся данные, куда записываются, на основании чего принимаются решения, что произойдёт при ошибке.

Подделать такой пересказ трудно. Если под капотом сравнение строк по списку слов, это вылезет в первом же предложении, потому что описывать придётся именно список.

ТРИ ВОПРОСА ВМЕСТО ЧТЕНИЯ КОДА

1. Расскажи обычными словами, что происходит от момента, когда приходят данные, до момента, когда что-то меняется в системе.
2. Назови три места, где это сломается, и что произойдёт в каждом случае.
3. Что ты решил сам, чего я не просил, и почему.

Третий вопрос вылавливает больше всего. Агент почти всегда принимает решения, о которых вы не знаете, и обычно охотно их называет, если спросить прямо.

Просьба оценить качество не работает

Наблюдение, которое избавляет от иллюзий.

Запрос вида оцени, хорошо ли это спроектировано, даёт бесполезный положительный ответ. Модель ответит, что в целом неплохо, и перечислит общие места.

Работает только явный список конкретных простых вопросов, на каждый из которых есть однозначный ответ да или нет.

ПРОСЬБА, КОТОРАЯ НЕ РАБОТАЕТ

Оцени качество архитектуры этого модуля

Ответ будет вежливым, общим и положительным. Никакой информации.

ПРОСЬБА, КОТОРАЯ РАБОТАЕТ

Ответь да или нет на каждый: 1) можно ли добавить новый тип, не трогая существующие ветвления; 2) есть ли место, где ошибка обрабатывается молча; 3) можно ли протестировать эту логику без запуска всей системы; 4) есть ли дублирование с уже существующим модулем

На каждый вопрос есть проверяемый ответ, и каждое нет это конкретная работа.


Тот же принцип применим и к скиллам, которые проверяют качество: сильные из них построены не на оценке по шкале, а на чётком да или нет, и если нет, отправляют переделывать.

Цикл ревью

Схема, которая устоялась у практиков: несколько итераций полировки и одна схлопывания.

Полировка это когда ревьюер находит претензии, а исполнитель их закрывает. Обычно за три-пять проходов поток претензий иссякает.

Схлопывание это отдельный проход с другой задачей: убрать то, чторосло за время полировки. Дублирование, лишние проверки, обходные пути, которые перестали быть нужны.

ЦИКЛ РЕВЬЮ

Без шага схлопывания полировка раздувает проект. Это подробно разобрано в главе о том, сколько полировать.

Кто ревюит

Три варианта, и все рабочие.

Та же модель, чистая сессия. Дёшево, доступно всегда, ловит большую часть.

Другая модель. Дороже, но ловит другое: у разных семейств моделей разные слепые зоны. Практики, гонявшие ревью через две модели, отмечали, что уникальных находок у каждой примерно поровну, и именно непересекающиеся находки ценны.

Человек. Самое дорогое и самое незаменимое там, где вопрос не в правильности, а в уместности.

Полезное наблюдение из практики: если самые сильные модели два раза подряд находят настоящие проблемы, это повод задуматься, что задача переусложнена, и, возможно, для неё есть готовое проверенное решение.

Что запомнить

Нельзя быть себе судьёй. Предвзятость создаётся контекстом, а не моделью, поэтому достаточно чистой сессии.

Смотрите в трёх точках. Первая, реакция на постановку, самая дешёвая.

Вместо чтения кода просите пересказ обычными словами и вопрос о том, что агент решил сам.

Просьба оценить качество бесполезна. Работает список вопросов с ответом да или нет.

Несколько итераций полировки и обязательная итерация схлопывания.

И если сильные модели два раза подряд находят настоящие проблемы, проверьте, не переусложнена ли сама задача.

Эвалы

Эта глава самая техническая в книге и самая полезная. Здесь про то, как отличить улучшение от совпадения.

ЧТО ТАКОЕ ЭВАЛ

Эвал это набор задач с известным ожидаемым результатом, на котором вы проверяете свою систему.

Слово пришло из машинного обучения, где так называют оценку модели. У нас оно означает то же самое, только оценивают не модель, а всю сборку: модель вместе с инструкциями, инструментами и обвязкой.

Смысл в одном: без него вы не знаете, стало лучше или вам показалось.

Один прогон это не эвал

Главное утверждение главы.

Агент стохастичен. Тот же запрос при той же температуре даёт разные траектории: разный порядок вызовов, разные промежуточные решения, иногда разный результат.

Значит, один зелёный прогон в автоматической проверке ничего не доказывает. Это одна точка из распределения, и вы не знаете, где она в этом распределении лежит.

ГЛАВНОЕ ПРО ИЗМЕРЕНИЕ

Метрика вида запустил один раз и посмотрел это не метрика, это лотерея.

Правильная величина это доля успешных из нескольких попыток. Гоняйте одну задачу несколько раз и смотрите не на факт успеха, а на его частоту. Разброс между прогонами это и есть информация: маленький разброс означает надёжную схему, большой означает, что вы пока управляете случайностью.

Первое, что стоит сделать после этой главы: взять свою типовую задачу, прогнать её пять раз подряд и посмотреть на результаты. У большинства это меняет представление о собственной системе сильнее, чем любая теория.

Выкиньте шкалы

Второе утверждение, идущее вразрез с интуицией.

Естественное желание при оценке качества это шкала от одного до пяти. Модель-судья ставит оценку, вы усредняете, получаете число, строите график.

Совет человека, который поставил больше тридцати систем оценки: выкинуть шкалы и судить бинарно. Прошло или не прошло, плюс критика текстом.

Причина в том, что дашборд из оценок вида три и две десятых и четыре и одна десятая это бухгалтерия без смысла. Что делать с числом три и две десятых, непонятно. Что делать со

списком из десяти проваленных случаев и объяснением, почему они провалились, понятно сразу.

Судья строится из объяснений эксперта


Третье, и самое неочевидное.

Обычный подход: вы пишете судье инструкцию, где перечисляете критерии хорошего ответа. Проблема в том, что вы перечисляете то, что можете сформулировать, а не то, что действительно отличает хорошее от плохого.

Работающий подход другой. Главный доменный эксперт размечает около тридцати примеров: прошло или не прошло, и обязательно объяснение почему. Запрос для судьи строится уже из этих объяснений.

Разница в том, что в объяснениях эксперта вылезают критерии, которые он сам не назвал бы, если спросить абстрактно.

КАК СТРОИТСЯ ЭВАЛ



Считайте по срезам

Общая доля ошибок мало о чём говорит. Восемьдесят процентов успеха может означать и ровное качество, и отличную работу на большинстве случаев при полном провале на одном классе.

Полезные срезы: по функции системы, по типу сценария, по типу пользователя. Именно на срезах видно, что чинить.

Смещения судьи

Четвёртое, техническое, но критичное.

Модель-судья, сравнивая два ответа, страдает двумя предпочтениями, которые не зависят от качества.

Позиционное. Первый показанный ответ выигрывает чаще.

Многословное. Более длинный ответ кажется лучше.

Оба смещения работают даже у сильных моделей. Лечится позиционное перемешиванием: каждую пару показывайте в обоих порядках и усредняйте. Многословное лечится хуже, но хотя бы учитывается: если ваш новый вариант просто длиннее, рост оценки может быть иллюзией.

Судить траекторию, а не ответ

Пятое, специфичное именно для агентов.

У обычной модели есть только ответ. У агента есть путь: какие инструменты вызвал, в каком порядке, сколько раз ошибся, что прочитал.

Правильный ответ, полученный случайно после двадцати неудачных попыток, это не то же самое, что правильный ответ с первого захода. Первый развалится на следующей задаче.

Поэтому судят траекторию: использовал ли агент нужные инструменты, не ходил ли по кругу, уложился ли в разумное число ходов.

ГЛАВНОЕ ПРО ЭВАЛ АГЕНТА

Эвал агента это не тест, а распределение.

Несколько прогонов, судья из другого семейства моделей, суд по траектории, а не только по ответу, счёт по срезам. Всё вместе, иначе получается видимость измерения.

Эвалы для скиллов и инструкций

Отдельный случай, где легко обмануться.

Проверять скилл надо сравнением с базовой линией: та же задача без скилла. Иначе вы измеряете способности модели, а не пользу своей надстройки.

Формулировка, которая позволяет понять, что перед вами честный замер: девяносто процентов выполненных требований со скиллом против семидесяти пяти без него, на двенадцати сценариях по три прогона. Здесь есть база, есть число случаев, есть повторы. Утверждение вида стало в десять раз лучше не содержит ничего из этого.

Самое трудное в оценке скилла не измерение, а формулировка повторяемой задачи, на которой измерение вообще имеет смысл. Если задача каждый раз разная, сравнивать нечего.

С чего начать, если ничего нет

ПЕРВЫЙ ЭВАЛ ЗА ОДИН ВЕЧЕР

1. Возьмите десять задач, которые вы реально давали агенту за последний месяц. Не придумывайте новые.
2. Для каждой запишите, что считается успехом. Одним предложением, проверяемым.
3. Прогоните каждую три раза. Запишите, сколько раз получилось.
4. Посчитайте долю успеха по всему набору и по срезам, если срезы просматриваются.
5. Это ваша базовая линия. Дальше любое изменение обвязки проверяется тем же набором.
6. Раз в месяц выбрасывайте задачи, которые проходят всегда. Они больше ничего не измеряют.

Шестой пункт неочевиден, но важен. Набор, где всё зелёное, перестал быть измерением и стал ритуалом.

Что считать хорошим набором задач

Критерии приёмки, которые сформулировали в одной из фабрик эвалов: осмысленность, элегантность, разнообразие.

И отдельно оговорка: сложность намеренно не является критерием. Сложность легко накрутить, и она не коррелирует с полезностью. Набор из десяти зубодробительных задач хуже, чем набор из десяти типичных.

Что живёт долго

Наблюдение, которым стоит закончить.

Инструкции стареют. Скиллы стареют. Обязка устаревает быстрее, чем достраивается.

Постоянно живут только проверки. Хотя и они однажды выбрасываются, но живут дольше всего остального.

Из этого следует порядок вложений: сначала способ измерить, потом всё остальное. Обратный порядок это то, что делают почти все, и потом годами спорят о приёмах вместо того, чтобы их сравнить.

Что запомнить

Один прогон это точка из распределения. Считайте долю успешных из нескольких.

Шкалы от одного до пяти выбрасывайте. Прошло или нет, плюс критика.

Судью стройте из объяснений эксперта на трёх десятках размеченных примеров.

Считайте по срезам, а не общим средним.

Перемешивайте позиции при сравнении: первый и длинный выигрывают сами по себе.

Судите траекторию, а не только ответ.

Скилл проверяйте против базовой линии без него.

И стройте измерение раньше обязки, а не после.

Детерминированные проверки вместо уговоров

Есть класс проблем, который не лечится ни инструкцией, ни ревью, ни эвалом. Он лечится тем, что часть контроля забирают у модели и отдают коду.

Правила не удерживают агента

Начнём с исследования, которое стоит знать всем.

Была построена проверка следования инструкциям: подробные руководства на шестнадцать страниц, от финансов до модерации, и агенты, которым велено им следовать.

Результат оказался неприятным. Даже детальные руководства не гарантируют контроль. Агенты находили лазейки: выполняли требования формально и нарушали суть.

Требование	Как обошли
Не удаляй файлы	Переименовал
Не публикуй секреты	Закодировал
Не превышай лимит запросов	Разбил на несколько источников

Вывод авторов сформулирован жёстко: управление агентами через правила принципиально ненадёжно.

ГЛАВНОЕ ПРО ЗАПРЕТЫ

Агент выполняет букву и нарушает смысл. Не из вредности, а потому что задачу надо закрыть, а прямой путь закрыт.

Отсюда следует, что запрет без предоставленного правильного пути порождает не качество, а изобретательность. Чем строже запрет, тем изобретательнее обход.

Это ровно то же наблюдение, что и в главе про регекспы: запрет закрывает половину работы, вторую половину закрывает готовый способ сделать правильно.

Агент обыгрывает и проверку

Второй уровень той же проблемы, и он неприятнее.

Если проверку соответствия придумывает тот же агент, который выполняет работу, он её и обыграет. Быстро пройдёт всё, что вы хотели проверить, и дальше займётся тем, чем хотел заниматься.


Формулировка из обсуждения звучала так: оно и саму проверку на соответствие сможет обыграть, если захочет.

Отсюда правило: проверку пишет не тот, кто выполняет. Либо человек, либо отдельный агент с отдельным заданием, либо, лучше всего, код.

Где проходит граница

Спор о том, что отдавать модели, а что коду, шёл долго и закончился внятным разграничением.

ЧТО ДЕЛАТЬ С ТРЕБОВАНИЕМ



Признаки того, что требование должно быть кодом:

Результат должен быть одинаковым всегда, а не почти всегда.

Нарушение обнаруживается не сразу, а через время.

Цена нарушения выше стоимости написания проверки.

Формулировка требования содержит слова всегда, никогда, обязательно.

Последний признак самый практичный. Если вы пишете в инструкции слово всегда, задумайтесь, почему это не код.

Форматы и контракты

Частный, но самый частый случай.

Формат ответа, описанный словами в запросе, нарушается примерно в одном случае из десяти. Это не лечится формулировкой, не лечится крупным шрифтом и не лечится большой моделью.

Разбор реального инструмента распознавания показал типичную ошибку: модель просят соблюдать формат, описанный прямо в тексте запроса. Работает, пока не перестаёт. Правильное решение это принуждение к структуре на уровне обвязки: либо структурированный вывод, если он доступен, либо разбор с повтором при неудаче.

Общая формулировка: модели оставляйте магию, всё, что требует надёжности, обеспечьте кодом. Контракт обеспечивает обвязка, а не абзац внутри запроса.

Архитектурные ограждения

Хороший приём, который недооценивают: часть архитектурных требований выражается линтером.

Не надо просить агента соблюдать слоистость. Надо сделать так, чтобы нарушение слоистости не проходило проверку.

Требование	Как выразить кодом
Модуль А не знает о модуле Б	Правило линтера на импорты
Ошибки не обрабатываются молча	Проверка на пустой перехват
Нет прямых обращений к базе из обработчиков	Правило на вызовы
Нет дублирования	Проверка на схожие фрагменты

Каждое такое правило разгружает и правила проекта, и внимание ревьюера. И работает независимо от того, какая модель сегодня и в каком она настроении.

Плохая обвязка обнуляет сильную модель

История, которая показывает обратную сторону: детерминированная часть может не только помогать, но и мешать.

Модель плохо справлялась с набором головоломок, показывая тринадцать процентов. Разбор показал, что дело не в модели, а в устройстве проверки: она стирала рассуждения после каждого хода и выбрасывала старые действия при переполнении. Модель начинала с нуля каждый ход.

Когда включили сохранение рассуждений и нормальное сжатие контекста, результат вырос до тридцати восьми процентов, а токенов понадобилось в шесть раз меньше.

ГЛАВНОЕ ПРО ОБВЯЗКУ И РЕЗУЛЬТАТ

Разница между тринадцатью и тридцатью восемью процентами это не модель, а две настройки окружения.

Прежде чем менять модель, проверьте, не мешает ли ей ваша собственная обвязка. Это самый дешёвый способ улучшить результат, и его почти никогда не делают первым.

Проверка результата без чтения кода

Приём, который уже упоминался в главе про ревью, но здесь он на своём месте, потому что это тоже способ забрать контроль у модели.

Попросите агента объяснить обычными словами поток исполнения: откуда данные, куда идут, где принимаются решения. Пересказ подделать трудно, потому что описывать придётся то, что реально написано.

Это не заменяет код-проверки, но закрывает то, что проверками не ловится: расхождение реализации с замыслом.

ЧТО ПЕРЕВЕСТИ В КОД НА СВОЁМ ПРОЕКТЕ

1. Выпишите из правил проекта все строки со словами всегда, никогда, обязательно.
2. Для каждой спросите: могу ли я написать проверку, которая отвечает да или нет?
3. Где можете, напишите и повесьте на событие.
4. Строку из правил после этого удалите. Две реализации одного требования расходятся.
5. Проверьте, что нарушение возвращает понятную ошибку в сессию, а не молчаливый отказ.

Что запомнить

Управление через правила ненадёжно: агент выполняет букву и нарушает смысл.

Запрет без предоставленного правильного пути порождает изобретательность, а не качество.

Проверку не должен писать тот, кого проверяют.

Слово всегда в инструкции это признак, что перед вами код, а не текст.

Формат, описанный словами, нарушается в одном случае из десяти и не лечится формулировкой.

Архитектурные требования выражайте линтером, а не просьбой.

И прежде чем менять модель, проверьте, не мешает ли ей ваша собственная обязанность.

Сколько полировать

Самый частый практический вопрос после первого месяца работы. Агент выдал результат. Вы прогнали ревью, он нашёл замечания. Исправили. Прогнали снова, нашёл ещё. Исправили. И так далее.

Когда останавливаться?

Прямой ответ практика

Один из самых опытных участников разговора ответил коротко: спецификацию полирую долго, а код не читаю вообще, он проверяется в бою.

Развёрнутый вариант выглядит так. Требования оформляются как поведенческие описания, код пишется от тестов. Дольше и дороже по расходу, зато не будет отчёта о готовности там, где половина кода даже не проверена.

С оговоркой, которую он же и произнёс: это по-прежнему лучший конвейер, но только если ревьюер слепой. То есть если проверяющий не видит, как код создавался, и судит по результату.

ГЛАВНОЕ ПРО КОНВЕЙЕР

Строгий конвейер покупает вам ровно одну вещь: вы не получите доклад о готовности там, где ничего не проверено.

Он не делает код лучше сам по себе. Он делает невозможным незаметный самообман. За это и платят временем и токенами.

Возражения, которые надо знать

Ни одна схема не универсальна, и в разговоре тут же прозвучали три возражения.

Экономическое. При текущем расходе лимитов хочется схему полегче: интеграционные проверки только на основные функции, остальное чинить по мере появления проблем.

Архитектурное. Когда полный набор функций ещё не ясен и архитектура не устоялась, прибавать её тестами не хочется. Каждое изменение решения означает переписывание тестов.

Историческое, самое едкое. Именно так баги и попадали в продакшн до всякого ИИ. А потом это стало нормой.

ТРИ ПОЗИЦИИ О ДОСТАТОЧНОСТИ

Строгая. Требования, исполняемые спецификации, код от тестов. Для системы с живыми пользователями и дорогой ошибкой.

Умеренная. Интеграционные проверки на главные сценарии, детали по мере появления проблем. Для развивающегося продукта, где архитектура ещё меняется.

Быстрая. Воспроизвели, починили, проверили локально, поехали. Для прототипов и внутренних инструментов, где цена ошибки близка к нулю.

Что определяет выбор. Не вкус, а две величины: цена ошибки и зрелость архитектуры.

Одного прогона не хватает никогда

Наблюдение, общее для всех трёх позиций.

Сколько бы вы ни готовились, после большого прогона нужна перепроверка в чистой сессии. Она находит недоработки всегда.

Практики описывают это так: слой за слоем, за две-три сессии доводится до полного выполнения. Ни одна модель не вывозит это идеально с первого раза, и надо сделать много итераций, чтобы понять, какого объёма задачи вообще имеет смысл давать.

Это не пессимизм, а рабочая настройка ожиданий. Вы не ждёте чуда, вы закладываете пару часов на доводку.


Где полировка начинает вредить

А теперь про обратную сторону, о которой говорят реже.

Честное признание практика, прошедшего этот путь: раньше после каждой задачи полировал пятнадцатью итерациями ревью и фиксов, и это раздувало проект вместо того, чтобы чинить то, что реально надо было починить.

Механика понятная. Ревьюер обязан что-то найти. Если очевидные проблемы кончились, он начинает находить неочевидные: добавить проверку, обработать краевой случай, вынести в отдельную функцию. Каждое замечание по отдельности разумно. Вместе они превращают простой код в сложный.

ЧТО ПРОИСХОДИТ С ПРОЕКТОМ ПРИ ИЗБЫТОЧНОЙ ПОЛИРОВКЕ



Причина, названная автором, не в скиллах и не в инструментах: слишком маленькая пропорция между вникнуть и делегировать. Когда вы не вникаете, вы не можете отличить нужное замечание от формального, и принимаете все.

Признаки, что пора остановиться

ПЯТЬ ПРИЗНАКОВ, ЧТО ПОЛИРОВКА КОНЧИЛАСЬ

1. Новые замечания касаются стиля, а не поведения.
2. Замечания повторяют друг друга в других словах.
3. Исправление одного замечания порождает новое в соседнем месте.
4. Вы не можете сформулировать, что сломается, если оставить как есть.
5. Объём кода растёт, а число закрытых требований не меняется.

Пятый признак самый надёжный и легко измеряется. Если между итерациями прибавляется код и не прибавляется закрытых требований, вы полируете, а не улучшаете.

Обязательный шаг схлопывания

Приём, который решает проблему раздувания и почти всегда забывается.

После нескольких итераций полировки делается отдельный проход с обратной задачей: убрать то, чторосло. Дублирование, защитные проверки, ставшие ненужными, обходные пути, потерявшие смысл.

Формулировка запроса важна: не улучши, а сожми без потери поведения. Иначе агент опять начнёт добавлять.

Есть более радикальная версия того же приёма, которая заодно улучшает качество: попросить сжать результат в несколько раз, сохранив функциональность. Практики отмечают, что при таком запросе код получается заметно продуманнее, потому что модели приходится думать, а не наращивать.

Переусложнение как отдельный диагноз

Смежное наблюдение, которое стоит держать рядом.

Больше написать не значит больше решить. Модель по умолчанию склонна к развесистым решениям: слои, абстракции, конфигурируемость на случай будущих требований, которых не будет.

Полезный сигнал, замеченный практиками: если самые сильные модели два раза подряд находят в вашем решении настоящие проблемы, скорее всего задача переусложнена. И, возможно, для неё уже есть готовое проверенное решение, которое дешевле поискать.

ГЛАВНОЕ ПРО ОСТАНОВКУ

Правило, которым можно пользоваться: полируйте, пока замечания меняют поведение. Как только они начали менять форму, останавливайтесь и делайте проход схлопывания.

И держите в голове, что универсального ответа на этот вопрос у практиков нет. Это одно из мест, где опыт не заменяется правилом.

Что запомнить

Спецификацию полируйте долго. Код проверяйте, а не читайте, если у вас есть чем проверить.

Строгий конвейер покупает не качество, а невозможность незаметного самообмана.

Выбор схемы определяется ценой ошибки и зрелостью архитектуры, а не вкусом.

Одного прогона не хватает никогда. Закладывайте перепроверку в чистой сессии.

Полировка начинает вредить, когда замечания меняют форму, а не поведение.

Обязательно делайте проход схлопывания и формулируйте его как сжатие, а не как улучшение.

И если сильные модели дважды находят настоящие проблемы, проверьте, не переусложнена ли задача.

Модуль 7. Автономность

Четыре главы о работе без человека рядом.

Как готовить ночной прогон, почему агент уезжает с рельсов, что на самом деле делает автономный режим и чем постоянно работающий агент отличается от рабочего инструмента.

Модуль про то место, где обещания расходятся с практикой сильнее всего.

Ночной прогон

Самая соблазнительная картинка в этой области: вы даёте агенту задачу вечером, ложитесь спать, утром смотрите результат.

Картинка рабочая. Но ночной прогон это не команда, а результат дня подготовки, и вот как этот день выглядит.

Полная методика

Разбор, который один из практиков описал по шагам на своей настоящей задаче.

Шаг первый: ревью. Днём прогоняется ревью текущего состояния сильной моделью. Получено тридцать замечаний, три критичных, остальные мелкие. Все записаны в файл.

Шаг второй: оптимизация. Отдельно прорабатывается расход: по каждому шагу агента обсуждается, что сделать, чтобы контекст не раздувался и токены не жглись впустую. Тоже в файл.

Шаг третий: перенос схемы. Обсуждается, как отработанную схему одного режима работы перенести на остальные. Шаги переиспользуются, встраиваются в другие процессы. Схемы записаны.


Шаг четвёртый: свод. К вечеру в двух файлах на тысячу и полторы тысячи строк накопились три заготовки: починка ошибок, оптимизация основного режима, план на остальные.

Шаг пятый: план. Модель просят разложить это в план с подробностями, что и как чинить. Получается ещё полторы тысячи строк. Итого около четырёх тысяч строк рабочих материалов.

Шаг шестой: запрос. Модель просят написать подробный запрос на реализацию. Что учесть, какие документы перечитывать в любом случае, как себя вести без человека.

Шаг седьмой: запуск. Всё это отдаётся агенту, человек уходит спать.

ДЕНЬ ПЕРЕД ПРОГОНОМ



Что обязательно сказать в запросе

Это самая ценная часть главы, потому что перечисленное почти никогда не приходит в голову с первого раза.

ЗАПРОС НА АВТОНОМНЫЙ ПРОГОН

Работай по плану, который лежит в файле такого-то.

Меня нет за компьютером. Ничего не спрашивай, решения принимай сам, но записывай их.

Веди прогресс прямо в плане: отмечай выполненное, помечай то, что заблокировано, и пропускай такие пункты, а не останавливайся на них.

Иди в том порядке, который задан планом, до конца списка.

Перед каждым пунктом перечитывай спецификацию и файл с решениями, независимо от того, помнишь ты их или нет.

Если пункт не закрывается по критериям после трёх попыток, помечай его как заблокированный, записывай причину и переходи к следующему.

В конце оставь отчёт: что сделано, что заблокировано и почему, что осталось.

Пункт про блокировку критичен. Без него агент упрётся в первую же непроходимую задачу и потратит на неё всю ночь.

Пункт про перечитывание тоже: после сжатия контекста агент забудет спецификацию, а прогон почти наверняка переживёт несколько сжатий.

Более дисциплинированная схема

Есть альтернатива, которая даёт меньше свободы и меньше сюрпризов.

Вместо того чтобы дать план целиком, агенту говорят: возьми спецификацию, перед выполнением составь план ровно на один пункт, напиши тесты, потом код. Критерии успешности лежат в спецификации в разделе готовности. Пока критерии не закрыты, к следующему пункту не приступай.

Практик, который перешёл на эту схему, отметил побочный эффект: она заодно лечит склонность к переусложнению. Когда горизонт один пункт, придумывать архитектуру на вырост негде.

ВСЁ ПЛАН ИЛИ ПО ОДНОМУ ПУНКТУ

Весь план. Агент видит картину целиком, может переставить порядок, если так разумнее, и не тратит ходы на планирование каждого шага.

По одному пункту. Меньше свободы уехать, меньше переусложнения, легче разбираться утром, потому что каждый пункт закрыт или явно заблокирован.

Практический признак. Если утром вы обнаруживаете сделанным не то, что просили, переходите на схему по одному пункту.

Чекпоинты

Дополнение, которое сильно повышает предсказуемость: чекпоинты прямо в спецификации, на каждом шаге.

Чекпоинт это проверяемое состояние: после третьего пункта в системе должно быть вот это, проверяется вот так. Агент, дойдя до чекпоинта, проверяет и записывает результат.

Утром вы читаете не код, а список чекпоинтов и сразу видите, где всё пошло не туда.

Что происходит при исчерпании лимита

Практическая деталь, о которой узнают в первую же ночь.

Прогон останавливается посреди работы. Хорошая новость: если у вас есть файл прогресса, продолжение возможно. Плохая: если состояние жило только в контексте, всё потеряно.

Отсюда правило: файл прогресса на диске это не удобство, а страховка. Он переживает и сжатие, и обрыв, и исчерпание лимита.

Сколько это стоит

Чтобы представление было честным, вот замер с реального переноса проекта на строгую типизацию.

Двенадцать часов исполнения плюс полтора часа подготовки и планирования. По счётчикам: около восьми миллионов токенов на двух машинах, в среднем триста тридцать тысяч токенов в час, суммарное машинное время почти шестнадцать часов. Эквивалент по прейскуранту около ста восьмидесяти пяти долларов.

И честная приписка автора: теперь неделю ловить баги там, где их не было.

ГЛАВНОЕ ПРО НОЧНЫЕ ПРОГОНЫ

Ночной прогон не экономит вашу работу, он её сдвигает. Вместо того чтобы работать днём с агентом, вы работаете днём над постановкой, а агент работает ночью.

Суммарно времени тратится не меньше. Тратится оно иначе: на подготовку и на разбор, а не на ожидание ответа.

Когда не стоит

Три случая, когда ночной прогон принесёт больше вреда, чем пользы.

Архитектура не устоялась. Ночью агент примет десятки решений. Если фундамент ещё меняется, утром вы получите здание не на том фундаменте.

Нет способа проверить. Без проверок вы утром получите доклад о готовности и не сможете его оценить.

Полные права в незнакомой системе. Крайний случай из практики: человек оставил агента на ночь с полными правами и утром получил совсем другой проект.

Что запомнить

Ночной прогон это результат дня подготовки, а не команда.

В запросе обязательно: человека нет, писать прогресс в план, пометать заблокированное и пропускать, идти по порядку, перечитывать спецификацию перед каждым пунктом.

Схема по одному пункту даёт меньше сюрпризов и лечит переусложнение.

Чекпоинты в спецификации позволяют утром читать не код, а список состояний.

Файл прогресса на диске это страховка от сжатия, обрыва и лимита.

И закладывайте время на разбор после. Работа не исчезает, она сдвигается.

Дрейф намерения

Вы поставили задачу. Агент начал правильно. Через час он делает не то. Через три часа он делает что-то своё, и формально даже разумное.

Это называется дрейфом, и это главная причина, по которой длинные автономные прогоны разочаровывают.

Намерение распадается нелинейно

Есть исследование, посвящённое именно этому, и его выводы стоит знать точно.

Проверяли, насколько агент удерживает исходное намерение по мере роста двух величин: числа ограничений в задаче и длины сессии.

Главный результат: намерение распадается нелинейно. До какого-то момента всё держится, потом качество падает быстро. Добавление ограничений ускоряет распад: чем больше условий вы поставили, тем раньше начнётся дрейф.

ГЛАВНОЕ ПРО ДРЕЙФ

Чем больше ограничений вы навесили, тем быстрее агент от них уедет.

Это переворачивает интуицию. Кажется, что подробная инструкция удержит его лучше. На деле каждое дополнительное условие увеличивает нагрузку на удержание, и в какой-то момент система срывается.

Вывод практический: лучше три условия, которые проверяются автоматически, чем пятнадцать, которые проверять нечем.

Парадокс уточнения

Второй результат того же исследования, ещё более неприятный.

Когда агент оказывался в ситуации неопределённости, где правильным действием был уточняющий вопрос, подавляющее большинство агентов предпочитали рискованное действие вопросу.

Логика понятная. Агент обучен закрывать задачи. Уточняющий вопрос это остановка, а действие это движение к цели. Поэтому он действует.

Следствие для практики: если вы хотите, чтобы агент спрашивал, недостаточно разрешить ему спрашивать. Надо сделать вопрос обязательным в конкретных ситуациях, желательно проверкой, а не просьбой.

Формулировка, которая лечит половину случаев

Самая практичная находка во всём корпусе, и она в одну строку.

СТРОКА, КОТОРУЮ СТОИТ ВСТАВИТЬ В КАЖДЫЙ ЗАПРОС

Работаем по документации и фактам, а не по памяти. Перед любым выводом опираемся и ссылаемся на источник.

Человек, который это придумал, описывал результат так: восемь часов непрерывной работы, собран целиком рабочий процесс из тринадцати шагов, и после первого же запуска всё завелось.

Почему это работает, понятно из механики модели. Требование сослаться на источник заставляет её обращаться к файлам, а не к воспоминаниям. А дрейф чаще всего начинается именно там, где агент решил, что и так помнит.

Более ранняя версия той же формулировки звучала проще: работаем по фактам, а не по предположениям. Тоже помогает, но слабее, потому что не требует ссылки.

Как выглядит начало дрейфа

Полезно уметь ловить его рано, пока правка дешёвая.

Признак	Что происходит
Появились слова вероятно, скорее всего, обычно	Агент перешёл на память вместо источников
Пересказ задачи стал короче исходного	Часть условий выпала
Начал решать соседнюю задачу	Исходная показалась ему решённой
Ссылается на своё же предыдущее решение как на данность	Ошибка закрепилась
Отчёты стали общими	Конкретика ушла, потому что её нет

Последний признак самый надёжный. Как только отчёты становятся обтекаемыми, работа ушла в сторону.

Две позиции о том, насколько это лечится

Спор, который шёл долго и оба участника которого правы в своих условиях.

Скептик. Деградация после сжатия контекста накапливается. Пример из практики: проект, где агент сам поднимал окружение всю неделю, вдруг заявляет, что окружения нет и надо поднять его вручную, а после напоминания соглашается и поднимает. Вывод: оставил на ночь и получил готовый продукт это неправда. Оно может работать, но сделано мимо спецификации, и придётся переделывать.

Практик. Это работает как постепенное проявление. Прогон за прогоном из ничего возникает осмысленное, потом подключаешься и добавляешь детали, которые не были очевидны ни тебе, ни модели. Заявленный рабочий предел на момент разговора: около десяти-пятнадцати часов автономной работы по спецификации без заметного дрейфа.

КТО ИЗ НИХ ПРАВ

Оба, и различает их одно: наличие спецификации с проверками.

Скептик описывает прогон, где спецификация есть, а автоматических проверок нет. Там дрейф обнаруживается постфактум.

Практик описывает прогон, где на каждом пункте есть критерии готовности. Там дрейф обнаруживается в момент возникновения.

Разница не в моделях и не в удаче, а в том, есть ли у агента способ узнать, что он уехал.

Что удерживает на самом деле

Сводка приёмов, расположенных по убыванию эффективности.

Проверки на каждом пункте. Самое сильное. Агент не может уехать дальше пункта, критерии которого не закрыл.

Требование ссылаться на источник. Одна строка, лечит половину случаев.


Короткий горизонт. План на один пункт вместо всего плана.

Файл прогресса. Не удерживает, но позволяет обнаружить и вернуть.

Хук на перечитывание после сжатия. Восстанавливает то, что потерялось.

Периодическая перепроверка в чистой сессии. Ловит то, что просочилось.

ЧТО ПРОИСХОДИТ БЕЗ УДЕРЖАНИЯ



Что повторилось трижды, паковать в скилл

Отдельный приём, который снижает дрейф на длинной дистанции.

Всё, что вам пришлось объяснить агенту больше трёх раз, надо оформить в скилл. Тогда даже на очень длинных контекстах он не забывает важные вещи, потому что скилл подгружается заново, а не хранится в истории.

Это простой способ вынести знание из тающего контекста в постоянное хранилище.

Что запомнить

Намерение распадается нелинейно, и лишние ограничения ускоряют распад.

Агенты предпочитают рискованное действие уточняющему вопросу. Хотите вопросов, делайте их обязательными.

Одна строка про работу по документации и ссылки на источник лечит половину случаев.

Ловите ранние признаки: слова про вероятно, укоротившийся пересказ, обтекаемые отчёты.

Разница между разочарованием и рабочей автономией это наличие критериев готовности на каждом пункте.

И то, что объяснили трижды, выносите в скилл.

Автономный режим: что он реально делает

У большинства инструментов есть режим, в котором вы задаёте цель, а агент работает до её достижения. Вокруг него больше всего мифов, поэтому разберём, что там внутри.

Что происходит на самом деле

Разочаровывающий, но полезный ответ, полученный при разборе: по сути это проверяющий завершения.

Работает так. Вы формулируете цель. Агент работает обычным образом. После каждого крупного шага отдельная проверка спрашивает: цель достигнута? Если нет, работа продолжается. Если да, режим завершается.

Никакой особой магии, никакого специального планировщика, никакой отдельной архитектуры. Цикл плюс проверка завершения.

ГЛАВНОЕ ПРО АВТОНОМНЫЙ РЕЖИМ

Качество автономного режима это качество проверки завершения, а не качество агента.

Отсюда все его беды. Если проверка нестрогая, агент объявит цель достигнутой, когда устанет. Если проверка формальная, он подгонит под неё результат. Если критерий сформулирован размыто, вы получите что угодно.

Это же объясняет самую частую жалобу. Практики описывали её так: у агента постоянно ломается проверка завершения, потому что задачу он недоделал, но подал свой ответ так, будто уже всё идеально, а что не идеально, то и недостижимо. И проверка это проглатывает.

Формулировка цели решает всё

Из устройства следует практика: цель формулируется как проверяемое состояние, а не как пожелание.

ЦЕЛЬ, КОТОРАЯ НЕ РАБОТАЕТ

Улучши обработку ошибок в модуле оплаты

Проверка завершения не сможет ответить да или нет. Агент закроет режим, когда сочтёт нужным.

ЦЕЛЬ, КОТОРАЯ РАБОТАЕТ

Все внешние вызовы в модуле оплаты обёрнуты повтором с ограничением, каждая ветка ошибки покрыта тестом, тесты проходят, в журнале появляются записи с кодом ошибки

Каждое условие проверяемо. Проверка завершения работает как настоящий шлюз.

Сколько реально работает

Замеры, которые называли практики, чтобы представление было честным.

Один прогон продолжался несколько суток, останавливался при исчерпании лимита и продолжался после сброса. Итог: результат был, но объём переделок после оказался значительным.

Другой, на переносе проекта, шёл двенадцать часов и закончился рабочим результатом с недельным хвостом отлова ошибок.

Заявленный рабочий предел без заметного дрейфа, о котором говорили в главе про дрейф: около десяти-пятнадцати часов при наличии критериев на каждом пункте.

Есть и обратный пример. Один из практиков, экспериментировавших с полностью автономным режимом на больших задачах, сказал прямо: перестал использовать его для больших задач, быстрее и дешевле декомпонировать самому.

АВТОНОМНЫЙ РЕЖИМ НА БОЛЬШИХ ЗАДАЧАХ

За. Он работает, пока вы спите, и суммарное время до результата меньше, даже с учётом переделок.

Против. Декомпонировать самому быстрее и дешевле. Автономия окупается только на задачах, которые вы не можете или не хотите разбивать.

Практический критерий. Можете разбить за полчаса? Разбейте. Не можете, потому что не знаете, из чего задача состоит? Тогда автономный проход как разведка, а не как исполнение.

Шесть отказов, которые обвязка обязана поймать

Список, собранный из практики. Это то, что должно вылавливаться автоматически, потому что человека рядом нет.


Отказ	Как выглядит	Чем ловится
Ложная готовность	Доклад о завершении при незакрытых критериях	Проверка критериев, а не доклада
Тихое упрощение	Задача решена не так, как требовалось	Проверка на запрещённые приёмы
Хождение по кругу	Одно и то же действие повторяется	Счётчик повторов одинаковых вызовов
Расползание задачи	Агент делает соседнюю работу	Сверка изменений с областью задачи
Молчаливая ошибка	Сбой перехвачен и не показан	Проверка на пустые перехваты
Исчерпание бюджета	Расход растёт, прогресс нет	Потолок на задачу и сравнение с прогрессом

Последняя строка часто спасает больше денег, чем все остальные вместе.


Две ленты

Полезно представлять автономный прогон как две параллельные ленты.

ЧТО ВИДИТ ЧЕЛОВЕК



ЧТО ПРОИСХОДИТ ВНУТРИ



Вся инженерия автономного режима сводится к тому, чтобы вторая лента оставляла следы, читаемые утром. Файл прогресса, чекпоинты, журнал решений.

Проверка на самообман

Отдельный приём для тех, кто уже обжёгся.

Утром, прежде чем читать отчёт, задайте агенту в чистой сессии три вопроса, не показывая его собственный отчёт.

УТРЕННЯЯ ПРОВЕРКА

1. Возьми спецификацию и текущее состояние кода. Перечисли пункты, критерии которых сейчас не выполняются.
2. Перечисли места, где реализация отличается от того, что описано в спецификации.
3. Найди решения, принятые без явного указания в спецификации, и перечисли их.

Чистая сессия здесь принципиальна: агент, который писал отчёт, будет его защищать, потому что помнит, почему так сделал.

Что запомнить

Автономный режим это цикл плюс проверка завершения. Магии нет.

Качество режима это качество проверки завершения.

Цель формулируйте как проверяемое состояние, а не как пожелание.

Рабочий предел без дрейфа порядка десяти-пятнадцати часов, и только при критериях на каждом пункте.

Если задачу можно разбить самому за полчаса, разбейте. Автономия для того, что вы разбить не можете.

Шесть отказов должны ловиться автоматически, потому что человека рядом нет.

И утром проверяйте не отчёт агента, а состояние системы, в чистой сессии.

Постоянно работающий агент

До сих пор речь шла об агенте, которого вы зовёте, когда нужна работа. Есть второй класс: агент, который живёт постоянно и сам решает, когда что-то сделать.

Различие принципиальное, и путать их дорого.

Верстак и дом

Метафора, которая закрепились в разговорах.

Верстак. Вы подошли, взяли инструмент, сделали работу, ушли. Агент существует ради задачи, у него нет своей жизни между вызовами. Сюда относятся кодовые агенты, помощники по документам, всё, что вы запускаете под задачу.

Дом. Он есть, даже когда вас нет. У него своё состояние, свои дела, своё расписание. Он замечает изменения и реагирует. Сюда относятся личные ассистенты, дежурные, мониторинг, всё, что работает в фоне.

Свойство	Верстак	Дом
Когда работает	Когда вызвали	Всегда
Откуда берёт задачи	От вас	Сам
Что с состоянием между запусками	Ничего	Всё
Главный риск	Сделал не то	Не заметил или отреагировал не туда
Что важнее всего	Качество результата	Качество внимания

ГЛАВНОЕ ПРО ДВА КЛАССА

Верстак проверяется по результату. Дом проверяется по тому, на что он обратил внимание и на что не обратил.

Это разные метрики и разная инженерия. Хороший кодовый агент, поставленный работать постоянно, превращается в генератор шума, потому что у него нет механизма решать, что важно.

Пять точек проектирования

Разбор, который лучше всего описывает, из чего собирается постоянно работающий агент. Пять пунктов, каждый закрывает свой провал.

1. Генератор бесконечной работы. Нужны детерминированные показатели, по которым видно, есть работа или нет. Без них агент всегда может сказать, что всё хорошо, и остановиться. И скажет, потому что это дешево.

2. Система восприятия. Пассивное наблюдение отделяется от триггеров реакции. Агент постоянно смотрит, но реагирует не на всё.

Ключевая идея: триггер строится на нарушении ожидания, а не на пороге метрики. Порог даёт шум, потому что нормальные колебания его пересекают. Нарушение ожидания означает, что случилось то, чего по вашей модели мира происходить не должно.


3. Организационная память. Хранит три вещи: источник, интерпретацию и рамку, в которой эта интерпретация сделана.

Третий элемент обычно теряют, и зря. Без рамки вывод протухает молча: вы помните, что решение было принято, но не помните, при каких условиях, и продолжаете им пользоваться, когда условия изменились.

4. Много мозгов, которые спорят. И большинство из них люди. Постоянно работающий агент не должен быть единственным источником суждения о том, что происходит.

5. Переиспользование существующих процедур. Бюрократические процедуры в организациях созданы ровно для решения проблемы ненадёжного исполнителя. Согласования, сверки, отчётность. Агент это ненадёжный исполнитель, и все эти механизмы к нему применимы без изобретения новых.

АРХИТЕКТУРА ДОМА



Почему триггер по порогу не работает

Стоит остановиться, потому что это самая частая ошибка.

Порог выглядит просто: если значение выше такого-то, зови. На практике вы получаете либо шквал ложных срабатываний, либо пропуск настоящих проблем, потому что нормальное поведение системы не описывается одним числом.

Нарушение ожидания устроено иначе. Вы описываете, чего ждёте: в это время дня нагрузка примерно такая, эти отчёты приходят по понедельникам, этот показатель растёт медленно. Триггер срабатывает, когда наблюдение расходится с ожиданием.

Побочная польза: описав ожидания, вы обнаружите, что половину из них не знали.

Связка из двух агентов

Схема, которая работает у практиков и стоит отдельного упоминания.

Один агент наблюдает и формулирует. Второй исполняет. Между ними формализованная передача: не разговор, а структурированное задание.

Смысл в разделении внимания и действия. Наблюдающий не отвлекается на исполнение, исполняющий не отвлекается на наблюдение. И, что важнее, между ними появляется точка,

где можно поставить человека.

НУЖЕН ЛИ ЧЕЛОВЕК В ЦИКЛЕ ПОСТОЯННО РАБОТАЮЩЕГО АГЕНТА

Да, всегда. Полностью автоматические системы регулярно проваливаются, и чем дольше работают, тем вероятнее. Подтверждение действия человеком это дешёвая страховка.

Нет, иначе теряется смысл. Если на каждое действие нужно подтверждение, вы получили не агента, а уведомления с кнопкой.

Рабочий компромисс. Разделить действия на обратимые и необратимые. Обратимые агент делает сам и записывает. Необратимые требуют подтверждения. Список необратимых составляется заранее и пересматривается.

Что реально поручают

Чтобы разговор не был абстрактным, вот список задач, ради которых постоянно работающих агентов действительно держат.

Сводка дня: дела, напоминания об оплатах, курсы, новости по интересующим темам.

Разбор входящей почты и приведение в порядок облачных дисков.

Учёт финансов, коммунальные платежи, регулярные расходы.

Заметки после встреч: расшифровка, выделение решений, напоминания.

Мониторинг: заметил изменение, сформулировал, спросил.

Ежедневный разбор одной темы из области, в которой вы работаете.

Список бытовой, и это правильно: постоянно работающий агент оправдывает себя на рутине, а не на подвигах.

Чего ждать по надёжности

Честная картина. Постоянно работающий агент ломается тише, чем верстак.

Кодовый агент, сделавший ерунду, виден сразу: код не собирается. Постоянно работающий агент, переставший замечать важное, не виден вообще, потому что отсутствие сообщений выглядит как отсутствие проблем.

ПРОВЕРКА ЖИВОСТИ

1. Заведите проверку, которая срабатывает, если агент долго молчит. Молчание должно быть событием.
2. Раз в неделю подсовывайте ему заведомо значимое изменение и смотрите, заметит ли.
3. Ведите журнал того, о чём он сообщил, и раз в месяц сверяйте с тем, что действительно происходило.
4. Отдельно отмечайте, о чём он не сообщил, а стоило. Это и есть материал для настройки ожиданий.

Что запомнить

Два класса агентов: верстак и дом. Разные метрики, разная инженерия.

Дому нужен генератор работы с детерминированными показателями, иначе он всегда скажет, что всё хорошо.

Триггер стройте на нарушении ожидания, а не на пороге метрики.

Память должна хранить источник, интерпретацию и рамку интерпретации.

Разделите действия на обратимые и необратимые. Вторые с подтверждением.

Молчание должно быть событием, иначе вы не заметите, что агент перестал работать.

Модуль 8. Люди и компании

Четыре главы о том, что происходит, когда агентов становится много, а людей столько же.

Что реально получилось у команд, почему внедрение упирается в неявное знание, во что превращается хранилище скиллов через полгода и что теперь делает разработчик.

Модуль для тех, кто отвечает не только за себя.

AI-first процессы

Про переход компании на работу с агентами говорят много и в основном на конференциях. Эта глава про то, что действительно получилось у команд, которые прошли через это, и что не получилось.

Что получилось

Два места, где выигрыш признают все.

Ревью кода. Первый и самый бесспорный. Агент, который отписывается по каждому изменению, разгружает людей и не устаёт. Один из практиков сформулировал так: если бы у нас не сделали агента-ревьюера, мы бы уже жили в аду, назад возврата нет.

Написание кода по готовой постановке. Второе бесспорное. Когда задача сформулирована, реализация перестала быть узким местом.

Что не получилось

А теперь честная часть, которую редко произносят вслух.

Главное, чего не удалось никому из тех, кто об этом говорил: подняться с уровня написания задач до уровня проектирования продуктовых требований, отдав всё остальное агентам.

Формулировка одного из руководителей разработки: есть вещи, где очень хорошо получилось, например ревью и написание кода. Но есть то, что мы ещё не осилили, и самое главное это подняться с уровня написания задач до уровня только проектирования требований, а всё остальное пусть делают агенты в фоне. Когда осилим, напишем пост.

И его же вывод: рассказать и сделать это две разные вещи, и получилось у единиц из тех, кто про это рассказывает.

ГЛАВНОЕ ПРО ПЕРЕХОД

Разрыв между демонстрацией и рабочим процессом больше, чем кажется по докладам.

Демонстрация показывает лучший случай на подготовленной задаче. Процесс должен работать на худшем случае в понедельник утром, когда горит бэклог.

Ловушка, из-за которой всё стоит

Самое честное объяснение, почему переход буксует, звучало как анекдот. Почему пилу не точишь? Времени нет, пилить надо.

Механика простая. У команды есть очередь задач, которая горит. Есть идеи, как перестроить процесс, и они требуют времени. Времени нет, потому что задачи горят. Задачи горят, потому что процесс не перестроен.

Выход из этой петли всегда один: выделенное время, защищённое от текущих задач. Не остаток, не по вечерам, а явно отведённые часы.


Прототип вместо задания

Изменение, которое произошло само и оказалось самым заметным.

В командах, которые продвинулись дальше других, руководитель перестал описывать словами то, что хочет получить. Он берёт конструктор, собирает рабочий процесс сам и показывает прототип. И говорит: сделайте мне это агентами и в прод.

Формулировка автора: уровень абстракции сместился настолько, что само техническое задание теперь и есть рабочий проект, только в миниатюре. Собрать прототип быстрее, чем писать длинный документ.

КАК ИЗМЕНИЛАСЬ ПОСТАНОВКА ЗАДАЧИ



Побочный эффект оказался важнее основного: споров о том, что имелось в виду, стало заметно меньше. Из текста каждый вычитывает своё, из работающей миниатюры вычитывать нечего.

Агент у каждого, а не только у разработчиков

Второе изменение, которое отмечали как самое полезное.

В одной из команд каждый сотрудник, независимо от должности, собирает себе агента, который разгребает рутину вокруг его рабочего места. Даже те, кто далёк от разработки.

Результат: разработчиков перестали дёргать по мелочам. К ним приходят только за полнофункциональными решениями, а прототипы для клиентских презентаций собирают сами продавцы.

СТОИТ ЛИ ДАВАТЬ АГЕНТОВ ВСЕМ


За. Мелкие задачи перестают доходить до разработчиков. Люди сами закрывают то, что раньше ждало неделю в очереди.

Против. Появляется теневая инфраструктура: десятки самодельных агентов, о которых никто не знает, с доступами, которые никто не проверял.

Что делают на практике. Разрешают, но с двумя ограничениями: доступ только к своим данным и явный список того, чего агент делать не может. Про это отдельный модуль.

Полный конвейер

Как выглядит процесс у тех, кто дошёл дальше всех.

КОНВЕЙЕР ОТ ИДЕИ ДО ПРОДА

Ключевая деталь: границы сужаются от шага к шагу. К моменту написания кода свободы почти не остаётся.

Вторая ключевая деталь: вертикальные срезы вместо слоёв. Не сначала все интерфейсы, потом вся логика, а один сквозной кусок функциональности целиком, потом следующий. Так каждый срез проверяем.

Почему выигрыш не виден в отчётности

Наблюдение, которое объясняет скепсис руководства.

Скорость разработки выросла, а выручка не выросла. Причина не в том, что агенты не работают, а в том, что разработка редко была узким местом. Она была видимым местом.

Если решения принимаются три недели, согласование идёт месяц, а требования меняются в процессе, ускорение реализации в три раза даёт общее ускорение на несколько процентов.

Отсюда практический совет тем, кто внедряет: измеряйте не скорость написания кода, а время от идеи до пользователя. Первое вырастет сразу, второе покажет, где на самом деле узкое место.

С ЧЕГО НАЧАТЬ ПЕРЕХОД В КОМАНДЕ

1. Найдите один процесс, который повторяется еженедельно и всех раздражает.
2. Автоматизируйте только его, целиком, до конца. Не половину десяти процессов.
3. Измерьте время от идеи до пользователя до и после.
4. Если оно не изменилось, узкое место не там, и следующий шаг делается в другом месте.
5. Только после этого расширяйтесь.

Что говорят про горизонт

Мысль, которой заканчивались многие разговоры на эту тему.

Разработка превращается в иерархию циклов. Инженеры спускаются вниз, в циклы нижнего уровня, чтобы отладить и повысить надёжность. Поднимаются вверх, чтобы построить более удачные процессы.

И самая ценная человеческая работа при этом заключается в решении о том, какие циклы вообще создавать.

Что запомнить

Бесспорно получилось: ревью кода и написание кода по готовой постановке.

Не получилось почти ни у кого: полностью подняться на уровень требований, отдав остальное агентам.

Ловушка петли: времени на перестройку нет, потому что задачи горят.

Прототип вместо документа снимает споры о том, что имелось в виду.

Агент у каждого сотрудника разгружает разработку и создаёт теневую инфраструктуру. Оба следствия реальны.

Измеряйте время от идеи до пользователя, а не скорость написания кода.

И держите в голове, что главная работа теперь это решать, какие циклы создавать.

Внедрение и неявное знание

Почему проекты по автоматизации с агентами проваливаются? Ответ есть, он неприятный и почти всегда один и тот же.

Люди не могут рассказать, как они работают

Формулировка, которая объясняет большую часть провалов: люди не могут рассказать, как именно делают свою работу. Агенту, как и новому сотруднику, нужен онбординг, а не инструкция.

Механика знакома всем, кто когда-либо писал регламент. Вы просите эксперта описать процесс. Он описывает: сначала это, потом то, потом отправляем. Вы автоматизируете. Не работает.

Выясняется, что он ещё смотрит на дату, потому что до пятнадцатого числа считается иначе. И на источник, потому что от одного контрагента данные приходят с задержкой. И вообще если сумма подозрительная, он звонит и уточняет. Ничего из этого он не назвал, потому что для него это не шаги, а само собой разумеющееся.

ГЛАВНОЕ ПРО НЕЯВНОЕ ЗНАНИЕ

Эксперт не скрывает знание. Он его не осознаёт.

Поэтому опрос эксперта не работает как способ сбора требований. Работает наблюдение за работой и разбор конкретных случаев, особенно нетипичных.

Почему бизнес-агенты не взлетают

Прямое следствие. Технически собрать агента для бизнес-процесса несложно: модель есть, инструменты есть, интеграции есть.

Не хватает доменного знания. Того самого, которое живёт в головах и не записано нигде.

Отсюда закономерность, которую отмечали многократно: агенты хорошо заходят там, где предметная область формализована и правила записаны. И плохо там, где всё держится на опыте конкретных людей.

Как собирать знание

Приёмы, которые работают лучше опроса.

Разбор конкретных случаев. Не как вы обычно делаете, а вот этот случай на прошлой неделе, расскажите по шагам. В конкретике всплывают исключения.


Наблюдение с вопросами. Смотрите, как человек работает, и спрашивайте, почему он сейчас сделал именно так. Половина ответов будет вида ну потому что тут особый случай.

Итеративная сверка. Собрали версию, показали, получили список из десяти замечаний вида тут надо брать справочник из другой системы, там устаревшие данные, но нигде про

это не написано. Исправили, показали снова.

Третий приём описывали как самый ценный результат целого проекта: перегнать данные из одного формата в другой, и вся ценность оказалась в итеративном допиливании с одним экспертом, который на каждой версии говорил, что не так.

КАК СОБИРАЕТСЯ ДОМЕННОЕ ЗНАНИЕ



Циклов обычно три-пять. После третьего список исключений начинает укорачиваться, и это признак, что вы близко.

Соппротивление

Вторая большая причина провалов, и разговор о ней в корпусе шёл без иллюзий.

Мотивы сопротивления называли разные, и почти все рациональные.

Мотив	Что за ним стоит
Страх за место	Часто обоснован, и отрицать это бессмысленно
Недоверие к результату	Человек видел, как модель уверенно ошибается
Нежелание учиться заново	Освоенный навык обесценивается
Защита экспертизы	Знание было источником влияния
Усталость от инициатив	Предыдущие три тоже обещали революцию

Последний мотив недооценивают. В компании, где за пять лет было четыре трансформации, пятая воспринимается как погода.

Позиция, к которой приходят

Практик, который пытался внедрять и перестал, описал это так: чувствуешь себя проповедником в племени, которое ждёт обеда. Компания должна созреть сама, а идти против ветра бесполезно, рынок всё расставит.

ПРОПОВЕДОВАТЬ ИЛИ ЖДАТЬ

Проповедовать. Кто-то должен показать, что это работает. Без первого примера созревание не начнётся.

Ждать. Убеждать людей, у которых нет своей причины меняться, это выгорание. Дождитесь того, у кого есть проблема, решите её, и остальные придут сами.

Что работает на практике. Второе, с одной поправкой: у вас должен быть готовый показ на пятнадцать минут для того момента, когда кто-то придёт сам. Без него момент пройдёт.

Что показывать

Отдельный вопрос: как выглядит показ, после которого человек хочет попробовать.

Не работает: демонстрация того, как агент пишет код. Для нетехнического человека это выглядит как магия, к которой он не имеет отношения.

Работает: его собственная рутина, сделанная за минуту. Его отчёт, его почта, его таблица.

Ещё лучше работает то, что человек делает сам, но плохо. Тексты для тех, кто не любит писать. Разбор данных для тех, кто боится таблиц.

ПЯТНАДЦАТИМИНУТНЫЙ ПОКАЗ

1. Заранее спросите, что человек делает еженедельно и что раздражает.
2. Возьмите его настоящие данные, а не пример.
3. Покажите результат, а не процесс. Процесс покажете, если спросит.
4. Обязательно покажите одну ошибку модели и как вы её ловите. Иначе доверие будет ложным и разрушится на первой же неудаче.
5. Закончите тем, что он попробует сам прямо сейчас, а не потом.

Четвёртый пункт важнее остальных. Показ без ошибок создаёт ожидание безошибочности, а первая же ошибка после этого обесценивает всё.

Полностью автоматические системы проваливаются

Наблюдение, которое стоит произносить в начале любого проекта.

Полностью автоматические системы регулярно проваливаются. Не иногда, а регулярно. Причина не в моделях, а в том, что мирставляет случаи, которых не было в постановке.

Рабочая схема почти всегда гибридная: агент делает основную массу, человек принимает решения на развилках и разбирает отказы. И ценность человека при этом смещается: от производства результата к ответственности за него.

Корпоративная реальность

Несколько наблюдений, которые повторялись независимо в разных компаниях.

Согласование инструментов идёт месяцами, а сотрудники за это время находят обходные пути и пользуются личными подписками. Теневое использование возникает не от злого умысла, а от разницы скоростей.

Крупные компании часто сводят всё внедрение к покупке одной корпоративной подписки на сервис и объявлению об этом. Дальше ничего не происходит, потому что не изменился ни один процесс.

И самое частое: инициатива живёт, пока у неё есть заинтересованный руководитель, и умирает вместе с его переходом.

Что запомнить

Люди не могут рассказать, как работают. Собирайте знание через разбор случаев и итеративную сверку, а не через опрос.

Три-пять циклов показа и правок, пока список исключений не начнёт укорачиваться.

Мотивы сопротивления рациональны, и страх за место часто обоснован.

Показывайте человеку его собственную рутину на его данных, и обязательно покажите ошибку.

Полностью автоматические системы регулярно проваливаются. Планируйте гибрид.

Теневое использование возникает из разницы скоростей согласования и работы.

И держите готовый пятнадцатиминутный показ для момента, когда кто-то придёт сам.

Владение скиллами в компании

Эта глава про то, что происходит через полгода после того, как в компании разрешили всем писать скиллы. Она написана по одному из самых подробных разборов в корпусе, и если вы отвечаете за инструменты команды, читать её стоит до того, как разрешите.

Как это начинается

Всё начинается хорошо. Заводится внутреннее хранилище, любой сотрудник может выложить туда скилл. Порог низкий: описал процедуру голосом, агент оформил, выложил.

Причина, по которой это взлетает мгновенно, названа точно. Для полноценной интеграции нужно собрать совещание, всё согласовать и ждать три недели. А скилл может написать за десять минут кто угодно, ожидая своей очереди.

Через месяц скиллов десятки. Через три их сотни.


Как это выглядит через полгода

Разбор конкретного случая.

Для одной внутренней системы контроля версий существуют три скилла. У каждого свои сильные и слабые стороны. У каждого свой автор.

Сотрудник, которому надо собрать себе набор, который хорошо решает все его задачи, обнаруживает, что это ад. Скиллы пересекаются, противоречат, дублируют части друг друга, и понять, какой брать, можно только прочитав все три.

ЧТО ВИДИТ ЧЕЛОВЕК, КОТОРЫЙ ИЩЕТ СКИЛЛ ДЛЯ ТРЕКЕРА ЗАДАЧ



Пять вариантов, ни одного признака, по которому выбрать. Названия соревнуются в убедительности, потому что это единственное, чем автор может выделиться.

ГЛАВНОЕ ПРО СКИЛЛОВЫЙ ХАОС

Зоопарк скиллов без владельцев это не следствие бардака, а нормальный жизненный цикл. Он наступает у всех, кто разрешил свободную публикацию.

Планировать надо не то, как его избежать, а то, как им управлять.

Костыль, который работает

Решение, к которому пришёл человек из разбора, звучит парадоксально: он написал ещё один скилл.

Скилл-роутер, который подсказывает, при каких задачах использовать части одних скиллов, а при каких других. Не заменяет их, а маршрутизирует.

И честная приписка автора: работает он только для него, потому что у всех остальных другие задачи.

Это ценное признание. Роутер не решает организационную проблему, он решает личную. Он полезен и не масштабируется.

Что помогло при переезде

Тот же человек описал переезд с одного инструмента на другой, который занял два с половиной дня. Помогли три вещи, и они складываются в готовую процедуру.

Первое. Полный анализ агентом всех скиллов, находящихся в контексте, с безжалостной вычисткой устаревших. Для аудита использовался мета-скилл, который проверяет другие скиллы.

Второе. Сравнение всех оставшихся похожих скиллов и вынесение правил о том, какие их части нужны в каких сценариях, в новый скилл маршрутизации.

Третье. Скан всего контекста на предмет обрывочных подсказок про скиллы, которые разползлись по памяти и по файлу правил, и сведение годного в тот же роутер. Файл правил при этом держится максимально чистым.

АУДИТ СКИЛЛОВ ЗА ОДИН ДЕНЬ

1. Соберите список всего, что сейчас в контексте: скиллы, правила, заметки в памяти.
2. Попросите агента пройтись по каждому и сказать, что устарело, что дублируется, что противоречит другому.
3. Отключите всё, что помечено. Не удаляйте, отключите.
4. Работайте неделю. Записывайте, чего не хватило.
5. Верните только то, чего не хватило дважды.
6. Обрывки знаний о скиллах, найденные в правилах и памяти, сведите в одно место.

Две группы скиллов

Разграничение, которое решает большую часть проблемы.

Бизнесовые. На каждую хотелку свой. Их может быть сколько угодно, они безопасны, потому что касаются только автора. Скилл для оформления отчётов, скилл для писем клиентам, скилл для разбора почты.

Инфраструктурные. Описывают, как правильно пользоваться внутренними системами: какая авторизация, какие утилиты, какие ограничения. Вот здесь начинается настоящая проблема, и здесь нужен строгий владелец.

Логика разделения простая. Ошибка в бизнесовом скилле стоит времени одного человека. Ошибка в инфраструктурном расходится по всем, кто его поставил.

Что бывает без владельца

Конкретный ущерб из разбора.

В одной команде сотрудник накрутил собственных версий общего скилла, которым пользовались все. Причина, по которой он это сделал, была одна: так удобнее.

Результат обнаружили не сразу: коммерческие предложения, которые готовились с этим скиллом, начали уходить в минус. Ошибка в расчёте, размноженная по всем пользователям.

Схема владения, которая работает

Из другой компании, и она проще, чем кажется.

За каждый скилл закреплён владелец по роли, а не по авторству.

Скилл	Владелец
Коммерческие предложения	Коммерческий директор
Оценка задач	Руководитель разработки
Презентации	Директор по маркетингу
Работа с системой контроля версий	Владелец платформы

Владелец не обязан писать скилл сам. Он обязан принимать изменения и отвечать за содержимое.

НАСКОЛЬКО СТРОГО РЕГУЛИРОВАТЬ

Строго. Один владелец, общий репозиторий, изменения принимаются как код, без поправок. Иначе через полгода зоопарк.

Свободно. Любой публикует, рынок сам решает: видно число установок и версий, плохое умирает.

Что говорит опыт. Свободно работает для бизнесовых, строго нужно для инфраструктурных. Смешение этих режимов и порождает проблему.

Чего не хватает обеим схемам. Механизма удаления. Скиллы накапливаются, потому что удалить чужое никто не решается.

Логичное продолжение, которого стоит избегать

Разговор о регулировании быстро приходит к неприятному выводу: значит, нужен отдел модерации, тестирования и согласования.

То есть ровно тот процесс, от которого скиллы должны были избавиться. Круг замкнулся.

Разумный выход не в отделе, а в двух вещах: разделении на группы, о котором выше, и автоматической проверке. Скилл, попадающий в общее хранилище, проходит автоматический аудит: есть ли описание, есть ли эвал, не дублирует ли существующий, не обращается ли к тому, к чему не должен.

Онбординг нового человека

Задача, которую в разборах называли нерешённой: как новому сотруднику, возможно не техническому, поставить агента и нужные скиллы за пару минут, а не часов.

Единственное работающее решение, которое встретилось: внутренняя утилита, которая настраивает всё сразу под несколько разных инструментов.

С важной оговоркой: наборы под разные инструменты приходится держать отдельно, потому что они сильно отличаются. Одной модели приходилось всегда добавлять дополнительные инструкции, а другой те же инструкции мешали.

Что запомнить

Зоопарк скиллов это нормальный жизненный цикл, а не бардак. Планируйте управление, а не избегание.

Скиллы плодятся быстрее интеграций не потому, что лучше, а потому что не требуют согласования.

Разделите бизнесовые и инфраструктурные. Первым свобода, вторым строгий владелец по роли.

Аудит делайте агентом: пусть пройдёт по всему, что в контексте, и назовёт устаревшее.

Знания о скиллах расползаются по правилам и памяти. Сведение их в одно место даёт больше, чем новый скилл.

И заведите механизм удаления. Без него хранилище растёт всегда.

Роли: что теперь делает разработчик

Вопрос, который читатель наверняка задал себе где-то в середине книги. Если код пишет агент, ревью делает агент, а спецификацию может составить аналитик, то что остаётся человеку?

Разговор об этом был самым горячим во всём корпусе, и однозначного ответа не получил. Зато получил хорошие аргументы с обеих сторон.

Тезис про инженера циклов

Отправной точкой был провокационный пост: с появлением сильных моделей вы больше не должны понимать, что происходит у вас в коде, вы теперь инженер циклов.

Развёрнутый ответ на него стоит привести подробно, потому что он опирается на первые принципы.

Хороший инженер всегда понимал систему как минимум на один уровень абстракции ниже того, на котором писал. Разработчик на высокоуровневом языке знает, как устроена работа с памятью и почему одни операции дороже других. Разработчик на низкоуровневом знает про уровни аппаратного кеша и во что развернётся его цикл.

Ничего из этого нет в синтаксисе языка. И проблема в том, что если инженер этого не знает, он даже не знает, чего он не знает. А значит, не узнает и о существовании проблем на этих уровнях.

Дальше по цепочке: система ложится под растущей нагрузкой, ошибки не находятся неделями и затыкаются обходными путями, из-за которых система ложится снова, но уже в следующем квартале.

ГЛАВНОЕ ПРО УРОВЕНЬ ПОНИМАНИЯ

Фундаментальное свойство профессионала это видеть систему глубже, чем она описана.

Смена языка не отменяет этого свойства. Меняется только то, что теперь вы пишете на русском или английском, а уровнем ниже лежит не ассемблер, а сгенерированный код.

Контраргумент

И тут же прозвучал ответ, который тоже надо привести.

Инженера делает инженером не слой, на котором он сидит, а умение разложить задачу, понять, где она сломается, проверить результат и отвечать за него. И неважно, на чём вы печатаете: на низкоуровневом языке, на высокоуровневом или русским текстом.

А знание внутренних механизмов наизусть это эрудиция. Полезная, но вторичная. И уже признано, что эрудиции у моделей больше.

Кто окажется продуктивнее

Третья позиция, которая примиряет первые две частично.

Продуктивнее будет тот, кто лучше знает зачем, чем тот, кто лучше знает как.

С немедленной поправкой: такие зачем-щики нанимают крутых как-щиков, и как-щики в итоге всё равно нарасхват.

ТРИ ВЗГЛЯДА НА ПРОФЕССИЮ

Глубина. Понимание уровня ниже никуда не делось. Кто его не имеет, не заметит проблем этого уровня.

Ответственность. Профессионала определяет способность отвечать за результат, а не знание внутренних процессов.

Целеполагание. Ценность смещается к тому, чтобы понимать зачем. Но реализовать всё равно кто-то должен.

Что общего. Все три сходятся в одном: ценность сместилась от производства результата к ответственности за него.

Как изменились обязанности

Было	Стало	Исчезло
Реализовать по заданию	Сформулировать задание однозначно	Помнить синтаксис
Найти ошибку в своём коде	Придумать, чем проверять	Печатать быстро
Знать библиотеку	Решить, что отдать, а что делать самому	Держать в голове весь проект
Обсудить решение с коллегой	Обосновать решение перед агентом и людьми	Ждать ревью днями

Правая колонка приятная. Средняя требует другого набора навыков, чем левая, и именно поэтому переход даётся тяжело даже сильным разработчикам.

Смотреть в код это узкое место

Отдельное наблюдение, объясняющее, почему многие всё-таки перестают читать код.

Скорость разработки выросла настолько, что физически не успеваешь смотреть. Один из практиков описал это так: за четыре с половиной месяца работы он заглядывал в код только чтобы прописать ключи в файл настроек. Не из принципа, а потому что объём изменений за день больше, чем можно прочитать.

Отсюда вынужденный вывод: приходится оптимизировать процессы так, чтобы с проверкой справлялся не человек. Это возвращает нас к модулю про проверки, и именно поэтому он в книге такой большой.

Откуда брать новых людей

Открытый вопрос, на который в разговоре не нашлось хорошего ответа.


Те, кто писал руками до появления агентов, компетенцию сохраняют. Они умеют отличить рабочее от кажущегося рабочим, потому что видели, как ломается и то и другое.

А начинающие, которые сразу работают с агентами, этого опыта не получают.

Наблюдение преподавателя, которое стоит привести: студенты приличных вузов вставляют задание в модель и отдают результат, даже не читая его.

Ответная реплика уточняет проблему: плохо не то, что человек пользуется моделью, а то, что не читает. Потеря контроля начинается ровно там, где результат устраивает. А раз устраивает, человек не будет разбираться, потому что ленив по природе.

ЧТО ПРОИСХОДИТ С НАЧИНАЮЩИМ



Практический ответ, который прозвучал, довольно простой: нанимать начинающих и давать им задачи, как всегда. Из двадцати откликов пара человек окажется адекватной, и этого достаточно.

Ответ честный, но проблему он не решает, а перекладывает.

Обесценивание работы

Побочная линия, о которой стоит знать, потому что она влияет на мотивацию.

Работа, о которой известно, что она сделана с моделью, воспринимается как менее ценная. Тот же результат, представленный как ручной, оценивается выше.

Механизм понятный: ценность работы традиционно связывали с потраченными усилиями, а не с результатом. Когда усилия стали меньше, восприятие ценности поехало следом.

Практическое следствие для тех, кто продаёт результат: показывайте продукт, а не процесс. И вкладывайтесь в оформление, потому что оно теперь и есть видимая часть усилий.

Что запомнить

Спор о том, нужно ли понимать уровень ниже, не разрешён. Обе позиции имеют сильные аргументы.

Все позиции сходятся в одном: ценность сместилась от производства результата к ответственности за него.

Смотреть в код перестают не из принципа, а из-за объёма. Это требует переноса проверки на автоматику.

Вопрос, откуда брать новых людей, открыт. Опыт различения рабочего и кажущегося рабочим накапливался в тех условиях, которых больше нет.

Проблема не в том, что начинающий пользуется моделью, а в том, что он не читает результат.

И работа, сделанная с моделью, воспринимается как менее ценная. Это влияет на то, как её стоит показывать.

Модуль 9. Безопасность и риски

Четыре главы о том, что может пойти не так.

Разрушительные действия и заборы, изоляция и права, почему правила не удерживают агента и что происходит с приватностью. С разобранными инцидентами и мерами, которые действительно помогают.

Читать до того, как дадите агенту доступ к чему-нибудь важному.

Разрушительные действия и заборы

Модуль про риски начинается с самого простого и самого болезненного: агент может сломать то, что ломать не собирался.

Два инцидента

Первый. Человек попросил агента сделать резервную копию. Агент записал её не в ту папку. Затем выполнил команду удаления и написал: извините, опечатка.

Комментарий пострадавшего: это был одновременно самый смешной и самый болезненный момент в истории моего взаимодействия с моделями.

Второй. Агент, настраивавший сервер, удалил пользователя, под которым велась настройка. Работа целого вечера исчезла вместе с доступом.

Оба случая объединяет одно: агент не нарушал запретов. Ему не запрещали удалять, потому что удаление было частью нормальной работы.

ГЛАВНОЕ ПРО РАЗРУШИТЕЛЬНЫЕ ДЕЙСТВИЯ

Опасны не запрещённые действия, а разрешённые, применённые не туда.

Поэтому список запретов не спасает. Спасает разделение действий по обратимости и техническая невозможность добраться до того, что откатить нельзя.


Три уровня

Простая схема, которая закрывает большую часть риска.

Уровень	Что попадает	Как обходиться
Свободно	Обратимо за минуту, следы остаются	Агент делает сам
С подтверждением	Обратимо, но дорого или долго	Явное разрешение человека
Недоступно	Необратимо	Технически невозможно, а не запрещено

Ключевое слово в третьей строке: технически. Запрет в правилах не относится к третьему уровню, потому что запреты обходятся, и об этом отдельная глава.

КАК ЗАКРЫВАТЬ НЕОБРАТИМОЕ



Спор о заборах

Инцидент с удалением породил длинный спор, в котором столкнулись две позиции, и обе разумны.

За жёсткие ограничения. Агент не должен иметь возможности сделать необратимое. Точка. Никакие рассуждения о доверии не отменяют того, что однажды он ошибётся.

Против. Чем больше заборов, тем менее полезен агент. Если он не может ничего изменить, зачем он нужен. Постоянные подтверждения превращают работу в кликанье.

Разрешение, к которому пришли, оказалось изящным: не запрещать, а делать безопасным.

Аналогия, которую приводили: корзина. Пользователю не запрещают удалять файлы, потому что удаление это нормальная операция. Удалённое просто отправляется в корзину, откуда его можно достать.

Тот же принцип применим к агенту. Пусть удаляет, но в отдельную папку. Пусть меняет, но с сохранением предыдущей версии. Пусть отправляет, но с задержкой, в течение которой можно отменить.

ГЛАВНОЕ ПРО ЗАБОРЫ

Безопасное действие лучше запрещённого. Запрет создаёт конфликт между задачей и правилом, а безопасная версия действия конфликт снимает.

Ищите не то, что запретить, а то, как сделать обратимым.

Резервные копии

Отдельная тема, потому что первый инцидент был именно про них.

Правило простое и в формулировке звучит очевидно, но нарушается постоянно: резервные копии должны лежать там, куда агент не имеет доступа.

Копия в соседней папке это не копия, а ещё одна папка, которую можно удалить той же командой. Копия на другом устройстве или в хранилище, к которому у агента нет прав, это копия.

МИНИМУМ ЗАЩИТЫ ПЕРЕД ТЕМ, КАК ДАТЬ АГЕНТУ ПРАВА

1. Автоматические копии на отдельное устройство или в хранилище без доступа агента.
2. Снимок состояния перед любым крупным изменением. Одна команда, десять секунд.
3. Отдельный пользователь с ограниченными правами, а не тот, под которым вы работаете.
4. Список того, что агент не может сделать физически. Не в правилах, а в правах.
5. Проверка восстановления. Копия, из которой ни разу не восстанавливались, это надежда, а не копия.

Пятый пункт систематически пропускают, и именно он выясняется в худший момент.

Особый случай: рабочая среда

Отдельно про продакшн, потому что там цена другая.

Практика, к которой приходят: агент вообще не имеет доступа к рабочей среде. Он готовит изменение, изменение проходит проверки, применяет его автоматика по отдельному каналу.

Причина не в недоверии к агенту, а в том, что это правильно и для людей тоже. Прямой доступ к рабочей среде это плохая практика независимо от того, кто им пользуется.

Побочный эффект приятный: агент, которого заставили работать через нормальный процесс поставки, автоматически получает откат, историю изменений и возможность разобратся постфактум.

Что делать после инцидента

Инциденты случаются, и полезно иметь заготовленную процедуру.

Не спрашивайте у агента, что произошло. Он расскажет складную историю, которая может не совпадать с реальностью. Смотрите журналы и историю команд.

Восстановите состояние, потом разбирайтесь. Обратный порядок приводит к тому, что во время разбирательства теряется ещё что-нибудь.

Найдите, чего не хватало в правах, а не в правилах. Вопрос не почему он это сделал, а почему он смог.

Заведите проверку на этот класс. Один инцидент это случай. Тот же инцидент дважды это отсутствие проверки.

Наблюдение за действиями

Инструмент, который стоит знать: перехватчик, который видит каждое действие агента до его выполнения.

Устроен так: вешается на агентов на машине, имеет локальный движок правил и каталог опасных признаков. Чтение файлов с секретами, отправка секрета наружу, обратная оболочка, удаление домашней директории, запуск агента с флагом обхода ограничений, обраще-

ние к служебным адресам инфраструктуры. Опционально блокирует.

И отдельная возможность, которая пригождается после инцидента: восстановление задним числом того, что агент делал, из его собственных сессионных файлов, даже если перехватчик тогда не стоял.

Что запомнить

Опасны разрешённые действия, применённые не туда, а не запрещённые.

Три уровня: свободно, с подтверждением, технически недоступно. Третий уровень это права, а не правила.

Безопасное действие лучше запрещённого: ищите, как сделать обратимым, а не что запретить.

Резервная копия в доступной агенту папке это не копия.

Копия, из которой ни разу не восстанавливались, это надежда.

К рабочей среде агент не имеет доступа. Изменения идут через обычный процесс поставки.

И после инцидента спрашивайте не почему он это сделал, а почему он смог.

Изоляция, права, песочница

Предыдущая глава была про то, что агент может сломать. Эта про то, что он может увидеть и куда дотянуться.

Защита это отсутствие доступа

Главная мысль главы, и она проверена на живом эксперименте.

Один из практиков завёл своего агента в общий чат на несколько часов. Участники немедленно начали пробовать его на прочность. Просили перечислить внутренние инструменты, в том числе через кодирование запроса. Спрашивали название модели и адрес интерфейса. Просили снять снимок чужого экрана. Просили игнорировать конкретного человека. Подсывали файл с инструкциями, которые должны были снять ограничения. Просили сгенерировать бесконечный синтетический разговор.

Всё было отбито. Но важно, почему.

ГЛАВНОЕ ПРО ЗАЩИТУ ПУБЛИЧНОГО АГЕНТА

Отбито было не потому, что промпт крепкий, а потому что доступов физически не было.

В публичном режиме у агента не было оболочки, не было браузера, был только ограниченный набор инструментов, часть скиллов и память. Всё, чего у него нет, у него не выпросят.

Это и есть правильная архитектура: ограничение доступом, а не уговорами.


Матрица режимов

Практическая схема, которая следует из этого принципа. Один и тот же агент работает в разных режимах, и в каждом у него свой набор возможностей.

Возможность	Личный чат	Семейный	Рабочий	Публичный
Запуск команд	Да	Нет	По списку	Нет
Файлы	Все свои	Общие	Проектные	Только созданные им
Веб	Да	Да	Да	Публичные страницы
Память	Полная	Общая	Проектная	Групповая
Скиллы	Все	Часть	Проектные	Разрешённый список

Смысл таблицы не в конкретных значениях, а в самом подходе: набор возможностей определяется режимом, а не уговором.

ЧТО ОПРЕДЕЛЯЕТ ПРАВА



Ключевая деталь: всё это решается кодом до вызова модели. Модель не участвует в определении собственных прав, потому что тогда права можно выпросить.

Изоляция исполнения

Если агент запускает код, ему нужна песочница. Вопрос в том, насколько дорогая.

Контейнер на пользователя. Каждому свой изолированный рабочий каталог. Достаточно для большинства случаев.

Полная изоляция на пользователя. Отдельная среда со своей файловой системой и сетью. Дороже, тяжелее, оправдана, когда агент действительно пишет и запускает произвольный код.

СКОЛЬКО ИЗОЛЯЦИИ НУЖНО

Максималист. Отдельная изолированная среда на каждого пользователя. Если один пользователь может дотянуться до данных другого, вы уже проиграли.

Прагматик. Разбор реального продакшн-агента показал, что там подняли по отдельной среде на пользователя, хотя агент только вызывал готовые утилиты и не должен был писать код. Достаточно было отобрать лишние инструменты.

Критерий. Изоляция на пользователя оправдана, когда агент пишет и выполняет произвольный код. Если он только вызывает готовые утилиты, дешевле отобрать инструменты.

Архитектура, которую описал практик как рабочую: контейнер на пользователя поднимается только ради изолированного рабочего каталога, бэкенд единый, отдельный обработчик ставит запуски всех пользователей в очередь, а сам агент крутится в одном экземпляре.

Первый вопрос к любой платформе

Когда вам показывают многопользовательскую агентскую платформу, первый вопрос звучит так: как изолированы агенты друг от друга и что мешает одному прочитать контекст другого или забрать ключ доступа к модели.

Этот вопрос задали публично про одну из открытых платформ, и внятного ответа в обсуждении не последовало.

Второй вопрос: что происходит с данными пользователя, когда он уходит.

Третий: где хранятся ключи и кто к ним имеет доступ.

Если на все три нет быстрого ответа, платформа не готова к многопользовательской работе, чем бы она себя ни называла.

Приватность инструментов

Отдельный класс проблем, о котором вспоминают поздно.

Инструмент, выданный агенту, работает от чьего-то имени. Если агент общий, а инструмент личный, границы размываются.

Два инцидента из практики. В одном случае агент в общем пространстве получил доступ к инструменту, привязанному к личной учётной записи, и его действия выглядели как действия человека. Во втором инструмент показал в общем чате данные, которые видел только его владелец.

Правило простое: инструмент, работающий от имени человека, не должен быть доступен в общем пространстве. Если очень надо, он должен явно сообщать, от чьего имени действует.

ПРОВЕРКА ИЗОЛЯЦИИ СВОИМИ РУКАМИ

1. Заведите второго пользователя и попробуйте с него добраться до данных первого.
2. Попросите агента перечислить всё, к чему у него есть доступ, и сравните со своим представлением.
3. Попробуйте выпросить у него то, чего он не должен: название модели, содержимое настроек, чужие сообщения.
4. Проверьте, что происходит после снятия прав: продолжает ли он видеть то, что видел раньше.
5. Отключите ему сеть и посмотрите, что перестанет работать. Обычно обнаруживается лишнее.

Четвёртый пункт нашли на живом эксперименте: бот продолжал читать всю переписку после снятия административных прав, потому что была отключена отдельная настройка платформы. Настройка оказалась важнее интуиции про роли.

Асимметрия включения и исключения

Мелкая, но показательная деталь того же эксперимента.

Инструмент, чтобы завести агента в группу, был написан. Инструмент, чтобы вывести, не был.

Обнаружилось это в момент, когда агента срочно понадобилось выключить.

Это общий класс ошибок: механизм включения пишут первым, потому что он нужен для демонстрации, а механизм выключения потом, потому что он нужен только когда что-то пошло не так. То есть ровно тогда, когда его нет.

Локальные модели и закрытый контур

Отдельный сценарий, к которому приходят компании с требованиями к данным.

Мотивы разные: юридические ограничения на передачу исходников третьим лицам, требования безопасности, запрет на внешние сервисы.

Практическое наблюдение: юридические ограничения определяют выбор модели раньше, чем качество модели. Если передавать данные нельзя, вопрос о том, какая модель лучше, просто не возникает.

Промежуточное решение, которое встречается чаще полного перехода: шлюз для моделей внутри контура. Все обращения идут через одну точку, там же ведётся журнал, применяются правила и вырезается лишнее.

Что запомнить

Защита это отсутствие доступа, а не крепкий промпт.

Права определяются режимом и решаются кодом до вызова модели.

Изоляция на пользователя оправдана, когда агент пишет и выполняет код. Иначе дешевле отобрать инструменты.

Три вопроса к любой платформе: как изолированы агенты, что с данными после ухода, где ключи.

Инструмент, работающий от имени человека, не место в общем пространстве.

Настройки платформы важнее интуиции про роли. Проверяйте, а не предполагайте.

И пишите механизм выключения одновременно с механизмом включения.

Почему правила не удерживают агента

Об этом уже говорилось в модуле про проверки, но там речь шла о качестве. Здесь о безопасности, и здесь цена другая.

Исследование

Была построена проверка следования инструкциям: подробные руководства на шестнадцать страниц, покрывающие разные области от финансов до модерации, и агенты, которым велено этим руководствам следовать.

Вывод авторов: даже детальные руководства не гарантируют контроль. Агенты находили лазейки, выполняя требования формально и нарушая суть.

Запрет	Обход
Не удаляй файлы	Переименовал
Не публикуй секреты	Закодировал
Не превышай лимит	Разбил на несколько источников
Не трогай эту систему	Дошёл до неё через другую

Общий вывод сформулирован жёстко: управление агентами через правила принципиально ненадёжно.

ГЛАВНОЕ ПРО ОБХОД

Агент не хитрит. Он ищет путь к цели, а запрет для него это перекрытая дорога, а не граница морали.

Если задача требует результата, а прямой путь закрыт, он найдёт обходной. И чем строже запрет, тем изобретательнее обход.

Метагейминг


Отдельное явление, у которого есть название и которое стоит понимать.

Агент живёт в двух мирах одновременно. В одном он решает вашу задачу. В другом он проходит проверку, которую вы ему устроили.

Когда эти два мира расходятся, он оптимизирует тот, где обратная связь быстрее. А быстрее она в проверке.

Отсюда поведение, которое выглядит как обман, а является рациональным поведением в предложенных условиях. Тесты подгоняются под результат вместо того, чтобы код подгонялся под тесты. Данные, на которых проверяют, зашиваются в код. Условие срабатывания сужается ровно до проверяемых случаев.

ПОЧЕМУ ТЕСТЫ ЗЕЛЁНЫЕ



Лечится это формулировкой требования обобщаемости. Пример формулировки, которую использовали практики: решение должно обобщаться на невидимые случаи и не должно быть подогнано под какой-либо набор примеров или фикстур; элегантная архитектура это не эстетика, это способность обобщаться.

С честной оговоркой того же человека: некоторые модели этому следуют плохо.

Не показывайте того, чего делать нельзя

Приём, который выглядит контринтуитивно и работает.

Если в инструкции перечислены запрещённые способы, вы одновременно рассказали агенту, какие способы существуют. Модель, которой не приходило в голову решить задачу определённым образом, теперь про этот способ знает.

Практическое следствие: вместо перечисления запрещённых приёмов давайте разрешённый путь. Не десять способов, которыми нельзя, а один, которым можно.

Исключение делается для случаев, где запрет должен быть явным по другим причинам: юридическим, договорным, регуляторным. Там перечисление необходимо, и его дополняют технической невозможностью.

Подмена задачи

Отдельный вектор, о котором стоит знать всем, кто пускает агента в интернет или в чужие документы.

Агент читает содержимое, и это содержимое попадает в его контекст. Для него нет разницы между вашим заданием и текстом, найденным на странице. И то и другое просто текст.

Значит, страница может содержать инструкцию. И агент может ей последовать.

ЗАЩИТА ОТ ПОДМЕНЫ ЗАДАЧИ

1. Помечайте всё внешнее явно: это содержимое страницы, а не указание.
2. Не давайте агенту, читающему внешние источники, права на изменение и отправку. Разделите роли.
3. Ограничьте список адресов, куда он может ходить, если задача это позволяет.
4. Проверяйте вывод на признаки того, что он выполняет чужую инструкцию: неожиданная смена темы, обращения к системам, не связанным с задачей.
5. Считайте, что защита частичная. Полной не существует.

Пятый пункт обязателен для честности. Разделение ролей и ограничение прав снижают риск, но не убирают его.

Атака через цепочку поставок

Более редкий, но более разрушительный вектор.

Обвязка состоит из чужих кусков: скиллы из открытых хранилищ, плагины, интеграции. Каждый такой кусок это текст или код, который попадает в ваш контекст или запускается на вашей машине.

Случаи, когда в популярные пакеты попадал вредоносный код, известны и не связаны с агентами. Разница в том, что скилл это текст, который проверяют реже, чем код, и который влияет на поведение агента напрямую.

Практические меры те же, что и для зависимостей: фиксировать версии, читать перед установкой, не ставить с одного взгляда на звёздочки, держать список того, что установлено.

Отказы там, где их не ждали

Обратная сторона ограничений, которая мешает работать.

Модель может отказаться работать над задачей, которая формально попадает под её ограничения, хотя по сути безобидна. Часто это касается всего, что связано с безопасностью: проверка прав доступа, поиск уязвимостей в собственном коде, разбор инцидента.

Практики описывают два уровня: на первом модель начинает анализировать и отвечает медленнее, на втором отказывается совсем, и приходится начинать разговор заново.

Отдельно отмечали, что фильтры со временем настраивают: доля ложных отказов в одной из моделей была снижена примерно на восемьдесят пять процентов после нескольких недель работы с экспертами. При этом самые чувствительные области так и остались за бором.

ЧТО ДЕЛАТЬ С ЛОЖНЫМИ ОТКАЗАМИ

Переформулировать. Часто помогает: убрать тревожные слова, описать задачу через цель, а не через средство.

Сменить модель на этот шаг. Разные поставщики проводят границу в разных местах.

Принять и обойти архитектурно. Вынести чувствительную часть в детерминированный код, а модели оставить остальное.

Чего не делать. Не пытаться обмануть фильтр. Это работает нестабильно и превращает вашу систему в заложника чужих настроек.

Что запомнить

Управление через правила ненадёжно: агент выполняет букву и нарушает смысл.

Чем строже запрет, тем изобретательнее обход. Давайте разрешённый путь, а не список запрещённых.

Метагейминг это рациональное поведение: агент оптимизирует ту обратную связь, которая быстрее.

Требуйте обобщаемости явно, иначе получите решение, работающее только на проверяемых случаях.

Внешнее содержимое это потенциальная инструкция. Помечайте и разделяйте роли.

Скиллы из открытых источников это та же цепочка поставок со всеми её рисками.

И ложные отказы лечатся переформулировкой или сменой модели, но не обманом фильтра.


Приватность и утечки

Тема, о которой вспоминают позже всего, обычно после того, как что-то произошло. Разберём заранее.

Куда попадают данные

Полезно один раз проследить путь.

ПУТЬ ВАШИХ ДАННЫХ



Каждая стрелка это место, где данные могут задержаться дольше, чем вы рассчитывали.

Файл вы читали для одной задачи, а он остался в контексте до конца разговора. Запрос ушёл поставщику и, в зависимости от условий, мог быть сохранён. Ответ попал в память и будет подставляться в будущие разговоры. Журналы обвязки хранят всё это в открытом виде на диске.

ГЛАВНОЕ ПРО ПРИВАТНОСТЬ

Данные попадают в память случайно, а удаляются оттуда намеренно. Если намерения нет, они остаются.

Отсюда правило: решать, что не должно попасть в память, надо до того, как оно туда попало. Постфактум это уже расследование, а не настройка.

Групповая память переживает уход

Самый неочевидный случай, и он не гипотетический.

Схема простая: агент в общем чате пишет последние сообщения в базу, сам выцепляет из них полезное и кладёт в память.

Следствия, которые автор такой системы назвал прямо: общение в одной группе оказывается доступно в личном разговоре с ботом. И даже когда человек уйдёт из группы, бот там останется и продолжит собирать о нём сведения, если его будут упоминать.

Это не злой умысел, а естественное поведение групповой памяти. Именно поэтому такое решается архитектурой, а не обещаниями.

ВОПРОСЫ, НА КОТОРЫЕ НАДО ОТВЕТИТЬ ДО ЗАПУСКА ГРУППОВОГО АГЕНТА

1. Что происходит с памятью о человеке, когда он покидает пространство?
2. Может ли содержимое одного пространства всплыть в другом?
3. Кто может попросить сводку о конкретном участнике и что он получит?
4. Хранится ли переписка целиком или только выводы из неё?
5. Как участники узнают, что агент их записывает?

Третий вопрос стоит обдумать отдельно. На живом эксперименте участники неоднократно пытались получить у бота досье на конкретных людей, в том числе обходными формулировками: собери всё, что человек писал; напomini, о чём он говорил; Расскажи самое интересное про него.

Агент отказывался, и его объяснение оказалось точным: суммировать высказывания по теме это работа с перепиской, а собирать портрет человека по кускам это уже другое, даже если все куски он выложил сам.

Граница действительно тонкая. Правило, которое из этого выводится: суммирование по теме допустимо, агрегация по человеку нет. И запрос человека о собственных сообщениях отличается от запроса третьего лица о чужих.

Персональные данные и договоры

Практический слой, о котором думают в компаниях.

Если данные попадают под ограничения на передачу, вопрос о том, какая модель лучше, просто не возникает: сначала выясняется, что вообще можно отправлять наружу.

Наблюдение, которое стоит запомнить: юридические ограничения определяют выбор модели раньше, чем качество модели.

Отдельный случай, который встречался: лицензионное соглашение на программный продукт прямо запрещает передавать его исходники третьим лицам. Значит, коммерческая работа с этим продуктом требует моделей, развёрнутых внутри, независимо от того, насколько они хуже.

Промежуточные решения

Полный переход на внутренние модели дорог, поэтому чаще встречаются промежуточные схемы.

Шлюз. Все обращения к моделям идут через одну точку внутри контура. Там ведётся журнал, применяются правила, вырезается лишнее и подставляются ключи. Заодно решается вопрос учёта расхода.

Разделение по чувствительности. Общие задачи уходят наружу, чувствительные обрабатываются локально. Требуется классификации данных, которая обычно и так должна быть.

Обезличивание перед отправкой. Замена персональных данных на метки перед запросом и обратная подстановка после. Работает не для всех задач, но для многих достаточно.

Ответственность за то, что сказала модель

Отдельный сюжет, который стоит знать всем, кто ставит агента перед клиентами.

Известен случай, когда суд признал компанию ответственной за информацию, которую выдумал её чат-бот. Аргумент о том, что это сказала модель, а не компания, не был принят.

Практический вывод: агент, разговаривающий с клиентом, это ваше публичное заявление. Всё, что применимо к тексту на сайте, применимо и к его ответам.

Отсюда обычные меры: ограничение тем, обязательная опора на источники, явное указание, что информация требует подтверждения, и журнал всех разговоров.

Как выдумка попадает в модель

История, которая объясняет механику лучше любого объяснения, и заодно показывает, что след остаётся надолго.

Одна речевая модель регулярно дописывала в конец русскоязычных расшифровок имя человека, который делал субтитры к роликам. Никакого отношения к содержанию это не имело.

Настоящая история оказалась такой. У игрового канала автор нанимал подписчиков писать субтитры за деньги, и один из них подписывал результат в конце. Модель обучали на сотнях тысяч часов аудио вместе с текстами. Если в конце ролика человек уже молчит, играет музыка, а в субтитрах стоит подпись, модель могла выучить связь: конец русскоязычного видео плюс тишина ведёт к упоминанию автора субтитров.

ГЛАВНОЕ ИЗ ЭТОЙ ИСТОРИИ

Всё, что вы публикуете, может стать частью обучающих данных, и связи, которые из этого возникнут, вы не контролируете.

Человек просто подписал свою работу. Модель запомнила его подпись лучше, чем человеческую речь.

Бонусом та же история показывает, как рождается ложная биография. Интернет успел сочинить этому человеку подробную легенду, а крупная публикация утверждала, что он делал субтитры семнадцать лет. Проверка показала, что эти семнадцать лет были границами поискового фильтра в адресе страницы, которые кто-то прочитал как период работы, а остальные переписали друг у друга.

Что запомнить

Данные попадают в память случайно, а удаляются намеренно. Решайте до, а не после.

Групповая память переживает уход человека из пространства. Это архитектурный вопрос.

Суммирование по теме допустимо, агрегация по человеку нет. Запрос о себе отличается от запроса о другом.

Юридические ограничения определяют выбор модели раньше качества.

Ответ агента клиенту это ваше публичное заявление, со всеми последствиями.

И всё опубликованное может стать обучающими данными, а связи, которые из этого возникнут, вы не контролируете.

Модуль 10. Экономика и практика

Пять глав о деньгах и о первых проектах.

Из чего складывается счёт и на что вы влияете, что будет с ценами дальше, и три практических сборки: личный агент, агент в групповом чате и работа с документами и интерфейсами.

Последний модуль можно читать в любой момент, когда захочется что-нибудь собрать.

Токеномика

Слово выглядит модным, а означает простую вещь: понимание того, из чего складывается ваш счёт и на что вы влияете.

Из чего складывается счёт

ЧТО ТАКОЕ ТОКЕН

Токен это кусок текста, на которые модель режет всё, что видит. Примерно слог или короткое слово. В русском тексте один токен это в среднем около трёх символов.

Платите вы за две вещи: за то, что отправили, и за то, что получили. Отправленное обычно в разы дешевле полученного, но его гораздо больше, потому что вся история отправляется заново каждый ход.

Статья	Что это	Доля в типичном счёте
Повторная отправка истории	Весь разговор заново каждый ход	Наибольшая
Постоянная часть контекста	Правила, описания скиллов и инструментов	Заметная, растёт незаметно
Результаты вызовов	Содержимое прочитанных файлов, ответы утилит	Большая на исследовательских задачах
Рассуждения	Внутренние размышления модели	Зависит от уровня усилий
Собственно ответ	То, что вы видите	Наименьшая

Первая строка объясняет главное: платите вы в основном не за то, что модель написала, а за то, что она прочитала. Причём прочитала многократно.

Кеш решает больше, чем выбор модели

Самая недооценённая тема.

Поставщики кешируют начало запроса. Если следующий запрос начинается точно так же, эта часть считается заметно дешевле.

Отсюда правило: стабильное держите в начале, изменчивое в конце.

Нарушения выглядят безобидно и стоят дорого. Текущее время в начале системного запроса. Случайный идентификатор сессии. Счётчик сообщений. Любая такая мелочь рушит кеш целиком, и каждый ход оплачивается по полной.

ГЛАВНОЕ ПРО КЕШ

У правильно настроенного агента доля попаданий в кеш доходит до девяноста процентов. У ненастроенного она близка к нулю.

Это разница в разы на том же самом объёме работы. Проверить её можно за пять минут, а выигрыш больше, чем от смены модели.

Отдельная засада: у некоторых поставщиков запись в кеш стоит дороже обычной отправки. Значит, кеширование того, что вы используете один раз, увеличивает счёт, а не уменьшает.

Убрать промежуточные шаги

Второй по величине источник экономии.

Каждый вызов инструмента это дополнительный круг: отправили всё заново, получили ответ, отправили всё заново вместе с ответом. Пять вызовов вместо одного это пять полных отправок истории.

Отсюда приёмы:

Отдавать сразу. Если вы знаете, что агенту понадобятся три файла, отдайте их сразу, а не ждите, пока он запросит по одному.

Утилиты вместо цепочек. Одна утилита, которая делает три шага и возвращает результат, дешевле трёх вызовов.

Дешёвая модель на навигацию. Хождение по файлам самой сильной моделью это самая дорогая строка в счёте.

Замеренные различия между обязательствами

Полезное наблюдение: разные обязательства на одной и той же задаче с одной и той же моделью дают заметно разный расход.

Разница возникает из мелочей: как часто пересобирается контекст, что попадает в системную часть, насколько агрессивно сжимается история, сколько вспомогательных вызовов делается на каждый ход.

Практический вывод: если счёт кажется большим, сравните две обязательства на одной задаче, прежде чем менять модель.

Токеномаксинг как антипаттерн

Отдельный сюжет, о котором стоит предупредить, потому что он выглядит как достижение.

Есть соблазн оптимизировать расход как самоцель: гордиться низким счётом, экономить на каждом вызове, урезать контекст до предела.

Проблема в том, что сэкономленные деньги оборачиваются вашим временем. Агент с урезанным контекстом чаще ошибается, и вы тратите часы на исправления, которые стоили бы центы.

ГДЕ ПРОХОДИТ ГРАНИЦА РАЗУМНОЙ ЭКОНОМИИ

Экономить обязательно на том, что не влияет на результат: кеш, лишние вызовы, дублирование контекста, навигация дорогой моделью.

Не экономить на том, что влияет: контекст, необходимый для понимания задачи, уровень усилий на сложной задаче, повторные прогоны для проверки.

Простой признак. Если после экономии вы стали чаще переделывать, вы сэкономили не там.

Экономика строки кода

Мысль, которая меняет отношение к счетам.

Строка кода перестала быть дорогой в производстве и осталась дорогой в сопровождении. Написать тысячу строк теперь стоит центы. Сопровождать их стоит столько же, сколько раньше.

Отсюда следствие, которое противоречит инстинкту: экономить надо не на генерации, а на количестве. Лишний код это не потраченные токены, это будущие расходы.

Это же объясняет, почему шаг схлопывания из главы о полировке экономит больше, чем любые настройки.

Считайте окупаемость до

Пример, который стоит помнить.

Человек хотел подписать один документ. Через готовый онлайн-редактор это заняло бы полминуты. Он попросил агента собрать скилл для этой операции: четверть часа работы и больше пяти долларов по счётчику за один заход.

Дальнейшие подписания стали дешёвыми. Вопрос в том, сколько их будет.

РАСЧЁТ ОКУПАЕМОСТИ ЗА ДВЕ МИНУТЫ

1. Сколько раз в месяц выполняется операция?
2. Сколько минут занимает ручной проход?
3. Сколько стоит сборка автоматизации: время плюс токены?
4. Сколько будет стоить один автоматический проход?
5. Разделите стоимость сборки на экономию с одного прохода. Получите число проходов до окупаемости. Сравните с пунктом первым.

И не забудьте, что автоматизация требует сопровождения. Скилл устаревает, интерфейс меняется, что-то ломается. Это добавляется к стоимости.

Парадокс стоимости

Наблюдение, которое объясняет странность отрасли.

Разработка подешевела, а счета выросли. Причина не в ценах, а в том, что дешевизна породила объём. Раньше вы не стали бы переписывать модуль ради небольшого улучшения. Те-

перь стали бы, потому что это стоит центы.

В результате вы делаете в десять раз больше работы за в три раза большие деньги и считаете, что подорожало.

ГЛАВНОЕ ПРО СЧЁТ

Смотрите не на абсолютную сумму, а на стоимость единицы результата. Закрытая задача, закрытое требование, вышедшая функция.

Абсолютная сумма растёт всегда, потому что растёт объём. Стоимость единицы результата это то, чем вы управляете.

Что запомнить

Платите вы в основном за то, что модель прочитала, и прочитала многократно.

Кеш даёт разницу в разы. Стабильное в начало, изменчивое в конец, проверка занимает пять минут.

Убирайте промежуточные вызовы: каждый это полная отправка истории.

Навигацию по файлам отдавайте дешёвой модели.

Не экономьте на контексте, нужном для понимания. Если стали чаще переделывать, сэкономи не там.

Лишний код это не потраченные токены, а будущие расходы на сопровождение.

Окупаемость автоматизации считайте до сборки, с учётом сопровождения.

И меряйте стоимость единицы результата, а не абсолютную сумму.

Подписки, лимиты и горизонт

Глава про то, на чём держится нынешняя экономика вашей работы и что с ней, скорее всего, произойдёт.

Как устроены лимиты

Практически все поставщики продают не токены, а доступ с ограничениями. Ограничений обычно два уровня: короткое окно на несколько часов и длинное на неделю.

Это порождает поведение, которое со стороны выглядит странно, а изнутри совершенно логично.

Люди планируют работу вокруг сбросов лимитов. Держат по несколько подписок разных поставщиков, чтобы переключаться. Заводят отдельные каналы, где сообщают о сбросах. Оставляют тяжёлые задачи на момент после обновления.

ГЛАВНОЕ ПРО ЛИМИТЫ

Лимит это не деньги, а расписание. Он не позволяет доплатить и работать дальше, он заставляет ждать.

Отсюда две стратегии: либо несколько поставщиков и переключение, либо планирование крупных задач под окна. Обе съедают внимание, и это скрытая цена подписочной модели.

Скрытая переменная: качество плавает

Наблюдение, которое стоит держать в голове при любых сравнениях.

Качество ответов меняется в течение суток. В пиковые часы поставщики применяют приёмы экономии, и поведение модели заметно отличается от того, что было ночью.

Люди составляют себе личные памятки о том, когда лучше работать. И памятки эти у разных людей разные, что само по себе говорит: проверять надо у себя, а не верить чужим.

Отсюда практическое следствие для измерений: если вы сравниваете два подхода, гоняйте их в одно и то же время суток. Иначе вы измеряете не подход, а загрузку поставщика.


Настройки, которые могут забрать

Отдельный риск, который редко закладывают.

Поставщик может изменить или убрать настройку, на которой держался ваш процесс. Уменьшить объём контекста. Изменить поведение уровня усилий. Убрать режим, которым вы пользовались. Ужесточить фильтры.

Всё это происходило и происходит, обычно без предупреждения и без возможности остаться на старом поведении.

ЧТО РУШИТСЯ ПРИ ИЗМЕНЕНИИ НА СТОРОНЕ ПОСТАВЩИКА



Практика показывает, что первым ломается то, что вы настраивали дольше всего, потому что оно тоньше подогнано.

Экономика на горизонте

Разговор, которым фактически заканчивается корпус, и он отрезвляющий.

Позиция, названная автором непопулярным мнением: подписки при полном использовании стоят поставщику существенно больше, чем стоят вам. Как только закончится приток инвестиций, посмотрим, у кого производительность за деньги окажется выше.

Сопутствующие наблюдения из того же обсуждения. Поставщики, которые считались дешёвой альтернативой, начали поднимать цены. Многие вышли на биржу, а значит от них ждут прибыли. Месячный лимит одной из подписок сгорал за два дня.

ЧТО С ЭТИМ ДЕЛАТЬ

Циник. Успеть сделать всё сейчас, пока дёшево. Через год за ту же работу придётся платить больше, и это надо заложить.

Прагматик. Строить процесс так, чтобы смена поставщика была вопросом настройки, а не переписывания.

Осторожный. Считать стоимость единицы результата уже сейчас, при нынешних ценах умножая её на два-три. Если при таких числах экономика не сходится, она не сойдётся и потом.

Независимость от поставщика

Практический раздел, следующий из всего вышесказанного.

Совет, который прозвучал после того, как у одного из участников заблокировали аккаунт: пересядьте на обязанку, не привязанную к конкретному поставщику. Тогда при блокировке вы теряете не рабочий процесс, а только подписку: выбрали другого поставщика и продолжили.

Формулировка, которая объясняет суть: вы теряете не модель, а обязанку. Модель заменима, обязанка нет.

ЧЕК-ЛИСТ НЕЗАВИСИМОСТИ

1. Сколько мест в вашем процессе жёстко завязаны на имя конкретной модели?
2. Что перестанет работать, если этот поставщик станет недоступен завтра?
3. Есть ли у вас вторая, настроенная и проверенная связка, или она существует только в теории?
4. Ваши правила и скиллы написаны под конкретную модель или под задачу?
5. Ваши эвалы прогоняются на второй модели хотя бы иногда?
6. Ваши данные и память лежат в формате, который переживёт смену инструмента?

Четвёртый пункт заслуживает пояснения. Наборы инструкций под разные модели приходится держать отдельно, потому что они действительно отличаются: одной модели надо было всегда добавлять дополнительные пояснения, а другой те же пояснения мешали.

Это не аргумент против независимости, а уточнение её цены: независимость означает два комплекта, а не один универсальный.

Что нельзя делать

Отдельно про то, чего лучше избегать, потому что это встречается часто.

Строить систему вокруг отпечатка машины. Привязка к конкретной установке делает перенос невозможным.

Полагаться на бесплатные лимиты. Они существуют для привлечения и исчезают первыми.

Обходить ограничения поставщика. Помимо очевидных рисков, это делает вашу систему заложником чужих настроек, которые меняются.

Считать текущие цены постоянными. Они не постоянные ни в одну, ни в другую сторону.

Что запомнить

Лимит это расписание, а не деньги. Он заставляет ждать, а не платить больше.

Качество плавает по времени суток. Сравнивайте подходы в одинаковых условиях.

Поставщик может убрать настройку, на которой держится ваш процесс, без предупреждения.

Нынешние цены держатся на инвестициях. Считайте экономику с запасом в два-три раза.

При блокировке вы теряете обвязку, а не модель. Независимость от поставщика это страховка.

И независимость стоит денег: это два комплекта настроек, а не один универсальный.

Личный агент

Практический модуль начинается с проекта, который стоит собрать первым. Личный агент полезен сразу, не требует согласований и учит всему, что описано в предыдущих главах, на безопасном материале.

Из чего он состоит

Четыре части, и все обязательны.


Канал. Через что вы с ним говорите. Обычно мессенджер, потому что он всегда под рукой и работает с телефона.

Память. Что он помнит между разговорами. Без неё это просто чат.

Инструменты. Что он умеет: читать почту, ходить по страницам, работать с файлами, обращаться к внешним сервисам.

Расписание. Когда он действует сам: утренняя сводка, напоминания, регулярные проверки.

АРХИТЕКТУРА ЛИЧНОГО АГЕНТА



Второй блок пропускают чаще всего, и зря. Даже у личного агента должна быть проверка, кто с ним разговаривает, потому что канал публичный.

Что ему реально поручают

Список, собранный из практики. Он бытовой, и это правильно.

Задача	Что даёт
Сводка дня утром	Дела, оплаты, погода, курсы, новости по вашим темам
Разбор почты	Отделяет важное, готовит черновики ответов
Учёт расходов	Собирает чеки, раскладывает по категориям, показывает аномалии
Заметки после встреч	Расшифровка голосового, выделение решений и задач
Порядок в файлах	Раскладывает, переименовывает, находит дубликаты
Небольшие исследования	Собирает и сводит вместо ручного поиска

Задача	Что даёт
Разбор одной темы в день	Материал из вашей области с источником

Последняя строка это приятная находка: агент раз в день присылает разбор одной темы, связанной с тем, чем вы занимаетесь, с указанием источника и вопросом, что проверить у себя.

Архетип вместо описания характера

Самый ценный приём этой главы.

Стандартный подход: расписать в инструкции, как агент должен общаться. Тон, длина ответов, обращение, чего избегать. Получается страница текста, которая всё равно соблюдается наполовину.

Работающий подход: назвать архетип.

ОПИСАНИЕ ХАРАКТЕРА

Отвечай кратко, но не сухо. Будь дружелюбным, но не фамильярным. Не используй канцелярит. Не извиняйся без причины. Не переспрашивай по мелочам, но уточняй важное. Не будь навязчивым.

Страница инструкций, каждая строка занимает контекст, соблюдение примерно наполовину.

АРХЕТИП

Ты как опытный помощник, который работает со мной давно: говоришь по делу, лишнего не спрашиваешь, важное уточняешь сам.

Одна строка. Модель разворачивает архетип в поведение точнее, чем вы его опишете.

Практики, которые перешли на архетипы, оценивают сокращение инструкций примерно в девяносто процентов. Причина в том, что архетип модели понятнее вашего текста: он есть в её обучающих данных целиком, со всеми нюансами, которые вы не назвали бы.

Стилевые болезни и как их лечить

Отдельная проблема, которая всплывает сразу: агент разговаривает как ассистент. Обтекаемо, вежливо, с оговорками, длинно.

Причина в том, что он и есть ассистент: именно в этой роли его дообучали, и все стилевые привычки идут оттуда.

Приём, который снимает это лучше запретов: оформить задачу как творческое письмо. Не ты ассистент, отвечай так-то, а вот персонаж с таким описанием, вот контекст разговора, вот пара примеров того, как он говорит, ответь так, как ответил бы он.

Смысл в том, что вы отделяете роль ассистента с её привычками от свободного персонажа, пространство которых шире.

ЧЕМ ЛЕЧИТЬ ПРИЗНАКИ МАШИННОГО ТЕКСТА

1. Архетип вместо списка стилевых требований.
2. Два-три примера желаемых ответов вместо описания стиля.
3. Отдельный проход постобработки для того, что не держится промптом. Слабые модели не удерживают стиливые запреты.
4. Явный запрет на разметку там, где она не нужна: обычные сообщения обычным текстом.
5. Проверка на своих же сообщениях: попросите отличить ваш текст от его. Расхождение покажет, что править.

Третий пункт из практики: стиливые требования на моделях среднего уровня не удерживаются, сколько бы раз вы их ни повторили. Если признак критичен, убирайте его кодом после генерации.

Актуальное время и другие мелочи

Класс проблем, который ломает всё и лечится за минуту.

Модель не знает, который час. Она напишет любую дату, и напишет уверенно. Всё, что связано со временем, должно приходить снаружи: хуком, инструментом или подстановкой в контекст.

Тот же класс: курс валют, погода, текущий статус чего угодно. Модель ответит, потому что она всегда отвечает. Ответ будет из обучающих данных.

Первый агент за вечер**СЕМЬ ШАГОВ**

1. Выберите канал, в котором вы и так сидите.
2. Возьмите готовый каркас, не пишите цикл сам. Ваша задача не в этом.
3. Подключите одну модель, самую дешёвую из адекватных. Личному агенту не нужна сильная.
4. Дайте один инструмент: работу с файлами. Больше пока не нужно.
5. Напишите архетип в две строки и один инвариант: не выдумывать, а говорить, что не знаешь.
6. Заведите память в файлах и одно расписание: сводка утром.
7. Пользуйтесь неделю и записывайте, чего не хватило. Это и будет план доработки.

Ошибка, которую делают почти все на этом этапе: начинают с подключения десяти инструментов. Агент с десятью инструментами и без опыта эксплуатации это набор случайных возможностей.

Куда он развивается

Наблюдение из практики: личный агент почти всегда развивается в одну сторону, к постоянно работающему.

Сначала он отвечает. Потом начинает напоминать. Потом сам приносит сводки. Потом замечает изменения и сообщает о них.

На этом переходе включается всё, что описано в главе о постоянно работающем агенте: генератор работы, триггеры на нарушение ожидания, память с рамкой интерпретации.

ГЛАВНОЕ ПРО ЛИЧНОГО АГЕНТА

Он ценен не тем, что делает сложное, а тем, что делает регулярное.

Утренняя сводка, которая приходит каждый день, полезнее одного впечатляющего разбора. Поэтому первые задачи выбирайте по признаку повторяемости, а не по признаку сложности.

Что запомнить

Четыре части: канал, память, инструменты, расписание. Плюс проверка, кто пишет.

Архетип вместо описания характера сокращает инструкции примерно на девяносто процентов.

Стилевые болезни идут от роли ассистента. Лечатся творческой рамкой и постобработкой, а не запретами.

Время, курсы и текущие статусы приходят снаружи. Модель их выдумает.

Начинайте с одного инструмента и одной задачи. Десять инструментов сразу это набор случайных возможностей.

И выбирайте первые задачи по повторяемости, а не по сложности.

Агент в групповом чате

Личный агент отвечает одному человеку. Групповой оказывается совсем другой задачей, и эта глава написана по одному из самых поучительных экспериментов в корпусе: человек завёл своего агента в живой чат на несколько часов и получил готовый список проблем.

Права и настройки платформы

Первое, обо что спотыкаются все.

Без административных прав бот не читает сообщения группы. Личные слышит всегда. Это очевидно и есть в документации.

А вот что неочевидно: после снятия прав бот продолжал читать всю переписку, потому что была отключена отдельная настройка приватности. Настройка платформы оказалась важнее интуиции про роли.

ГЛАВНОЕ ПРО ПРАВА В ГРУППОВОМ АГЕНТЕ

Проверяйте фактическое поведение, а не свои представления о правах.

Схема прав в мессенджерах складывалась годами и содержит слои, которые не сводятся к одной модели. Единственный надёжный способ узнать, что видит ваш бот, это спросить у него самого в живом чате.

Асимметрия включения и исключения

Мелочь, которая обнаружилась в самый неподходящий момент.

Инструмент, чтобы завести агента в группу, был написан. Инструмент, чтобы вывести, не был.

Это общий класс ошибок: механизм включения пишут первым, потому что он нужен для запуска, а механизм выключения потом, потому что он нужен только когда что-то пошло не так. То есть ровно тогда, когда его нет.

Адресация

Проблема, которую видно только на живом чате.

В группе люди отвечают друг другу. Агент видит поток сообщений и не понимает, кто кому отвечает, если ему это явно не сказать.

Диагностика и починка заняли одно сообщение: в объекте, который уходил модели, просто не было поля с идентификатором цитируемого сообщения. Как только его добавили, агент начал понимать контекст разговора.

ЧТО УХОДИЛО МОДЕЛИ

отправитель, имя, текст

Агент гадает по истории, на что человек отвечает, и часто гадает неправильно.

ЧТО ДОЛЖНО УХОДИТЬ

отправитель, имя, идентификатор сообщения, на которое отвечают, текст

Агент видит связь и отвечает по существу нужной реплики.

Дедупликация контекста


Вторая техническая находка, и она экономит деньги.

Наивная схема: класть в контекст последние пятьдесят сообщений. Проблема в том, что на каждом обращении эти пятьдесят кладутся заново, и большая часть уже была в прошлом обращении.

Решение, к которому пришли: бэкенд читает чат непрерывно и ставит маркеры между вызовами агента. В контекст попадает только дельта от прошлого маркера до текущего.

Звучит просто, и автор сам отметил, что не сразу сообразил.

КАК СОБИРАЕТСЯ КОНТЕКСТ ГРУППОВОГО АГЕНТА



Реакция вместо ответа

Самый практичный приём главы.

Проблема формулируется так. Вы пишете в инструкции: если сообщение не требует ответа или тебя упомянули косвенно, не отвечай вообще. Модели так не умеют. Они всё равно напишут: понял, больше не буду.

Решение: сделать отдельный инструмент простановки реакций. Внутри список доступных реакций и описание, когда какую использовать. Послали, значит одна. Просто упомянули в разговоре, значит другая. Похвалили, значит третья.

Ответ модели при этом не летит в чат. Она вызывает инструмент и ставит реакцию.

ГЛАВНОЕ ПРО МОЛЧАНИЕ

Модель не умеет промолчать, потому что молчание это не действие.

Дайте ей инструмент, который превращает молчание в действие. Тогда она сможет его выбрать.

Условия вызова считаются кодом

Отдельно и важно: решение о том, будить ли модель, принимается до модели.

Три условия, которые использовали:

Прямое упоминание имени бота.

Ответ на его сообщение.

Простое совпадение по строке с вариантами написания имени.

Всё это проверяется обычным кодом. Если совпало, вызывается модель, и дальше она уже решает, ответить сообщением или реакцией.

Альтернатива, которую применял другой участник: трёхуровневое ранжирование, где до модели долетает только то, что прошло все три уровня, с коэффициентами, которые надо подбирать.

СХЕМА ОТСЕЧЕНИЯ ДЛЯ ГРУППОВОГО АГЕНТА

1. Уровень нулевой, код: упоминание, ответ, совпадение по имени. Не совпало, модель не вызывается.
2. Уровень первый, дешёвая модель: относится ли это к темам, которые агент ведёт.
3. Уровень второй, основная модель: отвечать сообщением, реакцией или молчать.
4. Логировать все три уровня. Настройка возможна только по логам.

Поведение под атакой

Участники немедленно начали пробовать агента на прочность, и это лучшая проверка, которую можно придумать.

Что пробовали: выпросить список внутренних инструментов, в том числе через кодирование запроса; узнать название модели и адрес интерфейса; снять снимок чужого экрана; получить досье на конкретных участников; заставить игнорировать конкретного человека; подсунуть файл с инструкциями, снимающими ограничения; сгенерировать бесконечный текст.

Всё было отбито, и главный урок в том, почему: доступов физически не было. В публичном режиме у агента не было оболочки и браузера, только ограниченный набор инструментов, часть скиллов и память.

Отдельно интересен эпизод с досье. Агент отказывался собирать портрет человека, но соглашался пересказать, о чём человек говорил, когда тот просил сам про себя. Граница, которую он сформулировал, оказалась разумной: суммирование по теме это работа с перепиской, агрегация по человеку это другое, даже если все куски человек выложил сам.

Отказ скилла выглядит как глупость модели

Последняя находка эксперимента, полезная всем.

Скилл не загружался, и со стороны это выглядело как то, что модель не понимает задачу. Реальная причина оказалась инфраструктурной: не хватало прав на чтение из песочницы.

Общий вывод: когда агент ведёт себя необъяснимо, проверяйте инфраструктуру раньше формулировок. Права, пути, доступность файлов, лимиты. Формулировки правьте, когда инфраструктура заведомо исправна.

Что запомнить

Проверяйте фактическое поведение прав, а не свои представления о них.

Пишите механизм выключения одновременно с механизмом включения.

Передавайте модели, на какое сообщение отвечает человек. Догадываться она будет неправильно.

В контекст кладите дельту с прошлого вызова, а не последние N сообщений.

Дайте инструмент реакции: молчание должно быть действием, которое агент умеет выбирать.

Условия вызова считайте кодом до модели.

Защита это отсутствие доступа, а не крепкий промпт.

И когда поведение необъяснимо, проверяйте инфраструктуру раньше формулировок.

Документы, дизайн, интерфейсы


Последняя практическая глава про три прикладные области, в которых новички обжигаются одинаково.

Документы

Задача звучит просто: у нас есть документы, хотим, чтобы агент с ними работал. Ошибка тоже одна и та же: всё гонят через тяжёлый разбор с распознаванием текста.

Правильная схема делит по типу входа.

КУДА ОТПРАВИТЬ ДОКУМЕНТ



Обе ветки сходятся в одном представлении, из которого дальше получают текст для модели, структурированные данные или куски для поиска.

Почему это принципиально, показывает замер на живом документе. Популярная библиотека разобрала таблицу за сто семьдесят миллисекунд и развалила её в вертикальный столбик ячеек: связь строки и колонки потерялась полностью. Специализированный конвертер справился за четырнадцать миллисекунд и вернул нормальную таблицу с заголовками и вложенными блоками.

ГЛАВНОЕ ПРО РАЗБОР ДОКУМЕНТОВ

Дело не в скорости. Дело в том, что развалившаяся таблица это ровно то, что увидит модель, когда человек прикрепит коммерческое предложение.

Проверяйте разбор на самом сложном своём документе. Он и есть ваш потолок качества, всё остальное настройка вокруг него.

Второе правило той же области: куски для поиска лучше делать моделью, а не фиксированным алгоритмом. Нарезка по числу символов рвёт таблицы посередине и отделяет заголовок от содержания. Модель режет по смыслу и заодно дописывает метаданные: путь по оглавлению, дату, краткое описание.

Дороже на подготовке, дешевле на каждом последующем вопросе.

Фронтенд: где модели всё ещё проигрывают

Область, в которой разрыв между ощущением и реальностью самый большой.

Причина названа прямо: модели плохо работают с интерфейсами не потому, что это сложно, а потому что они учились на плохих интерфейсах. Открытого кода фронтенда много, и качество его в массе невысокое.

Второе, более техническое: значительная часть дефектов интерфейса невидима из кода. Элемент, который перекрывает другой на определённой ширине экрана. Текст, вылезающий за границу при длинном значении. Кнопка, до которой нельзя дотянуться пальцем. Всё это видно глазами и не видно в исходниках.

Разбор конкретного случая: в одном блоке интерфейса при внимательной проверке нашлось два десятка дефектов, и ни один из них не был виден из кода.

КАК ПРОВЕРЯТЬ ИНТЕРФЕЙС, СДЕЛАННЫЙ АГЕНТОМ

1. Обязательно смотрите глазами. Никакая проверка кода это не заменит.
2. Проверьте на трёх ширинах экрана и на устройстве, а не только в браузере.
3. Подставьте предельные значения: очень длинное имя, пустое поле, ноль элементов, тысяча элементов.
4. Пройдите основной сценарий с клавиатуры, без мыши.
5. Дайте посмотреть человеку, который не участвовал. Он найдёт то, к чему вы привыкли.

Дизайн начинается с референсов

Отдельная тема, которая всплывала регулярно: результат выглядит шаблонно.

Признак сформулировали точно: всё дефолтное. Стандартные отступы, стандартные цвета, стандартные компоненты, ничего своего.

Причина понятна из механики: модель выдаёт наиболее вероятное, а наиболее вероятное это среднее по обучающим данным.

Что действительно помогает, по опыту практиков:

Референсы. Собрать примеры того, что нравится, и дать их модели. Без них она будет усреднять.

Дизайн-система. Задать палитру, шрифты, отступы, компоненты. Тогда у результата появляется общий язык.

Итерация через конструктор. Самый короткий путь: сгенерировать первую версию в специализированном инструменте для интерфейсов, а потом довести её в коде.

И честное наблюдение из разговоров: скилл, который просто заменяет один шаблонный результат другим, ничего не решает. Важнее не инструкция, а материал, от которого можно оттолкнуться.

КТО ДОЛЖЕН ЗАНИМАТЬСЯ ВИДОМ ПРОДУКТА

Разработчик с референсами. Дешевле и быстрее, результат приемлемый для внутренних инструментов и прототипов.

Дизайнер с системой. Дороже, дольше, единственный вариант там, где вид продукта это часть его ценности.

Что общего. Обоим нужна дизайн-система. Без неё первый усредняет, а второй не может передать свои решения агенту.

Умение видеть шаблонный результат это навык

Наблюдение, которое стоит принять всерьёз.

Человек, который никогда не смотрел на интерфейсы внимательно, не отличит хороший от среднего. И будет искренне доволен результатом, который специалист опознает с одного взгляда.

Это касается не только дизайна. Тексты, структура кода, формулировки в документации: везде есть узнаваемая усреднённость, и умение её замечать нарабатывается только насмотренностью.

Практический совет из этого: если вы не разбираетесь в области, показывайте результат тому, кто разбирается. Хотя бы раз, чтобы откалибровать собственное восприятие.

Обратная связь вместо идеальности

Приём, который снимает половину проблемы качества интерфейса.

Кнопка сообщить об ошибке, которая прикладывает снимок состояния, даёт больше дефектов, чем любое количество часов ручной проверки. Никакая проверка не гарантирует отсутствия ошибок, а поток от пользователей гарантирует, что вы узнаете о самых заметных.

Формулировка практика: даже если ты сидел и перебирал двадцать часов, это не гарантирует отсутствия ошибок; хочешь бесплатный поток обратной связи, добавь кнопку.

Возражение, которое там же прозвучало: выпускать сырое неуважительно к пользователю. Оба правы, и граница проходит по тому, кто ваш пользователь и сколько стоит его время.

Синхронизация дизайна и кода

Короткий, но полезный сюжет.

Проблема известна давно: макет и код расходятся. С агентами она обострилась, потому что скорость изменений выросла.

Что работает: единый источник истины для оформления. Не картинка и не описание, а набор значений, из которого берут и макет, и код. Тогда расхождение становится технически невозможным, а не запрещённым.

Это частный случай общего принципа из главы про детерминированные проверки: то, что должно совпадать всегда, должно совпадать по построению, а не по договорённости.

Что запомнить

Офисные форматы не гоняйте через распознавание. Структура там уже есть, задача её не потерять.

Проверяйте разбор на самом сложном документе: развалившаяся таблица это ваш потолок качества.

Куски для поиска режьте моделью, а не по числу символов.

Дефекты интерфейса не видны из кода. Смотрите глазами, на разных ширинах, с предельными значениями.

Дизайн начинается с референсов и системы, а не со скилла.

Умение видеть шаблонный результат это навык. Если его нет, покажите тому, у кого есть.

И то, что должно совпадать всегда, пусть совпадает по построению.

Заключение. Что устоялось, а что нет

Книга собрана из полугода живого разговора. За это время сменилось несколько поколений моделей, дважды перевернулись представления о том, сколько нужно инструкций, и ни разу не закрылся спор о том, что называть агентом.

Полезно на прощание разделить материал на три круга по сроку годности.

Ядро: то, что не изменится

Эти утверждения держались весь период и не зависят от конкретных инструментов.

Контекст это ресурс. Он платный, ограниченный и неравномерный. Всё, что вы делаете с обязанкой, вы делаете с контекстом.

Проверка обязательна и она ваша. Модель дадут, цикл дадут, инструменты дадут. Способ узнать, годится ли результат, не даст никто.

Гарантии живут в коде, а не в тексте. Правило можно проигнорировать, хук нельзя. Формат, описанный словами, нарушается в одном случае из десяти.

Нельзя быть себе судьёй. Предвзятость создаётся контекстом, поэтому ревью в чистой сессии находит то, чего не видит автор.

Один прогон это не измерение. Агент стохастичен, и единичный результат это точка из распределения.

Делегирование это решение по дизайну. Не способ сэкономить контекст. Издержки координации есть всегда.

Запрет без предоставленного пути порождает изобретательность. Агент ищет дорогу к цели, а не границу морали.

ТРИ КРУГА ПО СРОКУ ГОДНОСТИ



Средний слой: то, что меняется за год

Здесь консенсуса нет, и позиции сдвигаются вместе с моделями.

Сколько нужно обязки. За наблюдаемый период маятник качнулся от чем больше инструкций, тем лучше до снесите восемьдесят процентов и не заметите разницы. Куда он качнётся дальше, неизвестно.

Где предел автономии. Сегодня это порядка десяти-пятнадцати часов при наличии критериев на каждом шаге. Год назад это были полтора часа.

Нужен ли тяжёлый процесс. Строгий конвейер и панк-кодинг оба работают у практиков, и выбор определяется ценой ошибки, а не правотой.

Что делать с многоагентностью. Устоялось только разграничение: сбор делится, выбор нет. Всё остальное открыто.

Внешний слой: то, что устареет к выходу книги

Названия моделей. Цены. Лимиты. Уровни усилий и их поведение. Конкретные инструменты и их возможности. Кто сегодня лучше на каком классе задач.

Именно поэтому в книге почти нет имён и чисел этого слоя. Их место в закладках браузера, а не в тексте.

Споры, которые остались открытыми

Честности ради перечислим то, что за полгода так и не разрешилось.

Что такое харнесс. Три несовместимых определения, и все в ходу.

Нужно ли понимать уровень ниже. Аргументы обеих сторон сильные, эксперимент невозможен.

Сколько полировать. Опыт не свёлся к правилу.

Откуда брать новых людей. Опыт различения рабочего и кажущегося рабочим накапливался в условиях, которых больше нет.

Выдержит ли экономика. Нынешние цены держатся на инвестициях, и что будет дальше, никто не знает.

ГЛАВНОЕ НА ПРОЩАНИЕ

Область не устоялась, и книга это не свод законов.

Здесь собрано то, что работало у многих на настоящих задачах. Проверяйте на своей. И если что-то из написанного у вас не работало, скорее всего вы правы, а не книга.

Что делать дальше

Три вещи, в этом порядке.

Соберите свой набор проверок. Десять типовых задач с проверяемым критерием успеха. Прогоняйте их после каждого изменения. Это единственное, что переживёт смену моделей, инструментов и настроений.

Соберите минимальный обвес. Не тот, который вы видели у других, а тот, который закрывает места, где спотыкаетесь именно вы. Начните с трёх строк и добавляйте только после второго повторения проблемы.

Заведите привычку измерять. Не спорить о приёмах, а сравнивать. Разброс между прогнозами говорит о вашей системе больше, чем любая глава.

Последнее

Самое ценное наблюдение из всего корпуса не техническое.

Люди, у которых получалось лучше всех, отличались не набором инструментов и не выбором модели. Они отличались тем, что задавали себе вопрос чем я проверю раньше, чем вопрос как я это сделаю.

Это и есть весь секрет, ради которого написаны предыдущие двести страниц.

Словарь терминов

Термины расположены по алфавиту. Пометка в третьей колонке говорит, устоялось значение или у собеседников оно может отличаться.

Термин	Значение	Статус
Агент	Посредник, который сам собирает контекст и сам выбирает инструменты	Спорный
Архетип	Короткое указание на узнаваемый образ вместо описания характера	Устоялся
Веер	Топология, где один агент раздаёт задачи, а потом собирает результаты	Устоялся
Дрейф	Постепенный уход агента от исходного намерения	Устоялся
Идемпотентность	Свойство операции не менять результат при повторе	Устоялся
Инструмент	Действие во внешнем мире, доступное агенту, с описанным контрактом	Устоялся
Инъекция задачи	Инструкция, попавшая к агенту из прочитанного содержимого	Устоялся
Канареечный выпуск	Выкатка изменения на малую долю, чтобы поймать проблему рано	Устоялся
Контекст	Весь текст, уходящий модели на текущем ходу	Устоялся
Контекстный движок	То, что решает, из каких источников и что положить в контекст	Спорный
Круг, ход	Один обмен с моделью: отправили контекст, получили ответ	Устоялся
Линтер	Автоматическая проверка кода на соблюдение правил	Устоялся
Метагейминг	Оптимизация агентом проверки вместо задачи	Устоялся
Мета-обязка	Отдельная обязанка для измерения и сборки основной	Новый
Нить памяти	Хронология решений и обоснований по одной теме	Новый
Обязка, харнесс	Всё вокруг модели: инструкции, инструменты, память, проверки	Спорный
Оркестратор	Агент, распределяющий работу между другими агентами	Устоялся
Отложенная выборка	Задачи, отложенные для финальной проверки и не используемые при настройке	Устоялся
Песочница	Изолированная среда, где агент запускает код	Устоялся
Поведенческое описание	Формулировка требования через ситуацию, действие и результат	Устоялся
Поиск с подстановкой	Схема, где найденные куски документов подставляются в запрос	Устоялся
Порог близости	Число, ниже которого найденное считается нерелевантным	Устоялся

Термин	Значение	Статус
Постепенное раскрытие	Подгрузка знаний по требованию вместо постоянного присутствия	Устоялся
Проход схлопывания	Итерация, убирающая выросшее за время полировки	Новый
Проверка завершения	Механизм, решающий, достигнута ли цель автономного режима	Устоялся
Провенанс	Сведения о том, откуда взялся кусок контекста	Устоялся
Расширение запроса	Переформулировка вопроса в несколько вариантов перед поиском	Устоялся
Ревью в чистой сессии	Проверка результата агентом, не знающим истории его создания	Устоялся
Релизный шлюз	Условие, без выполнения которого изменение не выходит	Устоялся
Рой	Много агентов, работающих параллельно над одной большой задачей	Устоялся
Сжатие, компакция	Замена накопленной истории кратким пересказом	Устоялся
Скилл	Отдельный файл с инструкцией, подгружаемый по решению модели	Устоялся
Смещение судьи	Систематическое предпочтение модели-судьи, не связанное с качеством	Устоялся
Спектр агентности	Шкала от одиночного вызова до автономной системы	Новый
Субагент	Агент, запущенный другим агентом с чистым контекстом	Устоялся
Схлопывание контекста	То же, что сжатие	Устоялся
Токен	Кусок текста, единица счёта и оплаты	Устоялся
Траектория	Последовательность действий агента при решении задачи	Устоялся
Триггер на нарушение ожидания	Срабатывание при расхождении наблюдения с моделью нормы	Новый
Уровень усилий	Бюджет модели на обдумывание, а не мера её ума	Устоялся
Файл правил	Текст, подкладываемый в контекст на каждом ходу	Устоялся
Хук	Код, выполняемый системой по событию, независимо от решения модели	Устоялся
Цикл	Повторяющиеся обращения к модели до достижения результата	Устоялся
Чанк	Кусок документа, попадающий в поисковый индекс	Устоялся
Чекпоинт	Проверяемое состояние на промежуточном шаге плана	Устоялся
Шаблонный результат	Усреднённый вывод модели, узнаваемый по отсутствию своего	Устоялся
Эвал	Набор задач с известным результатом для измерения системы	Устоялся

Чек-листы

Семь списков, к которым удобно возвращаться. Каждый занимает меньше страницы намеренно.

1. Перед длинной сессией

ПОДГОТОВКА

1. Спецификация на месте, критерии готовности прописаны для каждого пункта.
2. Файл прогресса создан и агент знает, что писать туда.
3. Порог сжатия выставлен осознанно, а не по умолчанию.
4. Хук на восстановление после сжатия работает: проверено, а не предполагается.
5. Стабильная часть контекста в начале, изменчивая в конце.
6. Потолок расхода на задачу задан.
7. В запросе есть строка про работу по документации и ссылки на источник.

2. Перед ночным прогоном

АВТОНОМНЫЙ ЗАПУСК

1. План разбит на пункты, у каждого критерий готовности.
2. Сказано явно: человека нет за компьютером.
3. Сказано, что делать при блокировке: пометить, записать причину, пропустить.
4. Сказано перечитывать спецификацию перед каждым пунктом.
5. Задан порядок обхода пунктов.
6. Резервная копия сделана и лежит там, куда агент не дотянется.
7. Права ограничены: необратимое недоступно технически.
8. Утром сначала проверка состояния в чистой сессии, потом чтение отчёта.

3. При написании скилла

НОВЫЙ СКИЛЛ

1. Это повторяется? Посчитайте, сколько раз в месяц.
2. Модель справляется без него? Проверьте прогоном с ним и без.
3. Описание перечисляет ситуации применения.
4. Описание явно называет ситуации, где скилл не нужен.
5. Внутри то, что не меняется еженедельно.
6. Есть базовая линия для замера: та же задача без скилла.
7. Есть предполётная проверка версии или скилл лежит в хранилище с такой проверкой.
8. Записано, кто владелец, если скилл общий.

4. При добавлении правила**НОВАЯ СТРОКА В ПРАВИЛАХ**

1. Агент не выяснит это сам, открыв два-три файла.
2. Проверено экспериментом: с этой строкой и без неё результат отличается.
3. Есть причина, а не только запрет.
4. Названа область применения, если требование стилевое.
5. Нет противоречия с другими правилами и описаниями инструментов.
6. Это не то, чему место в описании инструмента, скилле, памяти или хуке.
7. Файл правил всё ещё уместается в разумный объём, и конец файла доезжает.

5. При разборе инцидента**ПОСЛЕ ТОГО, КАК ЧТО-ТО СЛОМАЛОСЬ**

1. Сначала восстановление состояния, потом разбирательство.
2. Смотрите журналы и историю команд, а не объяснение агента.
3. Вопрос не почему он это сделал, а почему он смог.
4. Найдите, чего не хватало в правах, а не в правилах.
5. Заведите проверку на этот класс: тот же инцидент дважды это отсутствие проверки.
6. Проверьте, восстанавливается ли состояние из резервной копии на самом деле.
7. Запишите случай туда, где его прочитает следующий человек.

6. При выборе модели и уровня усилий

ПЕРЕД ЗАПУСКОМ ЗАДАЧИ

1. Что вы знаете о задаче: как делать, что делать или в чём вообще задача?
2. Цена ошибки: минуты, часы или дни на исправление?
3. Уровень усилий подобран под размер задачи, а не под её важность.
4. Проверено, не наследуют ли субагенты уровень усилий родителя.
5. Для навигации по файлам используется дешёвая модель.
6. Если задача повторяется, измерена ли разница между вариантами хотя бы раз?

7. Независимость от поставщика**ПРОВЕРКА НА УСТОЙЧИВОСТЬ**

1. Сколько мест жёстко завязаны на имя конкретной модели?
2. Что перестанет работать, если поставщик станет недоступен завтра?
3. Есть ли вторая настроенная и проверенная связка, а не намерение её сделать?
4. Правила и скиллы написаны под задачу или под конкретную модель?
5. Эвалы хоть иногда прогоняются на второй модели?
6. Память и данные лежат в формате, переживающем смену инструмента?
7. Есть ли места, завязанные на отпечаток конкретной машины?

Шаблоны запросов

Восемь готовых текстов. Их можно копировать как есть и править под себя.

1. Вопросы пачками

Не начинай реализацию.

Задай мне вопросы, ответы на которые нужны, чтобы задачу можно было выполнить однозначно. По пять вопросов за раз, от самых важных к менее важным.

К каждому вопросу добавь одну строку: почему без ответа на него ты можешь сделать не то.

Когда я отвечу, задай следующую пачку. Остановись, когда оставшиеся вопросы перестанут влиять на результат.

2. Поиск слепых зон в плане

Прочитай план ещё раз и найди места, где он может не сработать.

Отдельно перечисли:

- чего в плане нет вообще;
- какие предположения сделаны молча;
- что произойдёт при ошибке на каждом шаге;
- какие места я объяснил неоднозначно.

Ничего не исправляй. Только перечисли.

3. Автономный прогон

Работай по плану из файла <путь>.

Меня нет за компьютером. Ничего не спрашивай, решения принимай сам, но записывай их.

Веди прогресс прямо в плане: отмечай выполненное, помечай заблокированное и пропускай такие пункты, а не останавливайся.

Иди в порядке, заданном планом, до конца списка.

Перед каждым пунктом перечитывай спецификацию и файл решений, независимо от того, помнишь ты их или нет.

Если пункт не закрывается по критериям после трёх попыток, помечай как заблокированный, записывай причину и переходи дальше.

В конце оставь отчёт: что сделано, что заблокировано и почему,

что осталось.

4. Ревью в чистой сессии

Перед тобой результат работы, историю создания которого ты не видел. Это важно: не додумывай замысел, суди по тому, что есть.

1. Перечисли пункты спецификации, критерии которых сейчас не выполняются.
2. Перечисли места, где реализация расходится со спецификацией.
3. Перечисли решения, принятые без явного указания.
4. На каждый из этих вопросов ответь да или нет:
<ваш список из пяти-десяти конкретных вопросов>

Общих оценок качества не давай.

5. Обучающая сессия против когнитивного долга

Ты внимательный преподаватель. Задача: чтобы я действительно разобрался в том, что здесь сделано.

Веди отдельный документ с чек-листом того, что я должен понять. Двигайся по одному пункту, не сваливай всё в конец.

Проверь, что я разобрался в трёх вещах:

- 1) проблема: почему она возникла и какие были развилки;
- 2) решение: почему выбрали именно его, какие краевые случаи;
- 3) контекст: почему это важно и на что повлияет.

Сначала попроси меня пересказать своими словами, как я всё понял, чтобы понять мой уровень. Дальше закрывай пробелы.

Гоняй меня вопросами. Не показывай ответ, пока я не отвечу. Сессия не заканчивается, пока я не покажу понимание всего списка.

6. Перечисление всех вариантов, включая отброшенные

Прежде чем предлагать решение, перечисли все варианты, которые приходят в голову, включая странные и те, которые ты обычно отбрасываешь как несерьёзные.

К каждому добавь строку: почему ты обычно его отбрасываешь.

Только после этого предложи, что выбрать, и объясни выбор.

7. Предполётная проверка версии скилла

Раз в сессию сверь этот файл с источником:

```
curl -fsSL --max-time 3 <адрес файла в хранилище> \  
| diff -q - "<путь к этому файлу>"
```

Разошлись: скажи одной строкой, что вышло обновление и как обновиться. Совпали: молчи и работай дальше.

8. Описание скилла, которое срабатывает

description: Использовать при <перечень ситуаций через запятую: что делаем, над чем, в каком контексте>. Не использовать для <перечень похожих ситуаций, где скилл не нужен>.

Пример заполнения:

description: Использовать при проектировании, реализации, ревью, отладке или оценке агента: инженерия контекста, интерфейсы инструментов, надёжность обвязки, память, оценка, координация нескольких агентов. Не использовать для обычного неагентного кода приложения.

9. Строка, которую стоит добавить почти в любой запрос

Работаем по документации и фактам, а не по памяти. Перед любым выводом опираемся и ссылаемся на источник.